

# 集箱管接头内焊缝表面缺陷识别方法研究<sup>\*</sup>

焦敬品 李思源 常 予 吴 斌 何存富

(北京工业大学机械工程与应用电子技术学院 北京 100124)

**摘 要:** 针对集箱管接头内焊缝表面缺陷自动检测需要,进行了基于计算机视觉的集箱管接头内焊缝表面缺陷自动识别方法研究。分析了不同焊缝图像的纹理特征,从焊缝图像的灰度共生矩阵中提取出 15 种可用于焊缝表面缺陷状态表征的特征参数。在此基础上,研究将 BP 神经网络应用于焊缝表面缺陷自动识别中。分析了灰度共生矩阵的步长、灰度级、神经网络的结构参数及输入特征参数的数量和种类对焊缝图像识别效果的影响,优化出最佳的识别参数。在以上研究基础上,利用优化后的神经网络对内窥镜获得的不同焊接质量的焊缝图像进行了训练和识别。结果表明,提出的基于图像纹理的神经网络识别系统可以很好实现集箱管接头内焊缝焊接状态的自动评价,整体识别率达 91%。研究工作为集箱管接头内焊缝焊接质量自动检测做了有益的探索。

**关键词:** 焊缝; 表面缺陷; 纹理特征; 灰度共生矩阵; BP 神经网络

中图分类号: TP391 TH878 文献标识码: A 国家标准学科分类代码: 460.40

## Defect classification of weld surface in header pipe joint

Jiao Jingpin ,Li Siyuan ,Chang Yu ,Wu Bin ,He Cunfu

( College of Mechanical Engineering and Application Electronics Technology , Beijing University of Technology , Beijing 100124 , China)

**Abstract:** In order to automatically classify weld surface defect in header pipe joint , Computer Vision based defect classification is studied. The texture features of different weld defects are analyzed , Grey level co-occurrence matrix ( GLCM) is applied to extract features from digital images , and 15 types of statistical indexes are obtained to characterize the weld surface defects. Back-propagation artificial neural network method is used for defect classification. The influence of GLCM parameters , the neural network structure and the number and variety of input parameters on the defect classification performance is analyzed , and optimal neural network structure and input parameters are selected. In further , the optimized network is utilized for training and classifying the images of different weld defects acquired by industrial endoscope. The results show that weld defects detection rate of overall classification can be up to 91% . The proposed method can be used for automatic classification of weld surface defect in header pipe joint.

**Keywords:** weld; surface defect; texture features; grey level co-occurrence matrix; BP neural network

## 0 引 言

作为管式锅炉的主体部分,集箱的主要作用是保证锅炉工质混合及加热的均匀。集箱主要由大口径筒体、管件、耳板等焊接而成,而集箱筒体与管件间的焊接接头是集箱乃至整个锅炉的关键及薄弱环节。其既要承受管道内部介质的压力作用,也要受到温差引起的应力作用,因此,锅炉失效破坏往往出现在管接头的焊接区域<sup>[1]</sup>。在集箱制造过程中,密集排布的短管接头多采用自动焊

接完成。焊接中存在的因素,使得焊缝表面不可避免的会出现焊瘤、断焊、烧穿、焊偏等缺陷。这些缺陷极易造成锅炉停运等恶性事故。因此,集箱管接头焊接质量备受人们关注。为保证锅炉的安全运行,有必要开展集箱管接头焊接检测技术的研究。

常用的焊缝检测方法包括目视法和图像自动识别法。目视法检测效率低,受检测人员主观因素影响大。随着计算机图像技术的发展,图像自动识别法已广泛应用于多类焊缝缺陷检测中。国内外学者对焊缝图像缺陷表征方法及自动识别技术进行了广泛深入的研究。

收稿日期: 2016-08 Received Date: 2016-08

<sup>\*</sup> 基金项目: 国家重点研发计划( 2016YFF0203002 )、国家自然科学基金( 11572010 , 11772013 ) 项目资助

例如,梁硼等人<sup>[2]</sup>对 X 射线检测的焊缝图像处理方法进行了研究,采用 B 样条曲线拟合出焊缝的灰度曲线,利用数学形态学方法对缺陷的形状和大小进行了修正,从而提取出焊缝内部缺陷信息;Shao J. X. 等人<sup>[3]</sup>将缺陷追踪技术应用于焊缝 X 射线图像处理,并通过霍夫变换减少噪声产生的伪缺陷,提高了缺陷的识别率。基于焊缝图像的空间特性,孙怡等人<sup>[4]</sup>对焊缝模糊识别方法进行了研究;高炜欣等人<sup>[5]</sup>将主成分分析法应用于焊缝图像中缺陷识别中,通过分析疑似缺陷的局部图像自相关矩阵的特征值,将焊缝疑似缺陷的局部图像降维为一维特征参数表征,并基于提取出的几何特征,利用支持向量机(support vector machine, SVM)分类器实现了线形和圆形缺陷识别。基于对称交叉熵及背景与目标的面积差等特征,吴一全等人<sup>[6]</sup>研究了焊缝局部图像的阈值分割方法,实现了焊缝夹渣和烧穿缺陷的识别;Valavanis I 等人<sup>[7]</sup>对 X 射线检测焊缝图像的缺陷表征方法进行了研究,提出利用几何特征和纹理特征表征不同缺陷,并利用支持向量机对缺陷进行分类;Lashkia V<sup>[8]</sup>将模糊推理的方法应用于焊缝 X 射线图像中焊接内部缺陷的自动识别。基于提取的焊缝图像的几何特征参数, Jiang H 等人<sup>[9]</sup>利用信息融合技术对焊缝 X 射线图像中缺陷进行识别研究。除此之外,作为一种常用的智能识别技术,神经网络技术也广泛应用于焊缝缺陷自动识别。基于提取的不同特征参数,国内外学者将神经网络应用于焊缝缺陷自动识别<sup>[10-14]</sup>。例如, Zapata J 等人<sup>[10]</sup>对焊缝 X 射线检测图像进行了高斯低通滤波和维纳滤波预处理,基于提取出的不同缺陷的几何特征参数,将模糊神经网络用于焊缝缺陷识别;Wang G 等人<sup>[11]</sup>对焊缝 X 射线图像进行了消噪和直方阈值处理,利用焊缝图像的几何不变矩特性表征焊缝缺陷,并利用神经网络对焊缝缺陷进行分类;Vilar R 等人<sup>[12]</sup>利用大津法和标签技术对焊接缺陷图像进行分割和缺陷特征提取,并利用人工神经网络对缺陷进行分类;Lim T. Y. 等人<sup>[14]</sup>对常用于焊缝图像缺陷表征的几何特征参数进行了筛选,并利用多层感知机(multi-layer perceptron, MLP)神经网络对焊缝缺陷进行了分类。

目前,焊缝图像自动识别研究主要集中于利用 X 射线对焊缝内部缺陷的检测,对焊缝表面缺陷检测研究较少。而 X 射线检测费用较高,对角焊、T 型接头的检测敏感度低,且对人体有危害性。近年来,随着机器视觉技术的发展,基于 CCD 相机的视觉检测技术开始应用于焊缝的识别中。例如,丛焕武等人<sup>[15]</sup>通过对焊缝的 CCD 图像进行分析处理,实现了焊缝的识别与定位;Bhat N N 等人<sup>[16]</sup>对焊缝的表面图像进行直方均衡化处理,利用离散小波变换从焊缝图像中提取出其表面纹理特征,并将 SVM 应用于焊缝表面缺陷的自动识别。但目前还鲜见基于 CCD 计算机视觉的焊缝表面缺陷识别分类的研究。

针对集箱管接头内焊缝表面缺陷自动检测需要,本文对内窥镜采集到的焊缝图像的纹理特征进行了研究,提取出可用于焊缝表面缺陷表征的特征参数。建立了基于焊缝图像纹理特征的 BP 神经网络识别系统,研究了灰度共生矩阵的步长、灰度级、神经网络的结构参数及输入特征参数的数量和种类对焊缝焊接质量识别效果的影响,并将其应用于实际集箱管接头内焊缝表面缺陷的自动识别中。

## 1 基于图像纹理的焊缝表面缺陷表征方法

不同加工质量的焊缝其图像特征各不相同,而不同的图像特征对焊缝质量状态的表征能力也不尽相同,因此,选取合适的特征参数是缺陷自动识别的前提和关键。良好的图像特征应具有以下 4 个特点:1) 可区别性:对于属于不同类别的对象,其特征值应具有明显的差异;2) 可靠性:对于属于同类别的不同对象,其特征值应比较相近;3) 独立性:各特征参数之间彼此不相关;4) 数量少:选取的特征参数数目少,且分类错误概率小。

物体的纹理特性能够帮助人们区分图像间的形态差异。而图像的纹理是一种反映图像中同质现象的视觉特征,它代表了物体表面具有缓慢变化或者周期性变化的组织排列的属性。作为图像的一个重要特征,纹理特征已广泛应用于图像分析、检索、分类及模式识别等领域<sup>[17-20]</sup>。图 1 所示为焊接良好的焊缝和具有典型缺陷的焊缝图像。可以看出,不同焊接质量的焊缝具有不同的纹理特点。焊接质量良好的焊缝表面纹理较为均匀;而有缺陷焊缝的表面纹理变化不规则,较为杂乱,且不同类型缺陷的纹理特征也不尽相同。因此,可采用图像纹理的方法表征焊缝表面特征。常用的纹理提取方法有结构纹理法、模型分析法和统计分析法。作为一种典型的统计分析方法,基于灰度共生矩阵提取的纹理特征因具有较好的鉴别能力而得到广泛应用。本文将基于灰度共生矩阵的纹理特征提取方法应用于不同质量焊缝的表征。

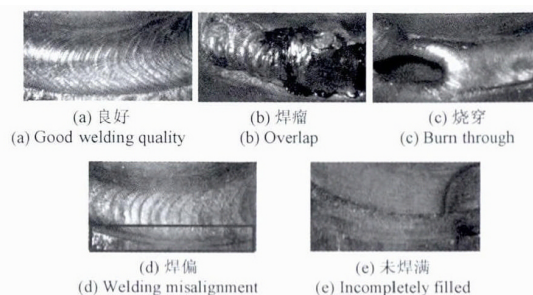


图 1 不同焊接质量效果

Fig. 1 Different welding pictures

由于纹理是由灰度分布在空间位置上反复出现而形成的,因而在图像空间中相隔某距离的两像素之间会存

在一定的灰度关系,即图像中灰度具有空间相关特性。灰度共生矩阵<sup>[21]</sup>就是一种通过研究灰度的空间相关特性来描述纹理的常用方法。

灰度共生矩阵主要描述在一定方向 $b$ 上,相隔一定距离的一对像素分别具有灰度值 $i$ 和 $j$ 的概率。图像中,任取一点 $(x, y)$ 和与其相距一定距离的点 $(x+a, y+b)$ ,用 $f(x, y)$ 表示灰度图像在像素点 $(x, y)$ 处的灰度值,像素点 $(x, y)$ 的灰度值为 $i$ ,像素点 $(x+a, y+b)$ 的灰度值为 $j$ ,则图像的灰度共生矩阵可表示为:

$$P(i, j, d, \theta) = \{ [(x, y), (x+a, y+b) | f(x, y) = i, f(x+a, y+b) = j] \} \quad (1)$$

式中:若图像大小为 $M \times N$ ,则 $1 \leq x \leq M, 1 \leq y \leq N$ ,且 $x, y$ 均为整数; $d$ 为生成步长,即两个像素点间的距离, $\theta$ 为生成方向,一般取 $0^\circ, 45^\circ, 90^\circ$ 和 $135^\circ$ 。因此, $a$ 和 $b$ 主要由生成步长以及生成方向共同决定。

特征提取的基本任务是从图像的众多特征中找出那些对分类识别最有效的特征,将图像从高维特征空间压缩到低维特征空间,并能反映图像的本质特征。针对焊缝图像特点,从焊缝图像的灰度共生矩阵中提取多种特征参数,研究不同特征参数对焊缝表面缺陷状态的表征能力。通常采用归一化的概率值表示灰度共生矩阵元素,即 $p(i, j) = p(i, j, d, \theta) / s$ ,其中, $s$ 为灰度共生矩阵中各元素之和。常用的基于灰度共生矩阵的图像特征参数有15种<sup>[18]</sup>。根据所表征属性的差异,可将这些特征参数分为4类:可视纹理特征参数、基于信息理论的图像特征参数、基于统计信息的特征参数和基于相关信息的特征参数。

#### 1) 可视纹理特征参数

可视纹理特征参数描述了图像的表面纹理结构特征。表1所示为5种常见的可视纹理特征参数及表达式,其中 $N_g$ 表示原图像的灰度级。其中,对比度用于图像纹理分布状况的表征;对比度越强烈,表示纹理效果越明显;同质性用于图像局部纹理变化的表征;相异性用于纹理间变化的表征;聚类阴影和显著聚类则用于图像纹理均匀性的表征。

表1 可视纹理特征参数

Table 1 Features of the visual texture

编号	特征描述	定义式
T1	对比度	$\sum_{i=1}^{N_g} \sum_{j=1}^{N_g} (i-j)^2 p(i, j)$
T2	同质性	$\sum_{i=1}^{N_g} \sum_{j=1}^{N_g} \frac{p(i, j)}{1 +  i-j }$
T3	相异性	$\sum_{i=1}^{N_g} \sum_{j=1}^{N_g}  i-j  \cdot p(i, j)$
T4	聚类阴影	$\sum_{i=1}^{N_g} \sum_{j=1}^{N_g} (i+j-u_i-u_j)^3 p(i, j)$
T5	显著聚类	$\sum_{i=1}^{N_g} \sum_{j=1}^{N_g} (i+j-u_i-u_j)^4 p(i, j)$

$$\text{注: } u_i = \sum_{j=1}^{N_g} i \cdot p(i, j) \quad u_j = \sum_{i=1}^{N_g} j \cdot p(i, j)$$

#### 2) 基于信息理论的图像特征参数

表2所示为2种常用的基于信息论的图像特征参数及表达式。包含熵与和熵两种特征参数主要用于图像内容随机性和图像纹理复杂性的表征。

表2 基于信息理论的图像特征参数

Table 2 Features based on information theory

编号	特征描述	定义式
T6	熵	$-\sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j) \log p(i, j)$
T7	和熵	$-\sum_{k=2}^{2N_g} P_X(k) \log [P_X(k)]$

$$\text{注: } P_X(k) = \sum_{i=1}^{N_g} \sum_{\substack{j=1 \\ |i+j|=k}}^{N_g} p(i, j) \quad k = 2, 3, \dots, 2N_g$$

#### 3) 基于统计信息的特征参数

表3所示为6种基于统计信息的特征参数及表达式。其中,均值和用于图像明暗变化的表征;方差、方差和用于图像纹理周期大小的表征。其值越大,表明纹理的周期越大;差的方差为相邻像素对灰度值差异的方差,主要用于纹理变化情况的表征;能量用于图像灰度分布均匀性及纹理粗细程度的表征。

表3 基于统计信息的特征参数

Table 3 Features based on statistical information

编号	特征描述	定义式
T8	方差	$\sum_{i=1}^{N_g} \sum_{j=1}^{N_g}  i-u  \cdot p(i, j)$
T9	差的方差	$\sum_{k=1}^{N_g-1} [k - \sum_{k=0}^{N_g} k \times P_Y(k)]^2 \times P_Y(k)$
T10	均值和	$\sum_{i=1}^{2N_g} k \times P_X(k)$
T11	方差和	$\sum_{k=2}^{2N_g} (k-T12)^2 P_X(k)$
T12	能量	$\sum_{i=1}^{N_g} \sum_{j=1}^{N_g} (p(i, j))^2$
T13	最大概率	$\max_{i, j} [p(i, j)]$

$$\text{注: } u \text{ 为各元素的均值, } P_Y(k) = \sum_{i=1}^{N_g} \sum_{\substack{j=1 \\ |i-j|=k}}^{N_g} p(i, j) \quad k = 0, 1, \dots, N_g-1$$

#### 4) 基于相关信息的特征参数

表4所示为2种基于相关信息的特征参数及表达式。相关和自相关两种特征参数包含有灰度共生矩阵中各元素在行或列方向上的相似程度信息,主要用于纹理主方向的表征。

利用上述提取的基于图像灰度共生矩阵的纹理特征参数,下面将进行焊缝表面缺陷的自动识别方法研究。

表 4 基于相关信息的特征参数  
Table 4 Features based on correlative information

编号	特征描述	定义式
T14	相关性	$\sum_{i=1}^{N_g} \sum_{j=1}^{N_g} \frac{(ij) p(i, j) - u_i u_j}{s_i s_j}$
T15	自相关	$\sum_{i=1}^{N_g} \sum_{j=1}^{N_g} (ij) p(i, j)$

注:  $s_i^2 = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j) (i - u_i)^2$ ,  $s_j^2 = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j) (j - u_j)^2$

## 2 基于 BP 神经网络的焊缝表面缺陷自动识别方法研究

在以上基于图像灰度共生矩阵的特征参数提取基础上, 还需要进行基于图像灰度共生矩阵的焊缝缺陷模式识别方法研究, 以达到焊缝缺陷自动识别的目的。作为一种重要的模式识别方法, 人工神经网络因具有记忆能力、学习能力和泛化能力强等特点, 而广泛应用于信号、文字、图像的自动辨识中。

### 2.1 BP 神经网络基本原理

BP 神经网络是一种利用误差反向传播训练算法的神经网络<sup>[22-24]</sup>, 它采用梯度搜索技术, 使网络的实际输出值与期望输出值的误差均方值最小。BP 神经网络的学习过程是一种误差边向后传播边修正权系数的过程, 是一种有监督的学习过程。BP 神经网络的优点在于, 只要隐含层和节点数足够多, 它可以逼近任意的非线性映射关系, 并且具有较好的泛化能力。典型的 BP 神经网络模型的拓扑结构包括输入层、隐含层和输出层(见图 2), 每层内包含若干个节点。




图 2 典型 BP 神经网络模型

Fig. 2 The typical structure of BP Neural Networks

对于输入的信息, 首先向前传播到隐含层, 经过激活函数作用后, 把隐含层的输出信息传播到输出层, 最后得到相应输出。其中, 节点的激活函数通常选取 Sigmoid 型函数, 其输出值在 0~1。以 3 层 BP 神经网络为例, 首先确定网络输入层节点数  $n$ 、隐含层结点数  $l$  和输出层结点数  $m$ 。假设输入层与隐含层、隐含层与输出层神经元

之间的连接权值分别为  $\omega_{ij}$  和  $\omega_{jk}$ , 隐含层阈值为  $a = [a_1, a_2, \dots, a_l]$ , 输出层阈值  $b = [b_1, b_2, \dots, b_m]$ 。则隐含层神经元输出可表示为:

$$h_j = f\left(\sum_{i=1}^n \omega_{ij} x_i - a_j\right) \quad (2)$$

式中:  $j = 1, 2, \dots, l$ 。  $f$  为隐含层激励函数,  $x_i$  为第  $i$  个输入节点变量。

输出层节点的输出为:

$$h_k = f\left(\sum_{j=1}^l h_j \omega_{jk} - b_k\right) \quad (3)$$

式中:  $k = 1, 2, \dots, m$ 。

在传播过程中, 输入信息从输入层经隐含单元逐层处理, 并传向输出层, 每一层神经元的输出只影响下一层神经元的输入。如果输出层不能得到期望的输出, 则进入反向传播, 反向传播通过误差反传算法, 对网络的权值与阈值进行学习修正。当网络的均方差小于给定值时, 即完成神经网络的学习过程。

### 2.2 基于 BP 神经网络的焊缝表面缺陷识别方法

针对焊缝表面缺陷自动识别需要, 建立了基于焊缝图像灰度共生矩阵的 BP 神经网络识别模型, 如图 3 所示。该神经网络的识别过程主要包括以下步骤: 1) 对训练图像进行处理, 提取出基于灰度共生矩阵的特征参数; 2) 确定 BP 神经网络的系统参数; 3) 利用训练样本提取的特征参数, 对 BP 神经网络进行训练; 4) 对识别样本进行处理, 提取其特征参数; 5) 利用训练好的神经网络对待识别样本的特征参数进行识别, 实现焊缝表面缺陷自动识别。

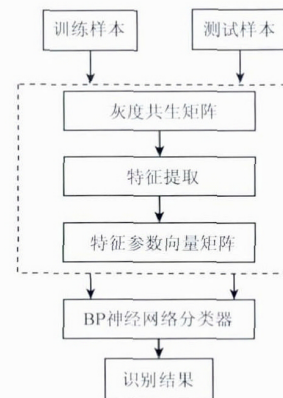


图 3 BP 神经网络焊缝表面缺陷识别流程

Fig. 3 The diagram of weld surface defect detection using BP neural networks

## 3 自动识别方法的影响因素研究

### 3.1 集箱管接头内焊缝表面缺陷识别系统

针对集箱管接头内焊缝检测特点, 建立集箱管内焊缝



视觉检测系统,如图4所示。该系统主要包括工业内窥镜、工业相机和便携式光源等。其中内窥镜采用卡尔斯托斯工业硬管镜,工业内窥镜外径为8 mm,视角为70°。




图4 视觉检测系统示意图

Fig. 4 The schematic diagram of visual inspection system

基于Labview软件平台,进行了集箱管接头内焊缝表面缺陷自动识别软件开发。软件操作界面如图5所示。该软件主要包括运动控制模块、图像采集模块和图像识别模块等。运动模块主要用于图像采集装置的运动控制,包括手动控制模式和自动控制模式两类;图像采集模块主要用于内窥镜参数设置、图像采集、显示和图像存储等功能;图像识别模块能够实现图像的识别分类和结果显示等功能。




图5 软件操作界面

Fig. 5 Software interface

### 3.2 BP神经网络模型建立

BP神经网络采用3层拓扑结构,隐含层与输出层的传递函数均选择对数S形。网络的初始化参数设置:训练次数 $k=10\ 000$ ,学习率 $\eta=0.01$ ,隐含层节点数为10。从每幅样本图像的4个方向分别提取出15种基于灰度共生矩阵的特征参数,每幅图片共获得60个特征参数,作为神经网络的输入。其中,生成灰度共生矩阵的构造因子初始设置:灰度级为8,生成步长为1。输出层分别用[1 0 0 0]、[0 1 0 0]、[0 0 1 0]、[0 0 0 1 0]和[0 0 0 0 1]5种节点状态表示焊缝表面良好、未焊满、

焊穿、焊偏和焊瘤。利用采集到的包含5种不同焊接质量的290幅图像作为样本库,其中每种焊接质量焊缝各有58幅图像。从每类焊接质量图像中随机选取50幅图像作为训练样本,对神经网络进行训练。利用训练好的神经网络对每类中剩余的8幅图像作为测试样本进行识别。

图6所示为神经网络的一个典型训练过程的均方误差变化情况。可以看出,随着迭代次数的增加,网络输出值和目标值间的均方误差逐渐变小。在第4 857次迭代时,输出值和目标值间的均方误差为0.009 99,小于设定值0.01,达到了设定的训练效果。




图6 BP神经网络的训练性能曲线

Fig. 6 The training performance curve of BP neural networks

基于以上方法,利用该神经网络系统对不同焊接质量的图像进行训练识别,20次测试结果如表5所示。从测试结果可以看出,基于图像灰度共生矩阵提取的15类特征参数,利用神经网络可以对不同焊接质量的焊缝进行识别,但其平均识别率较低,仅为78%。根据基于图像灰度共生矩阵的神经网络识别方法的原理可知,其识别效果受多种因素影响,如特征参数的构成方法、神经网络输入参数的种类及数量、神经网络结构参数等。

表5 BP神经网络测试结果

Table 5 The testing results the BP neural networks

训练样本数	测试样本数	最大识别率/%	最小识别率/%	平均识别率/%
250	40	85	65	78

### 3.3 BP神经网络输入参数影响因素研究

在特征参数提取过程中,灰度共生矩阵的步长、灰度级以及神经网络输入参数种类,影响着神经网络的识别效果,因此,下面对上述影响因素进行研究。

#### 3.3.1 生成步长

生成步长是影响灰度共生矩阵生成的一个重要参数,它确定了灰度共生矩阵中两个像素点间的距离,其大小决定了灰度共生矩阵所包含纹理信息的丰富程度。为

为了说明生成步长对灰度共生矩阵的影响,本文研究了从不同图像中提取的 15 种特征参数随生成步长的变化规律。受篇幅所限,图 7 以断焊图像样本为例,列出了生成步长对能量、对比度、相关性和同质性 4 种特征参数的影响。需要说明,为便于观察,图 7 中每类特征参数均进行了归一化处理。可以看出,生成步长对图像中不同纹理特征参数均有一定影响,但其影响规律不尽相同。因此,无法按照生成步长对某一图像的某一种特征参数的影响规律,确定最佳的生成步长。由于生成步长较大时,会有大量像素点不能参与灰度共生矩阵的生成,造成图像信息的丢失,因此,在本文研究中生成步长的范围选择为 1~10。

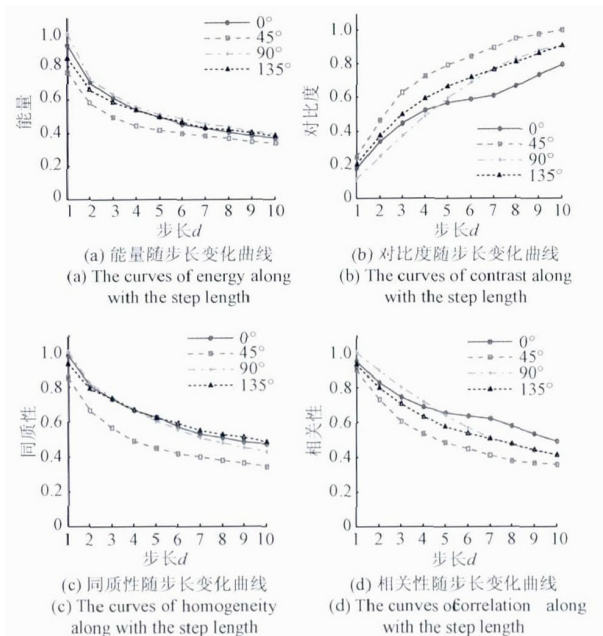


图 7 典型特征参数随生成步长变化曲线

Fig. 7 Graph of typical features curves

为了确定合适的生成步长,研究了生成步长对神经网络识别率的影响,典型结果如图 8 所示。在识别过程中保持其他参数与 3.2 节相同,仅研究生成步长对识别结果的影响。从 20 次识别结果可以看出,当生成步长为 4 时,神经网络的识别率最高且波动最小。因此,本文选取灰度共生矩阵的生成步长为 4。

### 3.3.2 灰度级

灰度级是影响灰度共生矩阵的另一个重要参数。灰度级的选择范围不仅会影响图像纹理的表征效果,而且直接关系灰度共生矩阵的运算量以及神经网络的迭代时间。在其他参数保持不变的情况下,研究了灰度级对神经网络识别率及运算时间(生成灰度共生矩阵的运算时间与网络训练时间之和)的影响,结果如图 9 所示。




图 8 生成步长对神经网络识别率的影响

Fig. 8 The performance measures for classifying with displacements




图 9 灰度级对网络识别率的影响

Fig. 9 The performance measures for classifying with gray level

由图 9 可以看出,灰度级对神经网络的识别率有一定影响,但影响不大,在一定范围波动;灰度级对运行时间有较大影响,总体而言,灰度级越高,运行时间越长。综合考虑,灰度级对识别率和运行时间的影响发现,当灰度级为 64 时,平均识别率最高且波动范围最小,运行时间适中。因此,后续分析中,将灰度级确定为 64。

### 3.3.3 神经网络输入参数

本节研究神经网络输入参数的类型及数量对神经网络识别率的影响<sup>[25]</sup>。分别将单一特征参数作为 BP 神经网络的输入,对不同焊缝质量的焊缝图像进行识别。图 10 所示为各单一特征参数输入情况下,神经网络的识别率分布。




图 10 不同特征参数对网络识别率的影响

Fig. 10 The performance measures for classifying with different features

由图 10 可以看出,不同单个特征参数下神经网络的平均识别率差别较大,通常分布在 20%~70%。平均识别率在 50% 以下的特征参数包括方差、差的方差、均值和、和熵、自相关、聚类阴影和显著聚类;平均识别率在 50%~60% 的特征参数包括能量、同质性和最大概率;平均识别率在 60% 以上的特征参数包括对比度、相关性、熵、相异性和方差和。

分别选取识别率在 50% 以上的特征参数(组合 1)、60% 以上特征参数的特征参数(组合 2)及全部的特征参数(组合 3),作为 BP 神经网络的输入特征矩阵,在其他参数设置与前相同的情况下,在 3 种组合输入参数下,利用神经网络对不同焊接质量的图像进行识别,结果如表 6 所示。

表 6 不同特征参数组合的 BP 神经网络识别结果

Table 6 The identification performance of BP neural networks with different features' combination

特征组合	特征参数 数量	平均 识别率/%	识别的 标准差	平均运行 时间/s
组合 1	8	89.50	2.08	40.9
组合 2	5	79.13	4.39	105
组合 3	15	89.38	3.02	60.8

分析表 6 可知,不同特征参数组合对神经网络的识别率及运行时间有较大的影响。其中,组合 1 和组合 3 下,神经网络的平均识别率较高,均能达到 89%。但组合 1 下,神经网络识别率的稳定性及运算速度均优于组合 3。因此,在本文后续研究中,利用识别率在 50% 以上的 8 种特征参数组合(组合 1)作为神经网络输入参数。

### 3.4 神经网络结构参数影响因素研究

由 3.1 节中式(2)和(3)可知,神经网络的输出与隐含层节点数和隐含层层数有关。在隐含层数确定的情况下,本节将研究隐含层节点数对神经网络的识别效果及效率影响。

若隐含层所包含的节点数量过少,神经网络所能获取的信息过少,会导致网络欠拟合,使得识别效果较差;若隐含层所包含的节点数量过多,不仅训练时间增加,还可能会出现“过拟合”的现象,即因误差增大而导致神经网络的泛化能力下降,也会影响神经网络的识别效果<sup>[26]</sup>。因此,合理选择隐含层节点的数量非常重要。隐含层节点数确定的一般原则为在能正确反映输入输出关系的基础上,应选用较少的隐含层节点数,以使网络结构尽量简单。对于包括一个单隐含层的 3 层 BP 神经网络,可根据经验公式选择隐含层节点数:

$$s = \sqrt{nm} + a \quad (4)$$

式中:  $n$  为输入节点个数,  $m$  为输出节点个数,  $a$  在 0~10 的常数。

按照 3.3 节组合 1 下的特征参数作为 BP 神经网络输入,输入节点的数量为 32,网络输出节点数为 5,按照式(4)可计算出隐含层节点数应在 12~22 选择。在其他参数确定的情况下,研究隐含层节点数对神经网络识别率以及输出误差的影响,结果如图 11 所示。




图 11 隐含层节点数对神经网络识别率和输出误差的影响

Fig. 11 The performance measures for classifying and output error of neural network with different hidden layer nodes

从图 11 中可以看出,隐含层节点数对神经网络的识别率和输出误差均有一定影响,但其影响趋势差别较大。平均识别率随隐含层节点数增加呈先增大后减小的波动状态,且当隐含层节点数较大时,识别率的分散性增加;均方根误差受隐含层节点数的变化影响较大,整体而言,随着隐含层节点数的增加,均方根误差呈增加趋势。对比可以发现,当隐含层节点数为 16 时,神经网络的平均识别率较高、波动较小,且均方根误差较小。因此,本文中神经网络隐含层节点个数选择为 16。

### 3.5 自动识别方法的应用

通过上节研究,确定了基于图像纹理特征的 BP 神经网络的最佳输入及结构参数,本节将进一步将其应用于集箱管接头内焊缝表面缺陷的自动识别中。将包含不同焊接质量的 250 幅图像作为训练样本,对优化后的神经网络模型进行训练,并利用训练好的网络对 200 幅不同焊接质量的图像进行识别,表 7 所示为 BP 神经网络识别结果的统计信息。

表 7 BP 神经网络识别结果

Table 7 The identification results of BP Neural Networks

焊接 质量	训练 样本数	测试 样本数	测试 出错数	分类 正确率/%
良好	50	40	1	97.5
未焊满	50	40	1	97.5
焊穿	50	40	3	92.5
焊偏	50	40	8	80
焊瘤	50	40	5	87.5
平均识别率/%			91	



从上述识别结果可知,基于图像纹理特征的 BP 神经网络系统可以有效实现不同焊接质量焊缝图像识别,整体识别率较高,可达 91%。进一步分析发现,该方法对不同缺陷类型焊缝识别率存在一定差别,其中,对良好和未焊满的焊缝识别率最高,可达 97.5%,对焊穿的识别率为 92.5%,对焊偏与焊瘤的识别率在 90% 以下。后续,需要进一步开展对带有焊偏和焊瘤的焊缝图像进行分析,提取更有效的表征参数,提高对其的识别率。

## 4 结 论

针对集箱管接头内焊缝表面质量评价的需求,本文进行了焊缝表面缺陷自动识别方法的研究,取得了以下结论:

1) 分析了不同焊接质量的焊缝图像的纹理特征,以整体识别率为评价标准,优选出了可用于焊缝缺陷表征的 8 种表征参数,即能量、对比度、相关性、熵、同质性、最大概率、和方差和相异性;

2) 研究了灰度共生矩阵的构造因子(步长、灰度级)以及神经网络构造参数(隐含层节点数)对焊缝表面缺陷识别效果的影响,优化出灰度共生矩阵构造及神经网络的输入与结构参数;

3) 利用优化后的神经网络,对包含焊缝表面良好、未焊满、焊穿、焊偏和焊瘤的测试样本图像进行识别,结果表明,基于图像纹理特征的 BP 神经网络系统可以有效实现不同焊接质量焊缝图像识别,识别率较高。

本文的研究工作为集箱管接头内焊缝焊接质量检测做了有益的探索。

## 参考文献

- [1] DAGA R, BANDYOPADHYAY G, SAMAL M K, et al. Consumed creep life fraction assessment of critical locations of an in-service super heater outlet header under surveillance programme [J]. Transactions of the Indian Institute of Metals, 2010, 63(2-3): 423-429.
- [2] 梁硼,魏艳红,占小红. 基于 B 样条曲线的 X 射线图像焊缝缺陷分割与提取[J]. 焊接学报, 2012, 33(7): 109-112.  
LIANG P, WEI Y, ZHAN X H, et al. Weld defect segmentation and extraction of X-ray image based on B-spline curve [J]. Transactions of the China Welding Institution, 2012, 33(7): 109-112.
- [3] SHAO J X, DU D, CHANG B, et al. Automatic weld defect detection based on potential defect tracking in real-time radiographic image sequence [J]. NDT & E International, 2012, 46(1): 14-21.
- [4] 孙怡,孙洪雨,白鹏,等. X 射线焊缝图像中缺陷的实时检测方法[J]. 焊接学报, 2004, 25(2): 115-118.  
SUN Y, SUN H Y, BAI P, et al. Real-time automatic detection of weld defects in X-ray images [J]. Transactions of the China Welding Institution, 2004, 25(2): 115-118.
- [5] 高炜欣,胡玉衡,武晓朦,等. 埋弧焊 X 射线焊缝缺陷图像分类算法研究[J]. 仪器仪表报, 2016, 37(3): 518-524.  
GAO W X, HU Y H, WU X M, et al. Sub-arc X-ray welding defect image classifying algorithm [J]. Chinese Journal of Scientific Instrument, 2016, 37(3): 518-524.
- [6] 吴一全,沈毅,刚铁,等. 基于二维对称 Tsallis 交叉熵的小目标图像阈值分割[J]. 仪器仪表学报, 2011, 32(10): 2161-2167.  
WU Y Q, SHEN Y, GANG T, et al. Thresholding for small target image based on 2-D symmetric Tsallis cross entropy [J]. Chinese Journal of Scientific Instrument, 2011, 32(10): 2161-2167.
- [7] VALAVANIS I, KOTSIPOPOULOS D. Multiclass defect detection and classification in weld radiographic images using geometric and texture features [J]. Expert Systems with Applications, 2010, 37(12): 7606-7614.
- [8] LASHKIA V. Defect detection in X-ray images using fuzzy reasoning [J]. Image and Vision Computing, 2001, 19(5): 261-269.
- [9] JIANG H, LIANG Z, GAO J. Classification of weld defect based on information fusion technology for radiographic testing system [J]. Review of Scientific Instruments, 2016, 87(3): 55-62.
- [10] ZAPATA J, VILAR R, RUIZ R. Performance evaluation of an automatic inspection system of weld defects in radiographic images based on neuro-classifiers [J]. Expert Systems with Applications, 2011, 38(7): 8812-8824.
- [11] WANG G, LIAO T W. Automatic identification of different types of welding defects in Radiographic images [J]. NDT & E International, 2002, 35(8): 519-528.
- [12] VILAR R, ZAPATA J, RUIZ R. An automatic system of classification of weld defects in radiographic images [J]. NDT & E International, 2009, 42(5): 467-476.
- [13] 余永维,殷国富,殷鹰,等. 基于深度学习网络的射线图像缺陷识别方法[J]. 仪器仪表学报, 2014, 35(9): 2012-2019.  
YU Y W, YIN G F, YIN Y, et al. Defect recognition for radiographic image based on deep learning network [J]. Chinese Journal of Scientific Instrument, 2014, 35(9): 2012-2019.
- [14] LIM T Y, RATNAM M, KHALID M. Automatic classification of weld defects using simulated data and an MLP neural network [J]. Insight, 2007, 49(3): 154-159.



- (6).
- [15] 丛焕武,郭福娟,吕飞,等. 基于 CCD 图像处理的焊缝识别技术研究[J]. 电子测量技术, 2012, 35(3): 73-77.  
CHONG H W, GUO F J, LV F, et al. Research on weld seam recognition technology based on CCD image processing[J]. Electronic Measurement Technology, 2012, 35(3): 73-77.
- [16] BHAT N N, KUMARI K, DUTTA S. Friction stir weld classification by applying wavelet analysis and support vector machine on weld surface images [J]. Journal of Manufacturing Processes, 2015, 20(7): 274-281.
- [17] 曹家梓,宋爱国. 基于马尔科夫随机场的纹理图像分割方法研究[J]. 仪器仪表学报, 2015, 36(4): 776-786.  
CAO J X, SONG AI G. Research on the texture image segmentation method based on Markov random field [J]. Chinese Journal of Scientific Instrument, 2015, 36(4): 776-786.
- [18] SOH L K, TSATSOU LIS C. Texture analysis of SAR sea ice imagery using gray level co-occurrence matrices [J]. IEEE Transactions on Geoscience & Remote Sensing, 1999, 37(2): 780-795.
- [19] 苑玮琦,李绍丽,李德健. 基于纹理脊线特征融合的木材表面裂缝线[J]. 仪器仪表学报, 2017, 38(2): 436-444.  
YUAN W Q, LI SH L, LI D J, et al. Wood surface crevice detection based on fusion of texture ridge line features [J]. Chinese Journal of Scientific Instrument, 2017, 38(2): 436-444.
- [20] 詹曙,胡德凤,蒋建国,等. 结合 GLWT 和 LBP 提取纹理特征的图像分割[J]. 电子测量与仪器学报, 2014, 28(2): 198-202.  
ZHAN SH, HU D F, JIANG J G, et al. Combined with GLWT and LBP extract texture features for image segmentation [J]. Journal of Electronic Measurement and Instrumentation, 2014, 28(2): 198-202.
- [21] BARALDI A, PARMIGIANINO F. Investigation of the textural characteristics associated with gray level co-occurrence matrix statistical parameters [J]. IEEE Transactions on Geoscience & Remote Sensing, 1995, 33(2): 293-304.
- [22] 黄良沛,吴超威,王靖. 小波包分析和 BP 神经网络在滚动轴承故障模式识别中的应用[J]. 电子测量技术, 2016, 39(4): 164-168.  
HUANG L P, WU CH W, WANG J, et al. Fault pattern recognition of rolling bearing using wavelet package analysis and BP neural network [J]. Electronic Measurement Technology 2016, 39(4): 164-168.
- [23] 王文靖,梁旭,温菲菲. 无人机机载发电机故障诊断技术研究[J]. 国外电子测量技术, 2016, 35(8): 94-98.  
WANG W J, LIANG X, WEN F F, et al. Research on fault diagnosis technology for UAV airborne generator [J]. Foreign Electronic Measurement Technology, 2016, 35(8): 94-98.
- [24] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning internal representations by error propagation [J]. Readings in Cognitive Science, 1988, 1(2): 399-421.
- [25] 王治国,尹成,雷小兰,等. 河道纹理属性分析中的灰度共生矩阵参数研究[J]. 石油地球物理勘探, 2012, 47(1): 100-106.  
WANG ZH G, YIN CH, LEI X L, et al. GLCM parameters in fluvial texture analysis [J]. Oil Geophysical Prospecting, 2012, 47(1): 100-106.
- [26] 焦敬品,李勇强,吴斌,等. 基于 BP 神经网络的管道泄漏声信号识别方法研究[J]. 仪器仪表学报, 2016, 37(11): 2588-2596.  
JIAO J P, LI Y Q, WU B, et al. Research on acoustic signal recognition method for pipeline leakage with BP neural network. Chinese Journal of Scientific Instrument, 2016, 37(11): 2588-2596.

#### 作者简介



焦敬品(通讯作者),分别在1995年和1998年于燕山大学获得学士和硕士学位,2005年于北京工业大学获得博士学位,现为北京工业大学教授、博士生导师,主要研究方向为现代测控技术与方法、无损检测新技术、现代信号分析与处理技术、新型传感器技术。

E-mail: jiaojp@bjut.edu.cn

**Jiao Jingpin** (Corresponding author) received her B. Sc. and M. Sc. degrees both from YanShan University in 1995 and 1998, respectively, and received her Ph. D. degree from Beijing University of Technology in 2005. Now she is a professor and doctoral supervisor in Beijing University of Technology. Her research interests include modern control & measurement technology and methods, new technology of nondestructive testing, modern signal analysis and processing technology, and advanced sensor technology.



李思源,2014年于燕山大学获得学士学位,2017年于北京工业大学获得硕士学位,现为清华大学博士研究生,主要研究方向为现代测控技术与方法。

E-mail: lisiyuan101@126.com

**Li Siyuan** received his B. Sc. degree from YanShan University in 2014, and received his M. Sc. degree from Beijing University of Technology in 2017. Now he is a Ph. D. candidate in Tsinghua University. His main research interest is modern control & measurement technology and methods.