

计算机集成制造系统
Computer Integrated Manufacturing Systems
ISSN 1006-5911, CN 11-5946/TP

《计算机集成制造系统》网络首发论文

题目: 基于融入注意力机制的改进 U-Net 鲁棒焊缝识别算法
作者: 周思羽, 刘帅师, 杨宏韬, 宋宜虎
收稿日期: 2022-07-01
网络首发日期: 2023-01-04
引用格式: 周思羽, 刘帅师, 杨宏韬, 宋宜虎. 基于融入注意力机制的改进 U-Net 鲁棒焊缝识别算法[J/OL]. 计算机集成制造系统.
<https://kns.cnki.net/kcms/detail//11.5946.TP.20230104.1212.011.html>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于融入注意力机制的改进 U-Net 鲁棒焊缝识别算法

周思羽, 刘帅师⁺, 杨宏韬, 宋宜虎

(长春工业大学 电气与工程学院, 吉林 长春 130012)

摘 要: 本文针对复杂焊接环境下大量弧光噪声造成焊缝激光条纹分割精度低的问题, 提出了一种融入注意力机制的改进 U-Net 鲁棒焊缝识别算法。首先, 在模型的特征融合过程中使用超强通道注意力机制实现特征的加权融合。然后, 在编码器结构之后, 加入特征分类结构, 使其可以输出焊缝对应类型名称。最后, 由于网络训练中正负样本失衡会对识别结果产生影响, 在模型的损失函数中添加 Dice Loss 和 Focal Loss 来加以修正以提高模型的鲁棒性和泛化性。另外, 本文在模型训练的过程中提出了一种像素位置信息和图像种类信息融合的方式, 以此增强焊缝识别的鲁棒性。实验表明, 在具有弧光、烟雾噪声等干扰环境下, 本文所提出的方法得到了较好的实验结果, 能够满足检测对精度和实时性的需求, 在具有弧光、烟雾等干扰的实际焊接现场中具有一定的应用前景。

关键词: 焊缝识别; 图像分割; 注意力机制; U-Net; 鲁棒性

中图分类号: TP242.2

文献标识码: A

Improved U-Net Robust Weld Seam Recognition Algorithm Based on Integrating Attention Mechanism

ZHOU Siyu, LIU Shuaishi⁺, YANG Hongtao, SONG Yihu

(College of Electrical and Electronic Engineering, Changchun University of Technology, Changchun 130012, China)

Abstract: To address the issue of low accuracy in laser streak segmentation of weld seams caused by substantial arc noise in complex welding environments, an enhanced U-Net robust weld seam-recognition algorithm incorporating an attention mechanism is proposed. Firstly, The ECA-Net is utilized in the feature-fusion process to achieve a weighted fusion of features. Subsequently, a feature-classification structure is supplemented after the encoder structure such that it can output the name of the corresponding type of weld. Finally, since the imbalance between positive and negative samples in the network training will affect the recognition results, Dice-Loss and Focal-Loss are supplemented to the loss function to enhance the robustness and generalization of the model. Additionally, a method of fusing pixel-position and image-type information is proposed to enhance the robustness of weld recognition. The experiments demonstrated that the method obtained favourable experimental results in an environment with interferences such as arc-light, smoke and noise. Therefore, it can satisfy the demand for accuracy and

收稿日期: 2022-07-01; 修订日期: 2022-09-13。Received 01 July 2022; accepted 13 Sep. 2022.

基金项目: 国家自然科学基金资助项目(62106023); 吉林省科技厅资助项目(20200703016ZP)。

Foundation items: Project supported by the National Natural Science Foundation, China(No.62106023), and the Jilin Provincial Science and Technology Department, China(No. 20200703016ZP).

real-time detection which possess certain application prospects in the actual welding site with arc-light and smoke interferences.

Keywords: weld recognition; image segmentation; attention mechanism; U-Net; robustness

0 引言

随着现代制造业的发展,智能焊接机器人是现代焊接制造中不可缺少的组成部分,实现智能焊接机器人的自动化、灵活性、自适应性、高效性是智能焊接的必然趋势^[1]。视觉信息因其方便直观、信息量大、易于处理等优点,是焊缝识别技术中的研究热点和重点。焊缝识别具有检测时间短、检测精度高、结果可靠的特点,但由于焊接环境条件恶劣,焊件表面不均匀,焊接过程中存在飞溅、电弧光、烟尘、重叠反射等干扰因素,大多数焊缝图像识别算法在焊接实践中都缺乏自适应性、泛化性和鲁棒性,于是如何将焊缝位置信息从背景中分割出来,已然成为图像处理过程中的关键步骤。

目前,对于焊缝激光条纹的识别,学者们提出了很多图像处理方法用于获得的焊缝条纹的有效特征。邹媛媛等^[2]使用Laws纹理滤波来获得焊缝区域,之后利用阈值分割方法进行图像分割。He等^[3]提出了一种能精确获得目标焊接区的区域增长图像处理方法。Zhang等^[4]提出了一种用于小孔深熔钨惰性气体焊接(TIG)焊缝跟踪的窄缝识别算法,利用了轮廓曲率评价方法获得相应的像素坐标。图像处理方法虽然在识别精度上可以达到亚像素精度级别,但是算法对复杂且恶劣的焊接环境的自适应能力较差。这对焊缝识别算法带来了许多挑战,因此,要实现焊缝特征的鲁棒提取,算法就必须具备较强的自学习能力以及可以实现多种特征的融合。

近年来,随着深度学习和人工智能的快速发展,国内外学者逐渐采用各种神经网络算法来识别焊缝类型和提取焊缝特征信息。张永帅等^[5]使用全卷积神经网络提取焊缝条纹的像素位置信息。Yu等^[6]提出了一种基于PSP-Net和Steger算法的焊缝结构光条中心线提取方法,该方法对简单环境下的焊缝图像能够快速分割,但在复杂环境下抗干扰能力不高。Cheng等^[7]利用卷积神经网络(CNN)模型处理焊接池的图像,监测焊缝的穿透状态。唐溪等^[8]提出一种基于改进CenterNet的焊缝起始向量检测与机器人位姿估计方法,采用特征融合与卷积块注意力机制(CBAM)增强CenterNet提取有效特征的能力。Xiao等^[9]训练一种Faster R-CNN模型来识别焊缝类型,并自动定位焊缝条纹ROI。以上深度学习方法相较于图像处理方法在特征提取能力上大大提升的同时,用时也都有明显缩短,但在具有强噪声干扰和焊缝条纹部分被遮挡的情况下,分割精度有待增强。

U-Net 作为经典的深度学习模型,其优点在于针对小型数据集也能进行端到端的快速有效训练。张世宽等^[10]构建了以 U-Net 作为语义分割分支与以 YOLO-V3 作为目标检测分支相结合的网络模型,

将其用于复杂环境强噪声干扰下的焊缝图像的检测。闫文伟等^[11]提出一种改进 U-Net 网络，使用金字塔池化模块并融入坐标注意力，实现激光条纹的精确分割。李可等^[12]针对经典 U-Net 网络特征提取能力不足、泛化性较差的问题，引入 Mobile-Net 作为 U-Net 的主干特征提取网络，提高网络获取焊点形状和位置信息的能力。U-Net 模型虽然可以快速识别简单环境下的焊缝，但是对于边缘模糊且带有遮挡的焊缝识别并不理想，存在漏检、误检等问题，而且分割结果精度较低。

由于实际焊接环境中存在着复杂的噪声干扰，导致焊缝识别的准确率较低，本文提出了一种融入注意力机制的改进U-Net焊缝识别鲁棒性算法。并提出一种新的图像特征信息融合的方式，将像素位置信息和图像种类信息融合，对网络模型进行训练。网络模型需要融合深浅层特征和多尺度特征，在特征融合过程中使用超强通道注意力模块ECA-Net^[13](Efficient Channel Attention for Deep Convolutional Neural Networks)实现特征的加权融合，增强网络的泛化能力，从而突出有效特征、抑制无效特征，以提高焊缝识别的自适应性、泛化性和模型鲁棒性。在网络模型中的特征提取模块后，加入特征分类模块，实现对焊缝类型的检测，在得到焊缝识别结果的同时获取焊缝类型名称。另外，针对焊缝激光条纹和干扰背景像素所占比例不均匀造成的不良影响，为了提高模型抗干扰能力，本文将Dice Loss和Focal Loss引入原有的损失函数，从而提高了模型的识别精度。

1 自动焊接系统平台

1.1 系统构成

本文中的自动焊接平台主要由视觉成像系统、运动执行系统和焊接执行系统三部分组成，如图 1 所示。

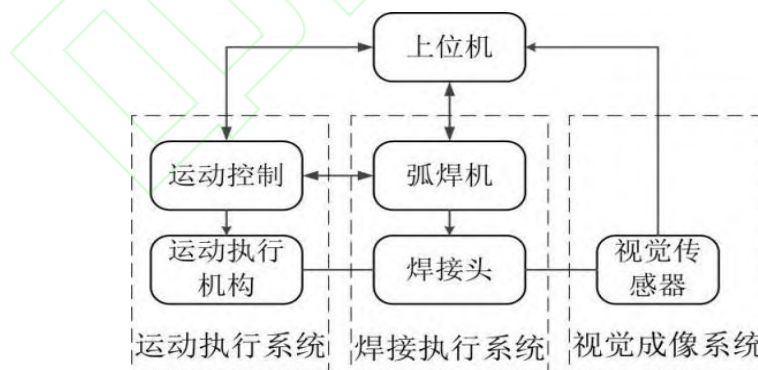


图 1 自动焊接系统平台总体框图

1.1.1 视觉成像传感器


视觉成像系统的核心部分是激光焊缝跟踪传感器，它的作用是采集待焊接工件的图像信息，并将图像传输至上位机进行焊缝图像处理。综合以上所需功能，选用苏州博智慧达激光科技有限公司生产的型号为 HD8-0050W 激光焊缝跟踪传感器如图 2(a)所示。

1.1.2 运动执行机构

焊接执行机构采用上海发那科机器人有限公司 LR Mate 200iD 六自由度机器人作为焊接机器人的执行机构，LR Mate 200iD 是一款大小和人的手臂相近的迷你机器人如图 2(b)所示。该机械手采用高刚性臂和最先进的伺服控制技术，实现了高速平稳的运动性能，并具有腕部承载能力大的特点。

1.1.3 焊接执行机构

弧焊机采用高压击穿的起弧方式，具有焊缝质量高、焊接应力与形变小、可焊接母材范围广、操作技术易掌握、辅助机具可以实现自动化生产、设备易维护等优点。综合上述因素，选用山东奥太电气有限公司生产的型号为 NBC-200i 逆变式多功能弧焊机如图 2(c)所示。



(a)HD8-0050W 焊缝跟踪传感器 (b) LR Mate 200iD 机器人 (c) NBC-200i 多功能弧焊机

图 2 自动焊接平台硬件选型

1.2 自动焊接平台

根据自动焊接平台的结构设计，将视觉成像传感器、运动执行机构和焊接执行机构安装并调试于自动焊接平台机柜上。视觉成像传感器和焊接头安装在机械臂最前端并进行加固，当机械臂运动时就跟随着紧固在自动焊接平台机柜上的机械臂共同运动。由于弧焊机在焊接过程中需要保护气体，所以要配置CO₂气瓶与焊机连接，为弧焊机提供保护气体，搭建的焊接平台实物如图 3 所示。




图 3 自动焊接平台

2 图像采集与焊缝类型

2.1 图像采集

本节利用视觉成像系统中的HD8-0050W激光焊缝跟踪传感器，采集实际焊接过程中的焊缝图像。将待焊接的金属焊件放置在激光焊缝跟踪传感器正下方，传感器发出红色的线激光，采样频率为 50Hz,可以检测宽度为 0-50mm的焊缝,高度方向分辨率为 0.003mm,宽度方向分辨率为 0.005mm,图像的分辨率为[1024×1024]。采集到带有噪声、飞溅和烟雾干扰的原始焊缝图像，示例如图 4(a)所示。为了降低网络模型训练的硬件资源成本和时间成本，我们将采集到的原始图像进行归一化处理，首先将图像的分辨率大小调整为[320×320]，其次调整图片位深度，将RGB图像调整至灰度图像。然后使用Label-Me图像标注工具对图像进行分类标记，需要提取的焊缝标注为红色，干扰背景标注为黑色，其中焊缝目标对应的视觉RGB值为(128,0,0)，背景对应的RGB值为(0,0,0)，示例如图 4(b)所示。最后对所有原始图片及其标签进行 90°、180°、270°旋转和左、右翻转操作，进行数据集扩充，最终得到 1100 张图片，将其中的 70%作为训练集，20%作为验证集，10%作为测试集。



(a)采集到的原始图片 (b) 标注图

图 4 原始图像与标注图像

2.2 焊缝类型

根据焊缝激光条纹图像，将典型的焊缝分为两类^[13]。一种是连续型焊缝，其激光条纹图像由多条线段连接组成，如角接焊缝、V型焊缝等，如图 5(a)(b)所示。另一种是不连续型焊缝，其图像中的激光条纹在焊缝边缘断裂，如对接焊缝、搭接焊缝如图 5(c)(d)所示。

不同类型的焊缝需要识别出不同的特征，连续型焊缝的中心是条纹线的交点，而不连续型焊缝的中心是两个不连续焊点的中点。因此本文所提出的网络模型在得到识别后的焊缝图像的同时也需要对其类型进行判断。为了增强焊缝识别的鲁棒性，本文采用一种新的图像特征信息融合的方式，进行网络模型的训练。在对图像数据增强的过程中，训练图片不止被标注了焊缝的位置信息，同时也携带着焊缝自身的类型信息。不同类型的焊缝对应的焊缝特征也不尽相同，如连续型焊缝需对条纹交点进行重点关注，而不连续焊缝则需要条纹线段的端点进行重点捕捉。网络训练的过程中，由

于位置信息和种类信息的融合，可以把不同种类的焊缝位置特征信息赋予不同的权重，以此来增强焊缝识别的鲁棒性。




图5 连续焊缝与不连续焊缝

3 基于融入注意力机制的改进 U-Net 的鲁棒性焊缝识别

3.1 基于改进 U-Net 的主干焊缝特征提取网络模型

U-Net^[14]是由Ronneberger等于2015年提出的一种深度学习语义分割模型，其本质是一个框架，主要由编码器和解码器构成。本文中使用的骨干特征提取网络模型是基于U-Net加以改进，使用VGG16网络的特征提取结构代替原有的编码器，以增强网络识别性能和提高网络的泛化性，实现焊缝条纹精准识别，改进后的U-Net网络架构如图6所示，左侧为编码器，右侧为解码器。改进后的编码器的结构对原有模型进行加深，卷积层通过对图像的空间特征进行提取，池化层的作用则是扩大模型的感知范围，使其能够得到更多的全局信息。在每次下采样之后，卷积层中的滤波器是上一层的两倍，最后再利用3×3卷积层连接编码器和解码器。解码器是上采样的过程，使用2×2转置卷积的同时将特征通道缩小为一半，最后通过一个1×1卷积层后输出图像识别结果。编-解码器间的跳跃连接，将编码器中下采样和解码器中上采样获得的不同特征进行拼接，并将融合的特征图传到后续的采样过程，可以尽量多的保留图像细节，提高最终分割结果的分辨率和边缘准确率。

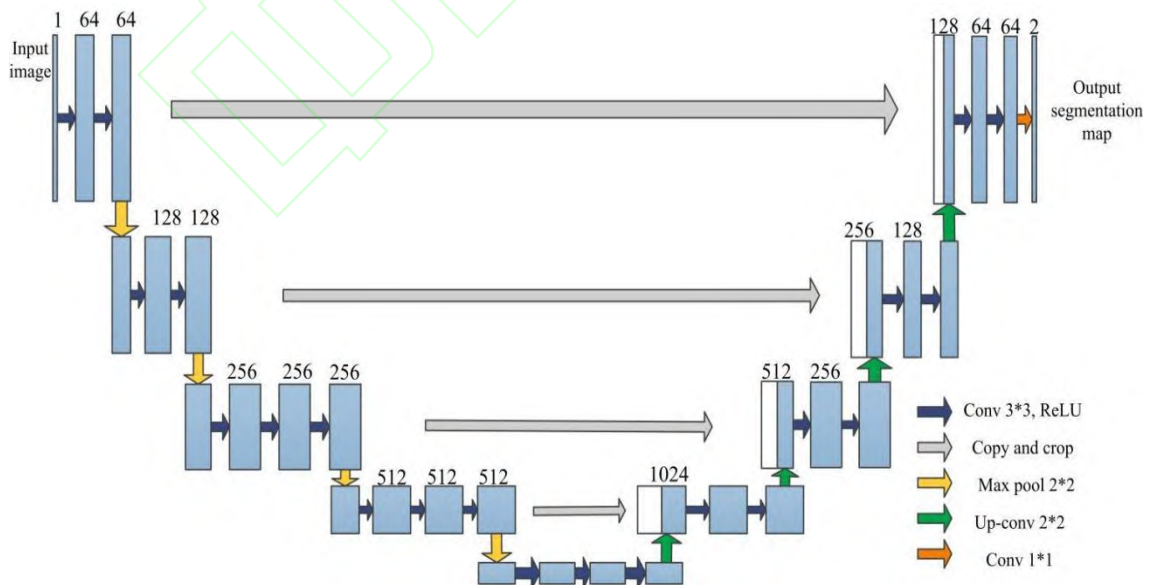


图6 改进U-Net的网络结构

3.2 超强通道注意力机制(ECA-Net)

现有研究表明,将注意力模块添加到现有卷积神经网络中可以带来显著的性能飞跃^[15]。图像中每个通道代表的特征信息重要程度不同,相同通道上不同位置处像素特征信息的重要程度也不同。然而,大多注意力机制为了提升模块性能,引入了更多的变量和计算方式,使得模型复杂程度增加。

ECA-Net是基于SE-Net^[16]进行改进而提出的一种新型超强通道注意力机制,大范围缩小了计算量,实现速度和性能上的优化,其模块结构如图 7 所示。ECA-Net给出了一种不会降低维度的局部跨通道交互策略,以及提出了一维卷积核的自适应选取算法。采用该方法选取的一维卷积核具有非完全连接的特点,一维卷积核只与部分通道进行卷积,这可以实现适当的跨通道交互,而不是像全连接层一样全通道交互。




图 7 ECA-Net注意力机制结构

ECA-Net去除了原来SE模块中的FC层(Fully Connected layer),直接使用全局平均池化(Global Average Pooling)从二维矩阵中压缩和提取输入特征映射 $\chi \in R^{(W \times H \times C)}$ 为一个实值,得到特征 $\chi_{avg} \in R^{(W \times H \times C)}$, C为通道维度,如公式(1)所示。

$$\chi_{avg} = GPA(\chi) = \frac{1}{W \times H} \sum_{i=1}^{W \times H} \chi_{ij} \quad (1)$$

其中: $\chi_{ij} \in R^{(C)}$ 是 χ 在 (i, j) 处的全通道特征,经过全局平均池化后,获取图像的所有特征。

另外,利用尺寸为K的一维卷积,实现了跨信道间的局部交互,卷积核K的大小代表了跨信道间的交互作用的范围,可以根据输入通道C的尺寸,由自适应功能计算出参数K的大小,如公式(2)所示。

$$K = \frac{\log_2 C + 1}{2} \quad (2)$$

ECA-Net使用Sigmoid函数计算一维卷积输出的激活值,得到表示不同通道的特征重要程度的权值 $W \in R(1 \times 1 \times C)$ 。最后,将每个通道 W 生成的权值乘法加权到原始输入特征 χ 上,完成 χ 每个通道特征的权重更新,根据特征的重要程度来分配不同的权重以此来加强有效特征,抑制无效特征。

3.3 融入ECA-Net 注意力机制的改进 U-Net 网络模型

根据上述提到的结构, 本文在U-Net网络基础上, 使用VGG16 网络的特征提取结构代替原有的编码器, 在跳跃结构中融入ECA-Net注意力机制, 在特征提取结构后加入特征分类模块进而得到融入ECA-Net注意力机制的改进U-Net网络模型如图 8 所示, 改进后的U-Net网络模型由特征提取结构, 特征分类结构, 解码器结构, 跳跃连接结构和分割预测结构组成。

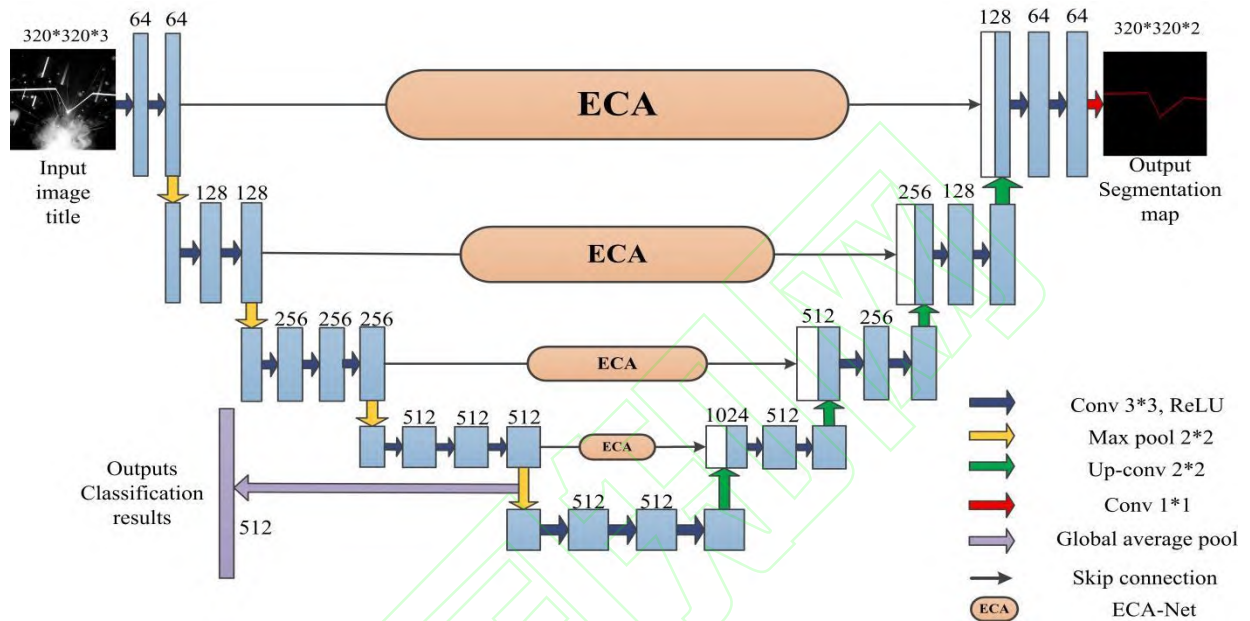


图 8 融入ECA注意力机制的改进U-Net网络模型

改进后模型的特征提取方式可以使卷积层输入与输出的有效特征图尺寸一致, 可以改善图像边界的处理效果, 提高了网络模型的鲁棒性和抗干扰能力。在特征提取结构之后, 加入全局平均池化层, 会得到一个 512 维度的特征向量, 之后对特征进行分类, 输出焊缝类型结果对应角接焊缝、V型焊缝、搭接焊缝、对接焊缝 4 种类型。接着进入解码器结构中, 对初步特征图进行上采样和特征融合, 融合不同层次的图像特征信息。最终获得的特征层和输入特征图的尺寸相同。网络中的跳跃连接可以将特征提取结构获得的有效特征图, 先通过ECA-Net注意力机制增强焊缝激光条纹特征提取能力, 对不同通道的信息重新赋予不同的权重, 然后将其与解码器上采样得到的特征图融合。最后就是分割预测结构, 经过 1×1 的卷积计算, 进而对解码器结构输出特征图进行通道数调整, 使其符合输出标准, 最后网络输出图像分割预测结果。

3.4 损失函数

视觉成像系统采集到焊缝激光图像中除了包括激光条纹和背景, 还有烟雾、飞溅和弧光等干扰, 激光条纹在图像中所占比例过小, 从而使得正样本数量不及负样本数量, 造成类别比例严重不平均。因此, 在训练过程中, 图像中存在大量负样本的损失值会对图像的损耗特性造成很大的影响, 这就

导致了网络在梯度更新过程中,焊缝图像中的干扰背景的权重偏大,从而影响焊缝条纹的预测结果甚至存在无法识别图片的现象。为解决由于焊缝模型中激光条纹和背景像素之间的比例失调,所造成的识别结果明显偏于背景的问题,本文在交叉熵损失函数(CE Loss)中添加Dice Loss和Focal Loss来对模型进行修正,从而达到提高模型分割精度的目的。

Dice Loss在训练中对于前景目标区域有着更深的挖掘能力,可以看作是在训练中对正样本影响的加强。其优势在于无论输入图片的尺寸如何,对于正样本的区域计算的Loss是一样的。因此,损失函数对于网络起到的监管作用始终与图像正负样本的尺寸无关。而正是因为前景目标占比较小才会导致正负样本不平衡的情况,所以Dice Loss在正负样本不均的场景有着不错的表现,对于本文所使用的焊缝图像数据集,应用Dice Loss可以在训练过程中提高目标焊缝条纹的权重,达到增强有效特征的正向作用。

Focal Loss^[17]主要针对了在训练中负样本权重过大的问题,降低其在训练中所占的权重,可以看作在训练中对负样本影响的削弱。Focal Loss是基于CE Loss改进提出的,其引入了参数 γ ,减少了易于分类的样本的加权,使得该模型更加集中于难分类的样本。同时还加入了平衡因子 α 用来改善正负样本比例不均,从而也有效缓解属性样本不平衡的问题。

本文使用的融入ECA注意力机制的改进U-Net网络模型使用Dice Loss、Focal Loss与CE Loss的组合函数作为网络的损失函数,表达式如下:

$$\text{Loss} = L_{\text{CE}} + L_{\text{DL}} + L_{\text{FL}} \quad (3)$$

$$L_{\text{CE}} = -y \log y' - (1 - y) \log(1 - y') \quad (4)$$

$$L_{\text{DL}} = 1 + \frac{(-2) \times (|X \cap Y| + 1)}{|X| + |Y| + 1} \quad (5)$$

$$L_{\text{FL}} = \begin{cases} -\alpha(1 - y')^\gamma \log y' & y = 1 \\ -(1 - \alpha)y'^\gamma \log(1 - y') & y = 0 \end{cases} \quad (6)$$

其中: L_{CE} 是二分类交叉熵损失函数, L_{DL} 是Dice损失函数, L_{FL} 是Focal损失函数, X 为预测焊缝激光条纹的像素数量; Y 为焊缝激光条纹真实像素数量, y 为真实值, y' 为像素预测为焊缝激光条纹的概率, $1 - y'$ 为像素预测为干扰背景的概率。当 $y = 1$ 时, 预测值越接近真实标签 1, 损失函数越小, 预测值越接近真实标签 0, 损失越大。当 $y = 0$ 时, 预测值越接近真实值 0, 损失越小, 预测值越接近真实值 1, 损失越大。

4 实验与结果分析

本文对基础U-Net网络的编码器结构进行改进，在跳跃连接中，使用超强通道注意力模块（ECA-Net）实现特征的加权融合，增强网络分割性能，实现激光条纹的完准确识别并正确识别焊缝类型。首先将视觉成像系统采集得到的图像标注并制作成数据集，在此基础上，将训练集图片用于对模型进行训练，然后验证集图片进行图像识别验证，最后对测试集图片进行分割预测与类型识别，具体流程如图9所示。

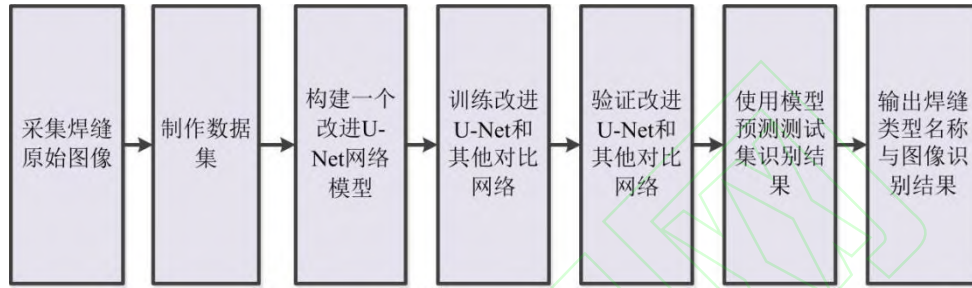


图9 焊缝识别的整体流程

4.1 模型训练

实验计算平台配置：Inter(R) Core(TM) i5-10400F处理器、显卡为NVIDIA GeForce RTX 3060Ti、操作系统为Windows10、Python 3.8、CUDA 11.1。深度学习框架使用的是Pytorch1.8.1，以Adam作为模型的优化器，将动量参数设置为0.9，学习率为0.0001。网络迭代训练epochs次数200次，Batch size为4。

4.2 评价指标

为了更加直观清晰的比较各个算法的分割结果精度，将人工标注图作为图像评价标准，计算各算法识别出的焊缝激光条纹像素与标注图之间的RMSE(Root Mean Square Error: 均方根误差)，PSNR(Peak Signal-to-Noise Ratio: 峰值信噪比)和SSIM(Structural Similarity: 结构相似性)。RMSE用来表示预测值与真实值之间的偏差。PSNR是峰值信号的能量与噪声的平均能量之比，单位为dB，代表了信号失真程度。SSIM是表现预测图像与目标图像相似程度的指标，在使用图像质量评价指标的同时，我们使用类别平均像素准确度（mPA）和平均交并比（mIoU）对焊缝激光条纹识别结果进行比对，计算公式如下：

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{x}_i - x_i)^2} \quad (7)$$

$$PSNR = 10 \log_{10} \frac{L^2}{MSE} \quad (8)$$

$$MSE = \frac{1}{N} \sum_{i=1}^N (\hat{x}_i - x_i)^2 \quad (9)$$

$$mPA = \frac{1}{K} \left(\frac{TP}{TP + FP} + \frac{TN}{TN + FN} \right) \quad (10)$$

$$mIoU = \frac{1}{K} \left(\frac{TP}{TP + FN + FP} + \frac{TN}{TN + FN + FP} \right) \quad (11)$$

其中： \hat{x}_i 为预测值； x_i 为真实值；N为种类数；TP（True Positive）表示目标被正确分割的像素数量；TN（True Negative）表示背景被正确分割的像素数量；FN（False Negative）表示目标被错误分割为背景的像素数量；FP（False Positive）表示背景被错误分割为目标的像素数量。

4.3 不同算法识别结果对比试验

本文选用OTSU图像分割算法，Steger激光条纹提取算法，U-Net和本文算法分别对测试集图像进行预测识别。本文将每种类型的焊缝随机抽取 2 张进行实验，对比实验结果如图 10、11、12、13 所示：

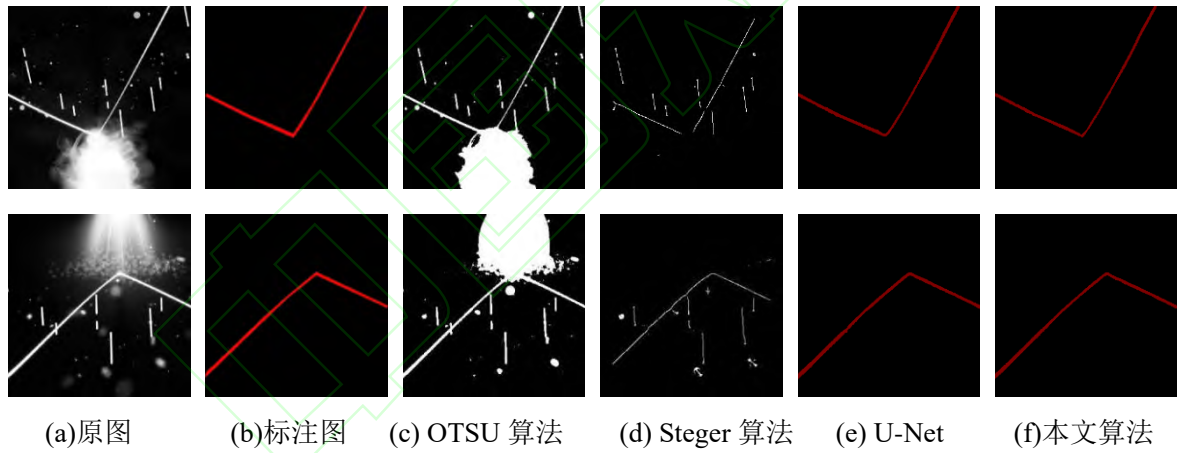



图 10 角接焊缝不同算法识别结果






图 11 V 型焊缝不同算法识别结果

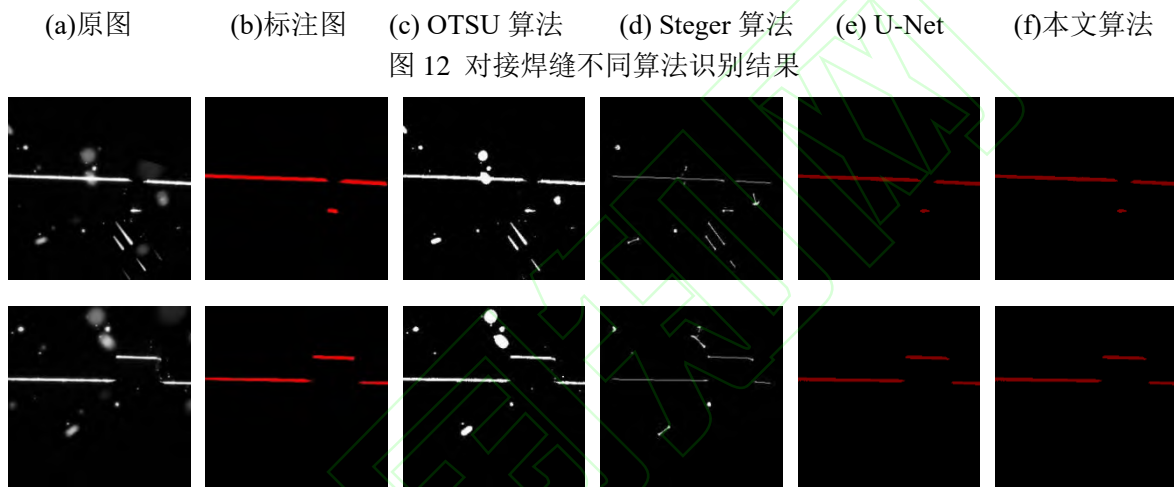


图 12 对接焊缝不同算法识别结果

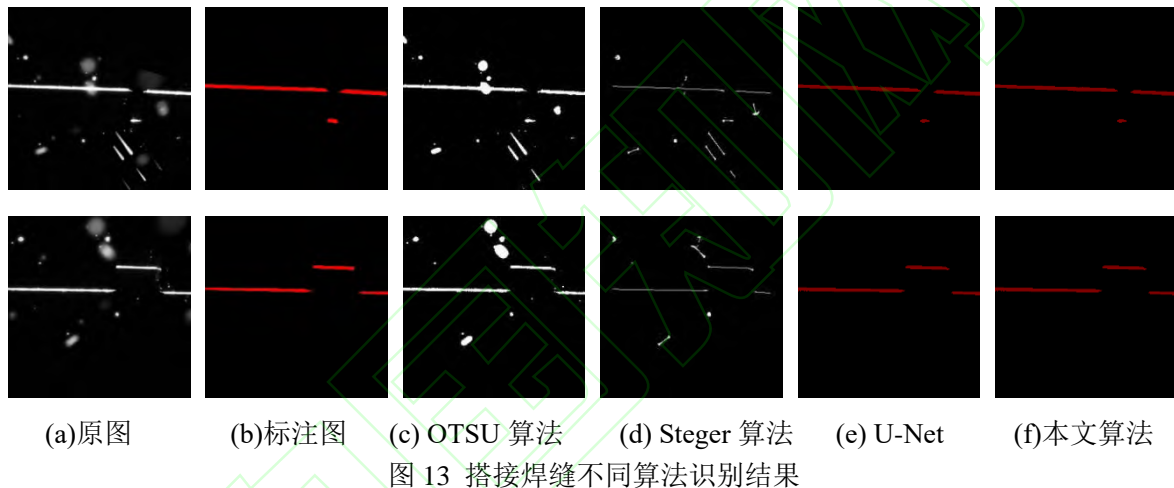


图 13 搭接焊缝不同算法识别结果

由于受到工件反光、噪声、飞溅以及烟雾干扰的影响，利用 OTSU 图像分割算法识别连续型和不连续型焊缝的结果如图 10(c)、11(c)、12(c)、13(c)所示，识别结果中存在大量噪点和干扰信息。由于 OTSU 算法是通过人工设定的阈值将图像中目标和背景根据灰度值的不同进行分类的，而图像中的干扰与焊缝灰度值相差不多，所以分割效果不理想。另外由于阈值的取值难以确定，也容易将烟雾，火花飞溅误识别为焊缝条纹。

Steger 激光条纹提取算法可以对烟雾干扰进行有效消除，但缺乏对噪声和飞溅的识别能力，仍出现误分割现象，Steger 算法识别连续型焊缝结果如图 10(d)、11(d)所示，当焊缝激光条纹交点被遮挡时，使用 Steger 算法识别结果会出现图像特征丢失的情况。Steger 算法识别不连续型焊缝结果如图 12(d)、13(d)所示，识别出的焊缝激光条纹端点位置仍然存在噪声偏差，且出现焊缝激光条纹特征缺失，条纹不完整和焊缝条纹边缘模糊的情况。

使用 U-Net 算法识别不连续焊缝结果如图 12(e)、13(e)所示，U-Net 算法可以克服大部分噪声，

飞溅以及烟雾干扰带来的影响，将图像中被烟雾和飞溅遮挡住的焊缝条纹也能被完整地识别出来，并能清晰的识别出线段端点为后续计算焊缝中心点提供精确位置信息。使用 U-Net 算法识别被遮挡的连续型焊缝如图 10(e)、11(e)所示，仍会存在背景与激光条纹像素混淆而被错误识别，以及由于烟雾和飞溅的遮挡导致连续的激光条纹出现特征丢失，从而焊缝激光条纹出现断裂现象，并且识别出的激光条纹毛刺较多，条纹并不光滑。

本文提出的融入 ECA-Net 注意力机制的改进 U-Net 算法，在识别连续型和不连续型焊缝都有着良好的表现，很好地解决了弧光，烟雾和飞溅的干扰，增强了焊缝条纹特征提取能力，减少了焊缝条纹特征丢失，将图像中被烟雾和飞溅遮挡住的连续焊缝条纹也能被完整地识别出来如图 10(f)、11(f)、12(f)、13(f)所示，本文提出的算法识别结果更接近于标准标注图，具有良好的噪声抑制能力的同时，提高了焊缝识别的泛化能力和抗干扰能力，增强了焊缝识别的自适应性和鲁棒性。

在得到预测识别图像结果之后，分别计算连续型和不连续型焊缝识别结果与标准之间的均方根误差(RMSE)，峰值信噪比(PSNR)和结构相似性(SSIM)，如表 1、表 2 所示：

表 1 连续型焊缝不同算法的 RMSE(pixel)、PSNR(dB)、SSIM

类型	评价指标	OTSU 算法	Steger 算法	U-Net 算法	本文算法
角接焊缝	RMSE(pixel)	6.2321	1.5041	0.6204	0.5281
	PSNR(dB)	9.8257	22.6850	31.7149	33.5756
	SSIM	0.7369	0.8975	0.9502	0.9592
V 型焊缝	RMSE(pixel)	6.8236	1.6198	0.5619	0.4513
	PSNR(dB)	8.9584	21.8644	31.1773	33.2294
	SSIM	0.6896	0.8835	0.9415	0.9617

从表 1 的数据可以分析出，相比于OTSU算法、Steger激光条纹提取算法和U-Net算法，本文提出的算法在识别连续型焊缝时具有良好的预测结果，本文算法识别效果所计算出的RMSE更小，这表明像素位置与评价标准误差更小，识别结果更接近真实图像。与RMSE相反的是在进行图像质量评估时，PSNR数值越大表明待评估的图像质量越好，所以本文提出的方法所识别出的连续型焊缝，图像质量也更接近于标准，优于其他方法，对于结构相似性，代表着两幅图像的相似水平。SSIM的范围为 0-1，值越接近 1，说明图像越相似。本文算法分割出的图像SSIM值最接近 1，说明与标注图像最为相似。从均方根误差(RMSE)，峰值信噪比(PSNR)和结构相似性(SSIM)三个指标来看，在连续型焊缝中，文中所述方法比其它方法都更有效。

表 2 不连续型焊缝使用不同算法的 RMSE(pixel)、PSNR(dB)、SSIM

类型	评价指标	OTSU 算法	Steger 算法	U-Net 算法	本文算法
对接焊缝	RMSE(pixel)	4.3553	1.0755	0.3526	0.3611
	PSNR(dB)	13.9673	24.2807	33.2100	34.1599
	SSIM	0.8524	0.9252	0.9469	0.9579
搭接焊缝	RMSE(pixel)	2.7158	1.2252	0.4837	0.4753
	PSNR(dB)	18.0596	23.9006	34.3349	33.3392
	SSIM	0.9145	0.9288	0.9507	0.9654

从表 2 的数据可以分析出，在对不连续型焊缝的识别过程中，会出现U-Net算法结果略优于本文算法的情况，其原因在于不连续型焊缝相较于连续型焊缝干扰更少，遮挡并不严重，且没有出现激光交汇所形成的光斑。所以在对接焊缝计算RMSE时，U-Net算法的像素位置更接近标注图像，而在计算PSNR和SSIM时，本文算法的数据均优于其他方法。而在搭接焊缝计算PSNR时，也出现了U-Net的数值更高，图像质量高于其他方法的情况，但本文算法计算出的数值与其相近。本文算法在像素位置误差和图像相似度方面，优于其他方法。

综上，通过图像识别结果和计算 RMSE、PSNR、SSIM 数据结果都可以看出，本文提出的方法在连续型和不连续型焊缝中，均体现出了良好的识别效果，进而说明本文提出的融入 ECA-Net 注意力机制的改进 U-Net 算法具有更精准的分割能力和更高的鲁棒性。

4.4 焊缝识别鲁棒性分析

由于在实际焊缝跟踪过程中，传感器所采集的图像大部分都是含有各种噪声干扰的图像，和少数的未起弧时较干净的图像，为了更好地比较算法的鲁棒性，本文利用神经网络图像分割算法领域常用的平均像素准确度（mPA）和平均交并比（mIoU）来衡量带有不同噪声的焊缝图像的分割精度，识别结果如表 3 所示。

表 3 U-Net 算法与本文算法在实际焊接中识别结果的比较

	mPA(%)	mIoU(%)	Time(ms)
U-Net	94.2	85.8	135
本文算法	95.6	90.4	142

由表 3 的数据中可以得出，U-Net算法的平均像素准确度(mPA)为 94.2%，在融入ECA-Net注意力机制后，mPA值上升并不十分明显，只增长了 1.4%，到达了 95.6%。这是因为实际场景下采集到的焊缝图像中黑色背景占据图像大部分面积，所以mPA值就会普遍偏高。而平均交并比(mIoU)在融入了ECA-Net注意力机制后上涨 4.6%，由原来的 85.8%上升至 90.4%。并且从处理图片用时方面，

本文算法虽添加了注意力机制，但处理图像时长上并未出现明显增加，可以满足实际焊接场景对实时性的需求。

为验证本文提出融入ECA-Net注意力机制的改进U-Net算法在实际应用上预测识别的精确性与鲁棒性，对视觉成像传感器采集到的带有复杂噪声的焊缝图像进行焊缝激光条纹识别实验，实验结果如图 14 所示：




图 14 复杂噪声环境下不同算法识别结果

由图 14 可知，对于在实际焊接的复杂噪声环境下采集到的具有烟雾，弧光，飞溅等干扰的图片，本文提出的方法可以对焊缝特征进行精确提取，进行高精度的预测分割，而且通过图 14(c)可以发现面对焊缝图像清晰度低，激光条纹较窄时，U-Net算法出现特征大量丢失的情况，激光条纹不完整无法获得具体像素位置信息。而本文提出的方法如图 14(d)所示，可以完整清晰地将条纹识别出来，不会出现断点，图像缺失等现象。当焊接激光条纹中的部分信息被产生弧光的烟雾所完全掩盖如图 14(a)所示，上述方法的检测结果中将可能存在特征缺失的现象，不过由于本文算法检测结果偏差相对较少，图像完整程度较好，图像分割精度较高。本文算法在处理速度上优于传统图像处理方法，也缩减了图像处理方法中的滤波去噪，图像增强等步骤。综上，本文提出的融入ECA注意力机制的

改进U-Net网络的鲁棒性焊缝图像识别方法能够进行深度学习,将焊缝图像准确完整地从中分离出来,并能对焊缝类型进行准确识别。这种方法在具有良好的噪声抑制能力的同时,提高了焊缝识别的泛化能力和抗干扰能力,增强了焊缝识别的自适应性和鲁棒性。

5 结束语

针对工件反光、噪声、飞溅以及烟雾干扰,导致焊缝图像处理复杂的问题,本文结合深度学习方法,提出了一种融入注意力机制的改进U-Net的焊缝图像鲁棒性识别算法,通过加强有效特征,抑制无效特征,提高焊缝识别的自适应性、抗干扰能力以及鲁棒性。在网络模型中的特征提取模块后,加入特征分类模块,在得到焊缝分割图像的同时获取焊缝类型名称。另外在损失函数中添加 Dice Loss和Focal Loss来修正网络预测结果偏向对焊缝图像中背景像素的问题,改善预测结果的同时提高分割的准确性。本文提出的算法在实际焊接环境中,对焊缝图像的分割精度指标mPA值为 95.5%, mIoU值为 90.4%,焊缝特征分类准确率达到 98%, RMSE、PSNR、SSIM指标也优于其他方法。上述结果说明,本文提出的算法可以在保证实时性的前提下,有效地提取和识别出焊缝的特征,在具有弧光干扰的实际焊接现场中具有一定的应用前景。在后续的研究工作中,将继续研究当条纹部分被遮挡时,对模型特征提取结构进一步优化,使其可以获取更多图像信息,让模型可以在强噪声环境下发挥更大的效用。

参考文献:

- [1] Fan.J, Jing.F, Yang.L et al. A precise seam tracking method for narrow butt seams based on structured light vision sensor[J]. Laser Technol.2019, 109 (2): 616–626.
- [2] Yuanyuan Z , Kezhu Z, Lingshen F, et al.Recognition of weld seam for tailored blank laser welding based on least square support vector machine[J].Transactions of The China Welding Institution.2019,40(2):77-81(in Chinese) .
- [邹媛媛, 左克铸, 房灵申等. 基于最小二乘支持向量机的激光拼焊焊缝识别[J].焊接学报, 2019,40(2):77 – 81.]
- [3] He.J, Yu,Z. Research on Weld Seam Tracking Detection Method Based on Image Processing[J]. Applied Laser ,2020,40(5): 847–854.
- [4] Zhang, Y et al . Narrow-seam identification and deviation detection in keyhole deep-penetration TIG welding [J]. The International Journal of Advanced Manufacturing Technology. 2018,101(5-8): 2051-2064.

[5] Yongshuai Z,Guowei Y , Qiqi W , et al.Weld Feature Extraction Based on Fully Convolutional Networks[J].Chinese Journal of Lasers,2019,46(3):1-8(in Chinese).

[张永帅,杨国威,王琦琦等. 基于全卷积神经网络的焊缝特征提取[J]中国激光,2019,46(3):1-8.]

[6] Weibo Y. Yu L.Hongtao Y et al.The Centerline Extraction Algorithm of Weld Line Structured Light Stripe Based on Pyramid Scene Parsing Network[J]. IEEE Access 2021,9:105144 - 105152.

[7] Cheng Y, Chen S, Xiao J et al.Dynamic estimation of joint penetration by deep learning from weld pool image[J].Sci Technol Weld Join 2021,26(4):279–285.

[8] Xi T, Xifan Y,Yi D, et al.Weld initial vector detection and robot pose estimation based on improved CenterNet[J/OL]. Computer Integrated Manufacturing Systems(in Chinese).

[唐溪,姚锡凡,董艺,等. 基于改进 CenterNet 的焊缝起始向量检测与机器人位姿估计方法[J/OL]. 计算机集成制造系统.<https://kns.cnki.net/kcms/detail/11.5946.tp.20211101.1612.016.html>]

[9] Runquan X, Yanling X, Zhen H et al.An adaptive feature extraction algorithm for multiple typical seam tracking based on vision sensor in robotic arc welding[J].Sensors and Actuators A: Physical,2019,297(10):1-15.

[10] Shikuan Z. Qingxiao W, Zhiyuan L. Detection and Segmentation of Structured Light Stripe in Weld Image[J]. Acta Optica Sinica, 2021,41(5):1-9(in Chinese) .

[张世宽,吴清潇,林智远. 焊缝图像中结构光条纹的检测与分割[J].光学学报, 2021,41(5):1-9.]

[11] Wenwei Y, Shuai C, Baoyan M , et al.Fringe segmentation algorithm based on improved U-Net network[J].Laser & Optoelectronics Progress,2021,25(4):1-24(in Chinese) .

[闫文伟,陈帅,穆宝岩,等.改进U-Net网络的光条纹分割算法[J].激光与光电子学进展 2021,25(4):1-24]

[12] Ke L, Zhongqing W, Yong J, et al.Detection method of weld bubble defect in chip X-ray image based on improved U-Net network[J].Huazhong Univ. of Sci. & Tech.2022,50(6):104-110(in chinese)

[李可,吴忠卿,吉勇,等.改进U-Net芯片X线图像焊缝气泡缺陷检测方法[J].华中科技大学学报(自然科学版):1-7]

[13] Wang Q, Wu B, Zhu P, et al. Eca-net: Efficient channel attention for deep convolutional neural networks[C]//IEEE Conference on Computer Vision and Pattern Recognition(CVPR).IEEE; 2020:11531-11539.

[14] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional networks for biomedical image

Segmentation[J]. Medical Image Computing and Computer- Assisted Intervention-MICCAI 2015,9531: 234-241.

[15] Z. Yuan, M. Xiangqun, J. Dengbiao et al. Structural light stripe center extraction method under complex interference[J]. China Laser, 2020, 47(12): 172–180.

[16] Jie H, Li Set al. Squeeze-and-excitation networks[J]. IEEE Trans Pattern Anal Mach Intell 2017, 99.

[17] Tsung-Yi Lin; Priya Goyal; Ross Girshick et al. Focal Loss for Dense Object Detection[C]// IEEE International Conference on Computer Vision (ICCV), 2017: 5879-5891.

作者简介:

周思羽（1998-），辽宁鞍山人，硕士研究生，研究方向：计算机视觉、模式识别，E-mail: zhousiyu0122@163.com;

+刘帅师（1981-），吉林洮南人，副教授，博士，研究方向：计算机视觉、模式识别，通讯作者，E-mail: liushuaishi@ccut.edu.cn;

杨宏韬（1982-），山西临汾人，副教授，博士，研究方向：视觉伺服、多源信息融合，E-mail: yanghongtao@ccut.edu.cn;

宋宜虎（1998-），山东济宁人，硕士研究生，研究方向：计算机视觉、模式识别，E-mail: songyihu12138@163.com。