

分类号 TG445

学 号 141030171

密 级 _____

西安石油大学

Xi'an Shiyou University

全 日 制 学 术 型

硕 士 学 位 论 文



题 目 基于主成分分析的焊缝缺陷识别算法

研究

作 者 姓 名 张君

导师姓名、职称 穆向阳 教授

学 科(专业)名 称 控制科学与工程

提 交 论 文 日 期 2017年6月19日

论文题目：基于主成分分析的焊缝缺陷识别算法研究

专业：控制科学与工程

硕士生：张君（签名）_____

导师：穆向阳（签名）_____

摘要

焊缝缺陷的识别是检测焊件质量的关键环节，有效地检测出焊缝缺陷保证焊缝的质量，对于安全生产具有十分重大的意义。传统的缺陷检测，主要依靠人工评片，该方法主观性强，受检测人员的专业素质影响较大，自动化水平低，易产生较多的误判和漏判；随着计算机技术以及电子技术的迅速发展，使得基于图像处理的计算机辅助评片技术成为可能，计算机评片技术则大大减轻了评片人员的工作量，提高了工作效率，使评片过程更加科学和规范，但是，由于焊缝图像在输入计算机时噪声过多、缺陷边缘模糊和对比度低等缺点，给缺陷信息的正确提取、分割和识别带来了很大的困难。

研究以埋弧焊焊缝的 X 射线检测图像为对象，针对焊缝区域中可能存在的气孔、裂纹等缺陷，通过图像处理、特征提取和神经网络识别完成了焊缝缺陷识别。首先，通过图像去噪、图像增强、图像分割和图像边缘检测算法在整幅图像中找到焊缝边界。其次通过分析行列灰度曲线的分布情况对焊缝缺陷的位置进行定位。再次，采用 7 类几何特征和形状特征对缺陷进行描述，建立相应的特征描述向量，并采用主成分分析 (Principal Component Analysis, PCA) 和核主成分分析 (Kernel Principal Component Analysis, KPCA) 方法对其进行主元分析。最后，分别以原始数据和得到的主元特征量为系统输入，针对气孔和裂纹 2 类缺陷，研究了基于神经网络的焊缝缺陷识别算法。研究表明，对特征选择后的数据利用主成分分析和核主成分分析进行特征提取，可将数据投影到一个更低维的特征空间，实现分类器性能的提高。仿真结果，在对数据进行特征提取的能力上，核主成分分析提取的主元比主成分分析提取的主元减少 1 个，显示核主成分分析优于主成分分析；在对焊缝缺陷识别的效果上，RBF 神经网络的分类正确率比 BP 神经网络高于 0.72 个百分点，显示 RBF 神经网络优于 BP 神经网络。

关键词：焊缝缺陷 图像处理 主成分分析 核主成分分析 神经网络

论文类型：其他

Subject: Welding defects recognition algorithm reasearching based on Principal Component Analysis

Speciality: Control Science and Engineering

Name: Zhang jun (signature)_____

Instructor: Mu Xiangyang (signature)_____

ABSTRACT

Weld defect recognition is a key technology in the process of welding quality detection. Detecting the weld defect effectively and guaranteeing the quality of weld are of great significance for oilfield safely production. In the aspect of defect detection, manual assessment has a big subjectivity, reatly influenced by testing personnel's professional quality, low level of automation. With the rapid development of computer technology and electronic technology, the technology of computer aid assessment based on image processing has become possible. And more misjudgments are easy to be produced. The computer Assistant Assess System has greatly reduced the workload of the worker, and improver the working efficiency is some extent, thus, the process of the film assessment is more scientific and more standard. But when we put the welding line image into computer, it has much noise, the edge of defect fuzzy and lack contrast and so on, so these weak points make drawing the defect information, segmentation and recognition much difficulty.

In this research, the X-ray images of submerged-arc welded pipe are taken as the object. To identify the welding defects, such as: air hole and crack, through image processing, feature extraction and neural network recognition is used to identify defect successfully. First, image filter, image enhancement, image segmentation and edge detection arithmetic is used to find the welding seam boundary in the entire image. Second, by analyzing the distribution of gray curve, the positions of the weld defects were located at first. Third, build up the feature vector by calculating 7 classes geometric and shape feature of welding defects, use the Principal Component Analysis and Kernel Principal Component Analysis method preprocess this vector. Last, the recognition between air hole and crack is studied based on the Neural Network, of which the Original data and processed vector are taken as the input parameter. The experiment result indicated the dataset had been carried out feature selection could be mapped to a lower feature space by using KPCA and PCA for feature extraction. As a result, the performance of the classifier was improved. Simulation result, we could find KPCA less than PCA 1 in feature extraction, KPCA was more effective than PCA; we could find RBF neural network BP neural network more than 0.72% in defects recognition, RBF neural network was more effective than BP neural network.

Keywords: Welding defects, Image process , Principal Component Analysis , Kernel Principal Component Analysis, Neural Networks

Thesis: Others

目 录

第一章 绪论.....	1
1.1 研究背景.....	1
1.2 国内外研究现状.....	2
1.3 研究的目的与意义.....	5
1.3.1 研究的目的.....	5
1.3.2 研究的意义.....	5
1.4 课题来源.....	6
1.5 研究的内容及技术路线.....	6
1.5.1 研究内容.....	6
1.5.2 技术路线.....	6
1.6 本章小结.....	7
第二章 图像处理的基础理论.....	8
2.1 图像处理技术.....	8
2.1.1 图像滤波.....	8
2.1.2 图像增强.....	9
2.1.3 图像分割.....	10
2.1.4 图像边缘提取.....	10
2.2 相关理论研究.....	11
2.2.1 神经网络相关理论研究.....	11
2.2.2 主成分分析相关理论研究.....	12
2.2.3 核主成分分析相关理论.....	14
2.3 本章小结.....	17
第三章 埋弧焊焊缝缺陷图像的采集与处理.....	18
3.1 X 射线焊缝缺陷图像采集系统的建立.....	18
3.1.1 CCD 摄像头.....	18
3.1.2 图像采集的结果与存取.....	19
3.2 焊缝图像处理系统.....	20
3.2.1 确定焊缝区域(ROI).....	21
3.2.2 基于灰度曲线分析的焊缝缺陷定位.....	32
3.3 本章小结.....	33
第四章 特征参数的选取与分析.....	34
4.1 焊缝缺陷种类及其特点.....	34

4.2 建立缺陷的特征参数.....	35
4.2.1 截取到的焊缝缺陷区域.....	35
4.2.2 缺陷的几何特征.....	37
4.2.3 缺陷的形状特征.....	38
4.2.4 提取出气孔和裂缝的部分特征参数.....	39
4.3 特征参数的处理.....	40
4.3.1 主成分分析的基本原理及计算步骤.....	40
4.3.2 特征参数的主成分分析.....	42
4.3.3 核主成分分析的基本原理及计算步骤.....	45
4.3.4 特征参数的核主成分分析.....	47
4.4 特征参数的主成分分析和核主成分分析的对比.....	52
4.5 本章小结.....	52
第五章 基于神经网络的焊缝缺陷识别研究.....	53
5.1 神经网络特征和缺陷识别原理.....	53
5.2 神经网络模型的对比.....	53
5.2.1 BP 神经网络.....	54
5.2.2 RBF 神经网络.....	57
5.3 实验对比分析.....	59
5.4 本章小结.....	62
第六章 总结与展望.....	63
6.1 总结.....	63
6.2 展望.....	63
致 谢.....	65
参考文献.....	66
攻读硕士学位期间发表的论文.....	69

第一章 绪论

1.1 研究背景

石油作为一种不可再生的战略资源，受到各个国家的竞争和高度重视。原油运输、货轮运输、罐车输送、管道传输等等，凭借安全、性价比高等优势，长输管道传输成为石油“流动”的主要途径。然而在其运输过程中需要架设管道，管道不仅会受到温度、湿度、压力的影响，而且有时还会受到极其恶劣环境的影响，致使其石油运输环境变得复杂，安全系数有所降低，因此在石油能源运输过程中必须要确保其自身安全性以及周边环境的可持续性发展，更重要的是确保人们的生命安全。

在管道的选择方面我们无法做到无缝钢管的采用，在管道与管道的连接方面我们多为采用焊接的方式。焊接是把两种相同或不同的物体通过加热的方式结合在一起，它作为一种连接、补缺工艺形式，在船舶、油气、桥梁等领域会经常用到^[1]。因外界复杂的环境，焊缝难免会产生缺陷，如果未得到及时处理不仅会造成资金的浪费，还会衍生一些附带的危害进而造成不必要的安全事故。为提高焊接的质量，确保焊缝的可靠性、安全性，对石油管道焊缝内的缺陷进行检测是必然之举。焊缝的无损检测的方式颇多，其中射线探伤（Radiographic testing）使用较为普遍。基于X射线图像检测直观可靠、数字化精度高、穿透力强等优越性，本文以X射线来做检测探究^[2]。

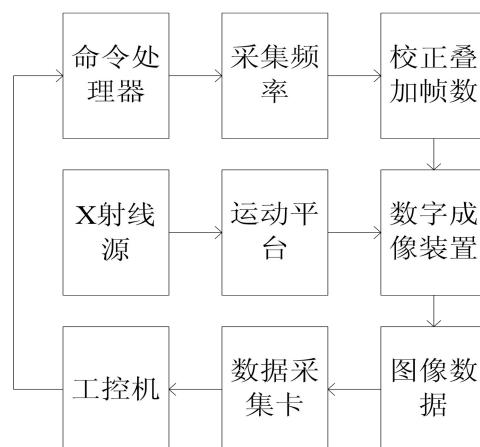


图 1-1 X 射线数字成像系统

管道焊接期间会出现很多不定影响因素，如焊接接头处含有杂质、电压不稳定、焊接工人技术不娴熟等，它们都能够使焊件产生一定的缺陷^[3]。消除潜在安全隐患，确保人身安全，必须对其焊缝缺陷进行检测，为了使检测结果没有差错，需要对焊缝内缺陷的具体位置予以确认及类别加以判断。目前，在油气长输管道焊缝缺陷检测中人工进行检测所占的比重较大，该方法主观性强、劳动强度大、受检验人员的专业能力和素质水平不同；其次，在检测技术方面主要依靠专业技术人员的理论知识，在检测识别过程中

难免会伴有技术人员主观意念加之自己的经验不成熟，往往会对做出不正确的判断；最后，由于埋弧焊焊缝缺陷在整张图片中占据的位置较小，容易导致使其误检或漏检，很难立即对焊缝缺陷做出正确的辨识和分析，因此应用计算机辅助技术对焊管埋弧焊焊缝缺陷进行分析和识别是相当有必要的。计算机辅助评片具有方便删改、易于存档等特点，在某种程度上降低了人工评片的工作量，提升了评片的能力。现如今，很多识别算法还存在着不足，识别率还有待提高^[4]。

计算机技术从发展初期到现阶段，在人们的学、工作、生活中起了巨大作用，成为了不可替代的工具。由于人工检测缺陷存在很大漏洞，为了对其进行弥补，很多专家提出了使用计算机技术进行评片。计算机技术优于人工技术，不仅在评片技术方面较突出，而且在存档和查找方面也较突出。如今，计算机评片技术虽然在一定程度上提高了焊缝缺陷检测的水平，但是仍然存在很多不足之处：如噪声夹杂在个别被检测的图像中容易对缺陷样图的提取造成一定的困难，也容易导致缺陷分类错误；样本模糊不易判断等^[5]。因此探究一种推广性能好、速度快、准确率高的焊缝缺陷识别方法，成为了人们不断追求的目标。

1.2 国内外研究现状

随着科学技术的不断发展，计算机辅助技术近几年始终是专业人员探究的领域之一，它在各项计算机领域应用过程中大大减少了人为参与，提升了工作能力。人工智能与计算机大数据的分析综合运用，在计算机各项分析、识别过程中，为了更好提高埋弧焊焊缝缺陷图像效果，必须充分将该科学技术应用到焊接技术这个领域，使得这项数据与图像相结合的高新技术在实际生产中发挥作用，以至吸引更多人对其进行研究，以下分别是国内外学者对其进行研究的现状。

1) 在焊缝缺陷的无损检测中

西安科技大学的王彬，利用超声检测中的小波变换的方法进行焊缝缺陷的检测，实验表明该方法具有良好的降噪效果、抗干扰能力，并且效率高、成本低，但是对缺陷的正确判定受人为影响较大^[6]；大连理工大学的王恩亮，利用无损检测中的X射线进行焊缝缺陷检测，该方法采用计算机自动检测技术，代替了人工检测与分析，受人为影响因素较少，但是射线检测还存在一些成本过高，图片分析不便等缺点^[7]。南昌航空大学的刘辉针对无损检测人工方式中存在的检测效率低、主观思维不一致，系统操作复杂等问题，研究了一套自动检测方案，提出了基于阈值分割的缺陷提取技术，并根据SUSAM算法和形态学孔洞填充算法实现了焊缝缺陷目标的定位，最后通过设计的二叉树分类算法流程，完成了埋弧焊缺陷的辨认。



图 1-2 焊缝无损检测国内外状况

2) 在焊缝缺陷图像预处理方面

国外学者藤田勉在缺陷样图提取方面，利用给定的数据寻求一种近似函数对图像线灰度进行拟合，利用拟合之后的图像与原图像进行对比，去除相同部分，就很容易得知缺陷边界信息^[8]。T. warren 等人针对线灰度分布中出现的一些情况，采取了一定的办法，通过灰度直方图中明显的波峰波谷出现提取了缺陷信息的具体位置^[9]；武汉理工大学的杨川对焊缝缺陷的识别过程进行了深入的研究和分析，首先，针对噪声采用了高斯平滑增强和模糊增强处理技术，然后利用缺陷标记等算法提取边界像素信息，最后对提取的缺陷进参数处理，提取缺陷的有用信息，才有利于后续焊缝缺陷更加容易识别^[10]；吉林建筑工程学院的魏大慧，针对焊缝缺陷中存在的问题进行了图像处理技术的实验对比，选出了 LUM 滤波方法去除噪声、保存完整信息、增强清晰度^[11]；西安科技大学的仲崇丽，针对 X 射线底片数字化之后，缺陷图像出现的一些问题，提出了一种利用 K 近邻平滑滤波方法进行降噪，然后用模糊进行图像增强，最后采用阈值进行分割完成图像预处理技术，接下来根据提取的缺陷进行形状特征参数描述，最后进行评片识别焊缝缺陷类型^[12]；北京邮电大学的莫国柱，研究了图像的灰度映射功能显示在 Windows 平台上，并借助数字剪影的思想将这项技术应用到缺陷轮廓提取中来，实现了焊缝缺陷的预处理操作，为后面的操作提供了基础^[13]。

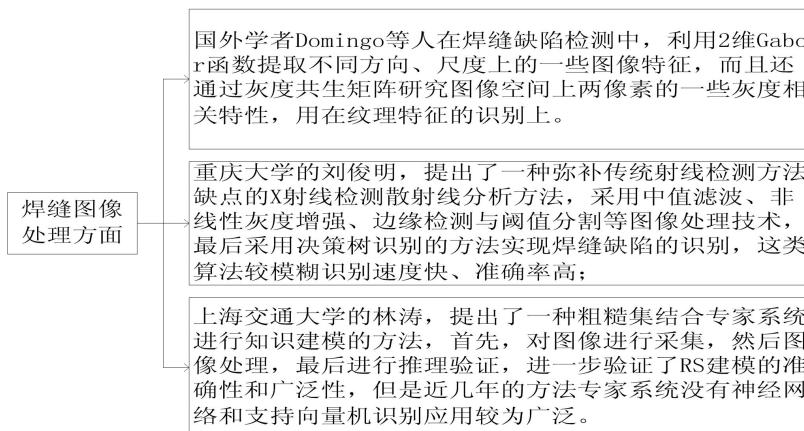


图 1-3 焊缝预处理方面国内外现状

3) 在焊缝缺陷特征参数提取方面

日本的井上腾敬通过提取缺陷的特征参数与资料库中的特征参数比较分析的方法识别缺陷的类型，该方法针对一些常见的类型识别比较容易，相对于复杂的类型来说识别就比较困难^[14]。西安工业大学的王鹏，针对射线胶片中存在的一些问题，提出了基于减影法的检测算法，首先利用模糊增强的方法增加对比度，利用像素标记提取原始灰度值，然后去除缺陷，衍生出背景图像，最后根据减影法得到缺陷^[15]。西安石油大学的蔡晓龙，在特征参数提取之后，对提取的形状参数数据进行了主成分分析，降低了维数，减少了运算的复杂度，提高了效率。^[16]

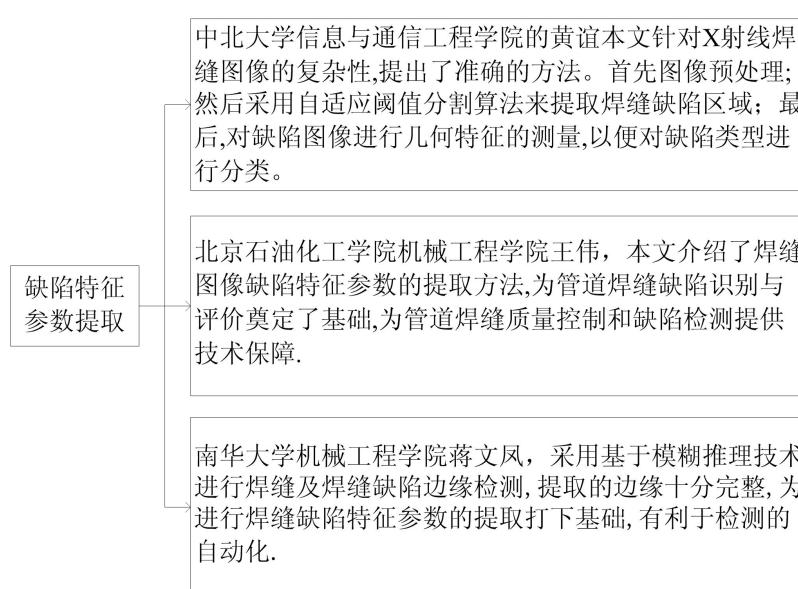


图 1-4 缺陷特征提取方面现状

4) 在焊缝缺陷图像识别方面

美国的 Zapata J, Vilar, Ruiz, 设计了一个自动系统来检测、识别焊接缺陷，射线图像基于neuro-classifiers人工神经网络和adaptive-network-based模糊推理系统进行分类和评估，在经过预处理提取缺陷后，依据几何特征描述缺陷的形状和方向，初步判定其类型，再通过一个人工神经网络之间的竞争和模糊推理系统对焊接缺陷进行分类^[17]。国外学者 Barai S V 和 Agrawal P，基于线性矢量量化监督神经网络分类器中实现并行处理环境参数，单个建筑单一处理器和单一建筑多个处理器并行神经分类器开发的焊接缺陷分类^[18]。三峡大学的李力，提出了一种基于小波和神经网络焊缝缺陷识别方法，对裂纹、气孔、未焊透等缺陷类型识别非常有效，准确率也高^[19]；东北石油大学的巩淼，针对焊缝缺陷特征固有的模糊性，研究基于模糊理论的神经网络模式识别算法，以模糊理论为基础网络的缺陷训练样本数据，代替传统的输入变量模式，提高网络的映射能力，开发出的焊缝缺陷识别系统运行速度快，容易分析，准确率也高，可以得到人们满意的结果^[20]。

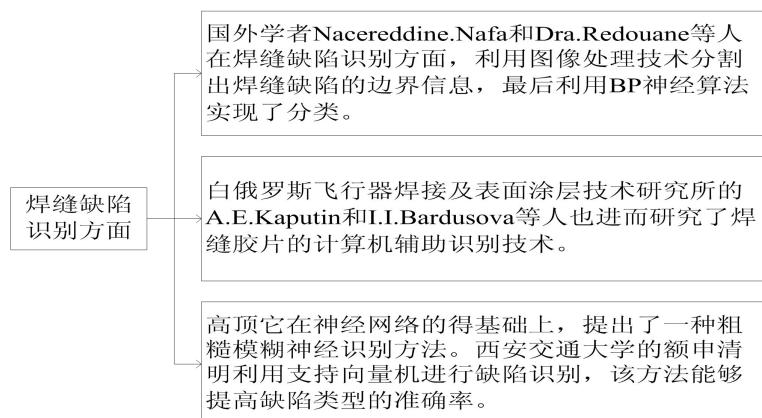


图 1-5 图像识别方面国内外状况

1.3 研究的目的与意义

1.3.1 研究的目的

油气集输是为了满足石油、石化等行业运输的需求，而开发的一种输送管道。随着管道使用年限的增加，它的安全管理工作逐渐引起重视，需要人们时刻关注管道在运行中出现的各种问题，并及时进行解决，才能够切实落实安全问题，维护社会稳定，提高企业经济效益，保障人们的利益。缺陷种类有很多，有的位于外部可以直接用肉眼看到，如咬边、烧穿、表面气孔、裂纹等它们称为外部缺陷；有的缺陷位于内部无法用肉眼看出，需要射线探伤技术，如未焊透、夹渣内部缺陷、裂纹等，它们称为内部缺陷。目前，如何准确的对埋弧焊焊缝缺陷样图进行分析和判断，探讨了一种基于主成分分析的特征参数降维处理算法^[21]。在实际的课题领域研究中，为了使问题得到比较详细的分析和完整的描述，提出的每个变量和因素我们都必须要考虑，所以变量反应的信息在一定程度上重复。但是，在研究这个课题时，变量信息太多就会加大算法时间和空间复杂度、减慢计算机的速度。很显然，人们希望探讨到一种方法来处理此类出现的问题使得到的数据量少，又能呈现出更多信息^[22]。

1.3.2 研究的意义

石油、天然气都属于能源物质，是人们的日常生活中不可或缺的部分，也占据着国民经济中重要的地位，而油气长输管道作为他们的运输管道，必须保障管道达到资源安全运输的程度，保障管道的材料有较强的强度，保障管道施工的技术，保障不发生事故，确保整个设计系统的可靠性高。可见保证生产安全是正常运行的前提，由于长输管道材料难以实现独立通体管道的输送，而是通过焊接技术实现管道的传输，因此在石油长输

管道中对缺陷进行检测和辨认是至关重要的步骤^[23]。鉴于人视察能力有限，对焊缝的表面积识别游刃有余，但对于焊缝的内部缺陷却无法很好的进行观测。

1.4 课题来源

本题目为自选课题。

1.5 研究的内容及技术路线

1.5.1 研究内容

本课题主要研究目标为长输管道埋弧焊焊缝缺陷识别算法，其图像作为本课题研究对象，通过深入学习国内外埋弧焊焊缝缺陷分析和识别的相关资料，对产生焊缝缺陷的成因以及影响检验正确性的关键因素进行了分析和探讨，对焊缝缺陷识别过程进行全面了解。研究内容：首先利用 MATLAB 软件中各种算法的常用程序，对焊缝缺陷样图按规定进行编程处理；然后在缺陷样图中进行形状特征参数的提取并利用不同的算法进行主成分的提取；最后将缺陷原始数据和不同算法提取的数据集利用不同的网络结构进行判断。

1.5.2 技术路线

本课题研究对象是埋弧焊焊缝图像，具体分析某个算法的优劣。重点研究了主成分分析算法，目的是使表示缺陷样图特征的数据量减少，最后应用神经网络实现缺陷类型辨识。拟采用的技术路线如下图所示：

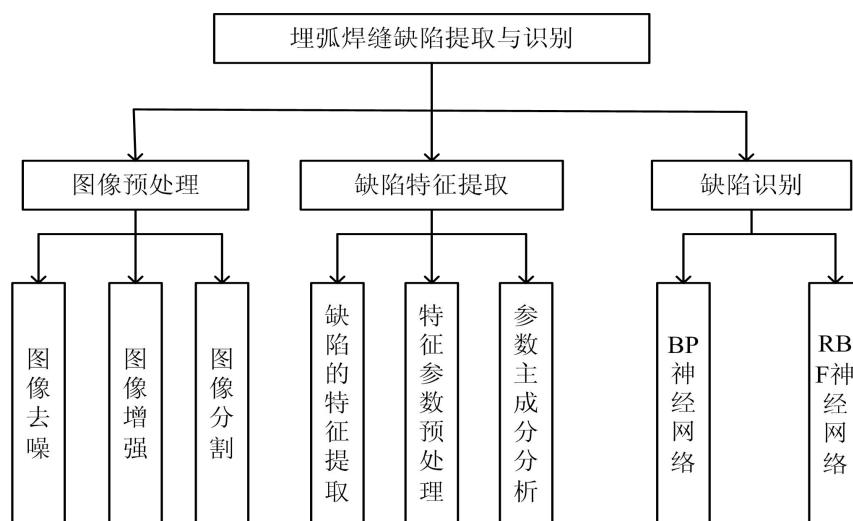


图 1-6 拟采用的技术路线

1.6 本章小结

本小章介绍了课题的背景、国内外现状、目的、意义以及内容，论述了长输管道运输的安全性以及焊缝缺陷识别的重要性，并且对全文拟采用的技术路线做了大概论述，指出了缺陷图像识别过程中用到的各种算法，算法各有优缺点，针对不同的缺陷图片采用不同的程序进行仿真。

第二章 图像处理的基础理论

2.1 图像处理技术

在X射线照射下长输管道埋弧焊焊缝成像形成了焊缝图像。由像素矩阵组成的焊缝图像数据量较大，在其传输、处理过程中难度加大。数字图像处理技术不仅需要操作人员具有较强的专业基础以及过硬的技术本领，而且还依赖于计算机的科学技术。数字图像处理技术是一门结合了众多软件编程算法的综合性学科^[24]。图像处理技术是对系统硬件采集到的图像进行前期操作，操作中会遇到各式各样的问题，针对不同的问题使用不同的软件编程，比如图像中噪声的去除，使用滤波的算法的进行编程；前后背景对比度差，使用灰度增强的算法进行编程；要想得到缺陷样图边界信息，使用图像边缘检测算法等，这是图像处理过程中必须采用的编程方法。

2.1.1 图像滤波

在硬件系统对目标图像采集的过程中，噪声也会随之产生，使得到的图像的表面特征变差、视觉效果模糊化，进而影响到后续图像目标的分析和判断。如果忽视其存在不采取任何措施，在缺陷图片的处理中会影响后续辨认的效果，因此图像排除噪声污染问题是图像处理过程中的重要步骤。在图像降噪的过程中主要是抑制混杂在图像中的噪声，增强被掩盖的信号，使图像目标几何结构变得清晰。由于噪声种类很多，没有一种特定的方法对不同的噪声进行抑制，这时选择一种适合滤除噪声的方法是非常重要的。图像滤波它是在尽可能保留样本特征的前提下对样本中的干扰信号进行排除，保留有价值的信息。图像滤波是一种邻域处理方法，输出图像的像素值由输入图像中某一点的像素值以及该点的邻边区域像素值决定。图像噪声是在图像输入、采集、处理、发送、接收、输出的过程中产生，使得图像的质量降低，为后续的工作展开带来很大的不利因素。噪声分类^[25]如下：

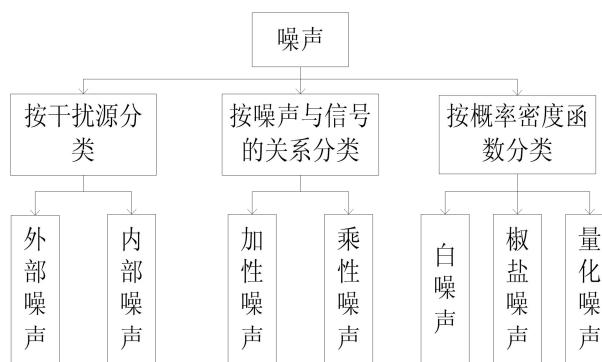


图 2-1 噪声分类

图像降噪主要是抑制噪声、降低干扰、提高图片的质量，目前降噪的两种主要方法是空域和频域滤波^[26]。空域滤波是借助空域模板对图像进行操作达到降噪的效果。频域滤波是通过衰减目标图像傅里叶变换中高频信号的范围来达到降噪的目的，虽然运算量大但可以得到较为理想的频率特性。空域滤波和频率滤波在图像降噪方面既有共同点也有不同点，相同点都是排除噪声污染提高样本质量，不同点是处理方式不同。下图是图像滤波的分类：

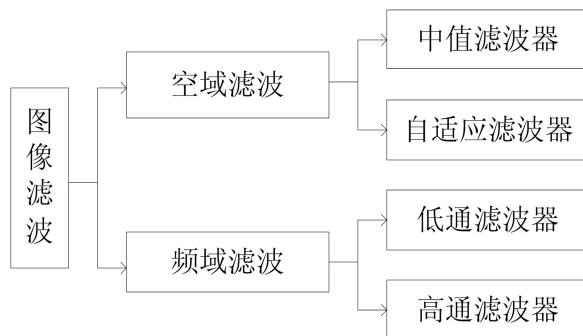


图 2-2 图像滤波的分类

因为采集到图片噪声的特点大多是不规则的而且是频率较高的所以本文采用空域滤波方法。

2.1.2 图像增强

图像增强采用一系列的方法根据特定的需求凸显图像中的有关信息，隐蔽图像中无关的信息，其目的是提高图片的质量和使用价值。图像增强后的图片不一定保真，但是它能够使图片中目标的轮廓清晰可见，增强人的视觉效果，加强图像的识别，满足某种特殊情况下的需要。图像增强是计算机的一种术语它增强的目的是使人产生的视觉效果更加明显，更适合计算机进行推理判断。图像增强是以特定的方式改变灰度直方图，是像素到像素的操作，它并没有一个固定的标准去判别其效果好坏，只要这种方法有利于图像的识别那便是有用的。图像增强颇受人们重视，它仿造人的视觉设计，其目的是为了得到人类期望的视觉效果。图像增强方法^[27]如下：

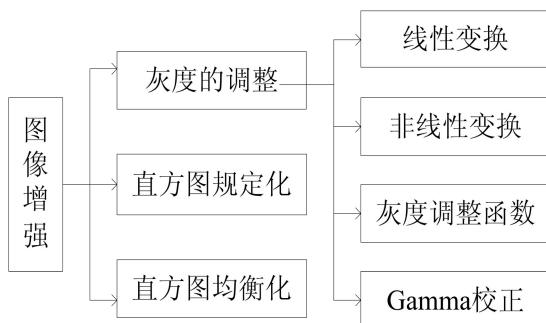


图 2-3 图像增强的方法

2.1.3 图像分割

图像分割已经遍及到生活中的各个领域，它是缺陷判断和计算机识别系统的重要环节。图像分割就是根据焊缝图像中前景区域和背景区域的灰度，使图片清晰分割开来并提出前景的过程，就是从背景中把前景分隔开来。图像分割是根据图像的特征把图像分成两类或者多类不同的类别，这些类别所划分的区域互不交叠，并且同类别所在区域的特性相似^[28]。图像分割算法很多如下图所示：

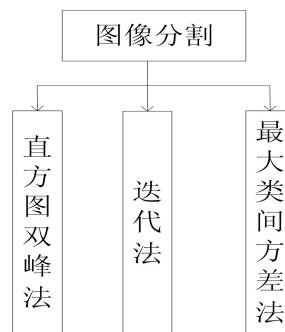


图 2-4 图像分割的算法

2.1.4 图像边缘提取

对于客观事物来说，人第一眼所看到的就是物体的大致形状，在数字图像处理中，图像的边缘特性最具有代表性，边缘提取就是对边缘方向，像素坐标等边缘信息的处理。边缘就是图像区域和另一个区域发生突变的边界，也就是图像灰度变换率最大的边界，我们在数学中称之为拐点。因此，边缘信息是图像分割时极为有用的特征，直接对图像分析的正确性产生影响。物体边缘信息的像素值有明显的差异，边缘信息的获取就是把灰度变化极大的位置信息提取出来，那如何提取边界信息的点集呢，本文中采用卷积或类似卷积的数学微分方法，通过找到数值跳跃性大的地方得到检测图像的边缘信息。几种常见的边缘检测算子^[29]如下图所示：

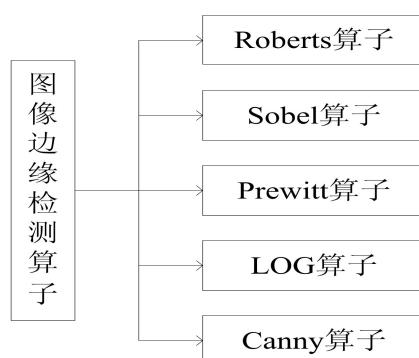


图 2-5 几种常见的边缘检测算子

2.2 相关理论研究

2.2.1 神经网络相关理论研究

人可以把外界接收到的讯号在其大脑中处理成有用信号，但是大脑进行分析、判断、综合、推理的过程是及其复杂的，我们又可以把大脑说成信息处理系统。现在这个社会人们一直在努力实现电脑模仿人的思维进行智能化信息处理的目标。人工神经网络就是其一，它在不同程度上对人的大脑进行模拟，但还是与人的大脑思维有一定的差距，随着年代的增加，神经网络对人大脑的模拟在更深一步的发展，神经网络模型在很多技术领域已经做出了很大贡献。

人工神经元的网络模型是一个多输入单输出的，其结构简单，功能较少、容易操作是最基本的信号处理单元^[30]，其模型^[30]如下图 2-6 所示。

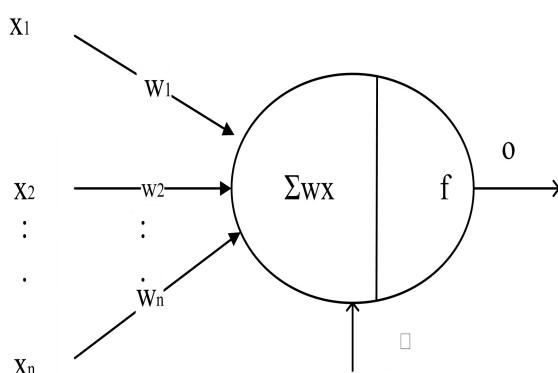


图 2-6 神经元模型

根据神经元的模型可知，图中的符号分别表示为： $X = (x_1, x_2, \dots, x_n)$ 是 n 个输入向量， $W = (w_1, w_2, \dots, w_n)$ 是 n 个分支的权值， $\sum WX$ 是激励函数值， θ 是神经元的阀值， o 是神经元的输出值，这些符号中的阀值 θ 不是一个固定不变的值，它会随着输出要求在不断改变，也称为偏置值。若输入信号 $X = (x_1, x_2, \dots, x_n)$ 和权值 $W = (w_1, w_2, \dots, w_n)$ 进行相应的乘加算法得到的值，如果超过一个额定数，则可以激活人工神经元，带动其开始工作，其输出公式为： $o = f(\sum wx - \theta)$ ，其中激活函数为 f 。传递函数的形式可以是线性也可以是非线性，其函数一般从如下阀值型、线性型、双曲函数型、分段线性型、Gaussian 函数型、Sigmoid 函数型中选择。

1) 线性函数公式如下：

$$f(x) = \alpha \cdot x \quad (2-1)$$

2) 分段线性函数公式如下：

$$f(x) = \begin{cases} \gamma, & x \geq \gamma \\ x, & |x| < \gamma \\ -\gamma, & x \leq -\lambda \end{cases} \quad (2-2)$$

3) Gaussian 函数公式如下:

$$f(x) = e^{-x} \quad (2-3)$$

4) 阈值型函数公式如下:

$$f(x) = \begin{cases} 1 & x \geq \theta \\ 0 & x < \theta \end{cases} \quad (2-4)$$

5) Sigmoid 函数公式如下:

$$f(x) = \frac{1}{1+e^{-x}} \quad (2-5)$$

6) 双曲函数公式如下:

$$f(x) = \frac{1-e^{-x}}{1+e^{-x}} \quad (2-6)$$

人工神经网络在处理数据信息时主要依靠神经元节点来完成，它不仅具有并行分布式结构，而且也是并行计算。模型结构如下图所示：

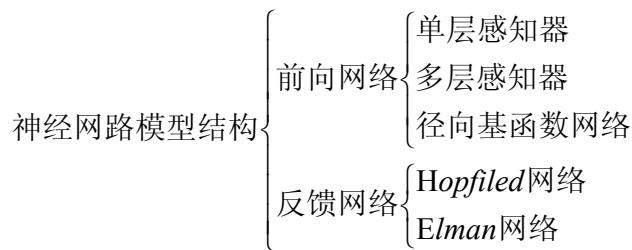


图 2-7 神经网络结构模型

无论哪种什么模型它们都具有并行处理、非线性运算的特点，因而他们具有运算快、适应性强、自组织的能力。

2.2.2 主成分分析相关理论研究

信息具有多元化和实时性特点，导致在对其进行提取、分析及处理时较困难。如果样本的两个变量因素具有相关性的关系，就可以统筹为信息叠加。在建筑工程中最终的中标总价与该项目的总体规划、材料款项及人工费、后期变更及签证有重要的相关性；在市场营销行业中，销售员的年终评价与自己的销售业绩，销售份额以及拥有的客户量存在较好的相关性。然而在信息大数据化的前提下，众多信息的相关性和错杂的信息重叠下，给许多的科学的研究以及信息提取带来了众多的不便。减少变量，去余求整，简化

信息，是最为简单明了的解决方案，但同时又会衍生一些附带问题，那就是信息的丢失和不完整。在现代这个社会，数据被广泛应用于各个方面，得到的真实数据之间也有很大的问题存在，会导致算法复杂性增加和泛化能力降低，这些问题表现为数据较集中、数据的不同特征间具有相关性、数据集的样本少样本特征多，因而需要寻求一种合适的方法去解决。

针对上面问题，研究者都在探讨一种既能有效的减少数据分析上变量的相关性又能保证信息的准确性的一种高效分析方法。通过查阅书籍、分析和试验，找到了一种科学而实用的方法主成分分析（Principal Component Analysis, PCA）法，它是通过数学变换的思想将一组具有线性相关的变量转化成一组线性不相关的变量，用少数的新数值去解释原来图像中大部分的数值，是一种降维的方法^[31]，并且广泛应用于各个领域。主成分分析法在识别和机器学习方面上已经应用，而且具有解决上述问题的能力，所以本文选用主成分分析算法进行课题相关研究手段。

主成分分析的中心思想是通过软件编程得到的少数主元来代替原来多个特征参数间的内部关系，将得到的主元重新组合成两两不相关的新变量^[32]。定义 x 是随机矢量是由 d 个均值为 0 的随机变量构成的， v 是一个 d 维单位向量。即

$$E(x) = 0 \quad (2-7)$$

$$v = \arg \max_v \text{var}(v^T x) \text{subject to } v^T v = 1 \quad (2-8)$$

$$\text{var}(v^T x) = E(v^T x x^T v) = v^T \sum \Sigma v \quad (2-9)$$

可以把上述问题转换成下面的式子进行探讨：

$$v = \arg \max_v v^T \sum \Sigma v - \lambda(v^T v - 1) \quad (2-10)$$

式 (2-9) 中 Σ 是 x 随机矢量的协方差矩阵。

对式 (2-10) 中的 v 进行求导运算就可以得到如下表达式：

$$\Sigma v = \lambda v \quad (2-11)$$

将式 (2-11) 带入到式 (2-9) 可以得到如下结果：

$$\text{var}(v^T x) = \lambda v^T v = \lambda \quad (2-12)$$

上述是单个主成分推导的整个过程，要想得到多个主成分就按照上述步骤进行推广。大量的事实证明在上述数学推理过程中可以用协方差矩阵 C 来近似代替随机矢量 x 的协方差矩阵 Σ 。我们定义样本矩阵 $X = [x_1, x_2, \dots, x_n]$ ，就可以用如下表达式进行代替。

$$\Sigma \approx C = \frac{1}{n-1} X X^T \quad (2-13)$$

主成分分析不仅可以消除指标间的相互影响、节省工作量，而且在对数据进行处理

的过程中不需要对参数进行选择，无需建立数学模型。但是它也存在一些缺点必须保证提取的几个主成分的方差之和达到一定的标准，并且提取到数据量应明显少于之前的原始数据量，这样才可以体现出算法的优越的特性。

2.2.3 核主成分分析相关理论

Karhunen 在 1947 年提出主成分分析后，由于其基础的数学分析算法，已经引起了人们广泛的关注，如在数学分析、图像处理、人口统计等领域中都有应用。利用这种方法进行计算，不仅速度快，而且识别率大大增加，但是主成分分析的最大的一个缺点是不能应用于非高斯分布中，无法对数据进行准确的提取。人们设想了很多方法，目的就是为了能够精确的提取到非高斯数据。经过多年的积累，核方法的理论已经渐渐的走上成熟，被应用于数学理论中。正交矩阵的理论由 David Hilbert 最先阐明，由 Mercer 在其基础上深入探讨，最后由 Aronszajn 进行归纳总结。当核方法的理论体系正式形成之后，在机器学习领域，由 Aizerman 学者最先提出将其计算应用到实际的工程中去，1995 年 Cortes 和其他学者就开始将核方法应用到矢量内积的求解中去，从此之后其一直备受人们关注，直到 1997 年，由 Bernhard Scholkopf 及其小组成员利用 Mercer 核的算法和主成分分析算法的结合方式提出了一种新的运算方法核主成分分析（Kernel Principal Component Analysis）^[33]，弥补了其他分析算法在数据提取上的不足。

核主成分分析和主成分分析之间既有类似又有差异，它们在理论基础上比较相近，只是核主成分分析在主成分分析的基础上多了一步非线性映射，它能够处理输入、特征空间中具有的非线性问题，但是最终实现需要主成分分析的线性代数做支撑，它是主成分分析的扩展。

核函数在不同的问题方面，所使用的处理方法不同，在线性问题方面样本数据的处理以数量积的方式呈现，在非线性问题方面样本数据的处理就需引进非线性映射函数。定义核函数 k ，核函数矩阵 K ，输入空间中数据点 x 、 y ，输入样本 x_i 、 x_j ， $\phi(x)$ 为非线性映射函数，样本的数量积为 $\phi(x_i)\phi(x_j)$ ，根据以上定义可以得到如下表达式：

$$k(x, y) = \phi(x)\phi(y) \quad (2-14)$$

$$K(x_i, x_j) = \phi(x_i)\phi(x_j) \quad (2-15)$$

核函数不但能够把多维空间中样本的数量积用式 (2-15) 进行转化替代，减少了计算量，提高了速度，从而避免了机器复杂运算等问题，而且在计算它时无需对 $\phi(x)$ 具体表达式进行了解。核方法的一般步骤如下图所示。

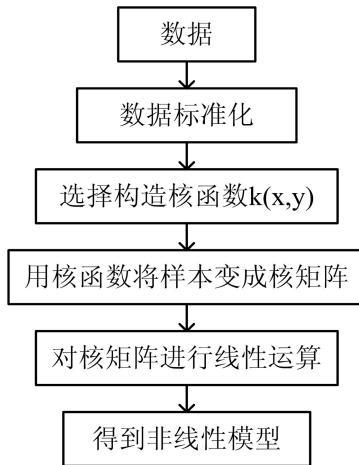


图 2-8 核方法示意图

在上述核方法的流程图中需要对核函数进行选择构造，现阶段，使用较为频繁的核函数有如下三种：

1) 多项式核函数：

$$k(x, y) = (x \cdot y + z)^m \quad (2-16)$$

2) 高斯核函数：

$$k(x, y) = \exp\left(-\frac{\|x - y\|^2}{2\sigma^2}\right) \quad (2-17)$$

3) Sigmoid 核函数：

$$k(x, y) = \tanh(x \cdot y + \kappa) \quad (2-18)$$

经过非线性映射函数映射到特征空间上的数据维数一般情况下是很高的，并且采用不同的核函数进行映射得到的维数是不同的，采用高斯方法比多项式方法得到的维数高出很多倍。

设定 n 个点 $\{x_1, x_2, \dots, x_n\}$ 是输入的样本集， f 记作特征空间，假设 $\sum_{i=1}^n \phi(x_i) = 0$ ，则中心化的特性就被凸显出来，特征空间中的点用如下表达式进行表达：

$$\bar{\Phi} = [\phi(x_1), \phi(x_2), \dots, \phi(x_n)] \quad (2-19)$$

根据核主成分的基本思想，要想得到最终的核主成的结果，在这一步需要按照主成分分析的步骤在 f 中计算协方差矩阵 \bar{C} 的特征值 λ 和特征向量 v ，其公式如下表示。

$$\bar{C} = \frac{1}{n} \sum_{i=1}^n \phi(x_i) \phi(x_i)^T = \frac{1}{n} \bar{\Phi} \bar{\Phi}^T \quad (2-20)$$

$$\bar{C} v = \lambda v \quad (2-21)$$

这是利用核成分的基本思想进行求解的步骤^[34]，但是根据已知的条件，非线性映射函数 $\phi(x_i)$ 没有给出具体值，根据式(2-20)无法求出协方差矩阵 \bar{C} ，更无法根据公式(2-21)

求出协方差矩阵 \bar{C} 的特征值 λ 和特征向量 v ，进而我们需要寻求一种新的办法来解决这个问题。

针对上面的公式，我们需要对其进行整理变形，得到如下公式。

$$v = \sum_{i=1}^n \frac{\phi(x_i)^T v}{n\lambda} \phi(x_i) \quad (2-22)$$

从式(2-22)，我们可以得知协方差矩阵 \bar{C} 的特征向量 v 是非线性映射的函数 $\phi(x_i)$ 的线性组合。定义线性系数向量为 $\alpha = [\alpha_1, \alpha_2, \dots, \alpha_n]^T$ ，我们就能够将其转换成如下公式。

$$v = \bar{\Phi} \alpha \quad (2-23)$$

$$\frac{1}{n} \bar{\Phi}^T \bar{\Phi} \bar{\Phi}^T \bar{\Phi} \alpha = \lambda \bar{\Phi}^T \bar{\Phi} \alpha \quad (2-24)$$

将式(2-24)用矩阵 k 来进行表示得到公式如下。

$$\frac{1}{n} k^2 \alpha = \lambda k \alpha \quad (2-25)$$

我们把 $\lambda^k = n\lambda$ 方程式，带入到式(2-25)进行转换得到如下关系式。

$$k^2 \alpha = \lambda^k k \alpha \quad (2-26)$$

接下来对式(2-26)进行化简处理得到如下公式。

$$k \alpha = \lambda^k \alpha \quad (2-27)$$

根据线性代数中特征值求解的定理和步骤，进而可以求出式(2-27)中的解。我们之前定义的特征向量 v 是单位向量，根据向量的性质我们可知 $v^T v = 1$ ，将式(2-23)前后同时乘以 v 的转置，转换成如下表达式。

$$\alpha^T k \alpha = 1 \quad (2-28)$$

结合公式(2-27)我们又可以得到如下表达式。

$$\alpha^T \alpha = \frac{1}{\lambda^k} \quad (2-29)$$

继而我们可以求出核矩阵 K 的特征向量 u 和特征值 λ^k ，根据其值我们可以得到如下表达式 α 的值。

$$\alpha = \frac{u}{\sqrt{\lambda^k}} \quad (2-30)$$

我们利用上步求出的核矩阵 K 的特征值 $\lambda^k = \{\lambda_1^k, \lambda_2^k, \dots, \lambda_k^k\}$ 和特征向量 $u = \{u_1, u_2, \dots, u_k\}$ ，进而就可求出协方差矩阵 \bar{C} 所对应的特征向量 $v = \{v_1, v_2, \dots, v_k\}$ ，根据如下公式进行求解：

$$v_i = \bar{\Phi} \alpha_i \quad (2-31)$$

$$\alpha_i = \frac{u_i}{\sqrt{\lambda_i^K}} \quad (2-32)$$

根据定义的 $K_t = [\phi(x_1)^T \phi(t), \phi(x_2)^T \phi(t), \dots, \phi(x_n)^T \phi(t)]^T$ 为列向量，我们可以得到如下表达式。

$$v_i^T \phi(t) = \alpha_i^T \Phi^T \phi(t) \quad (2-33)$$

$$v_i^T \phi(t) = \alpha_i^T K_t \quad (2-34)$$

通过以上表达式我们可以总结出在核主成分分析公式推导中，所有步骤中都能运用 f 中的数量积进行运算的，无需对非线性映射函数进行求解，解决了基本理论推导上无法解决的问题。

在上面求解协方差矩阵的特征值和特征向量的前提下，假设点是具有中心化的特性，但是在应用过程中，实际情况是在求解时需要我们自己来完成这一步。我们设 f 的中心点为 δ ，中心化的核矩阵为 \bar{K} ，单位对角矩阵 I ，设 $K = \Phi^T \Phi$ ，可以得到如下表达式。

$$\delta = \frac{1}{n} \Phi I \quad (2-35)$$

$$\bar{K} = (\Phi - \delta I^T)^T (\Phi - \delta I^T) \quad (2-36)$$

$$\bar{K}_t = (\Phi - \delta I^T)^T (\phi(t) - \delta) \quad (2-37)$$

通过以上表达式我们得到了中心化之后值，进而我们就可以按照之前的步骤进行求解。

2.3 本章小结

本章简要论述了课题中所应用到的一些图像处理基本理论概念，介绍了图像处理技术中的图像滤波、图像增强、图像分割、图像边缘提取等理论知识，接着介绍人工神经网络、主成分分析和核主成分分析的发展史及其基本概念，最后根据实际需要选择适合的方法进行研究。

第三章 埋弧焊焊缝缺陷图像的采集与处理

作为分析、评定焊接质量标准的唯一媒介——焊缝图像，其标准的高低将对焊接缺陷的辨识和分析结果产生质的影响。焊缝缺陷识别的是以样本图像展开的图像处理为中心和切入点。

3.1 X 射线焊缝缺陷图像采集系统的建立

X 射线在穿过被检测的样本时会出现一定程度的信号衰减，通过信号衰减比例来确定被检测的样本中是否含有缺陷，但是不同的样本素材对 X 射线的衰减影响和吸收程度有差异，进而可以得到黑度不一样的射线底片，有利于后续检测人员的对其进行判断。X 射线检测主要用于焊、铸件的检测^[35]。

数字化成像必须以可靠地计算机硬件系统作为基础，X 射线焊缝底片成像系统及其硬件结构如图 3-1 所示。



图 3-1 焊缝硬件结构采集

当 X 射线源穿过待测样本时，会出现一定程度的衰减，将这种衰减之后的 X 射线照射到图像增强器上，最后运用 CCD 摄像机将图片传入电脑中，完成焊缝缺陷图像的硬件采集过程。

3.1.1 CCD 摄像头

电荷耦合器（CCD）是一种新型的半导体成像器件，它不仅能够将光线转换成电荷功效而且还具有将电荷进行存储和转移的功效。CCD 由于尺寸小、精度高、灵敏性强、低功耗、寿命长、可靠性高等优越性，适用于图像的在线检测，一直被人们所应用，并且发展迅速^[36]。

样本采集过程中 CCD 摄像机在硬件结构中起着关键性作用，本文采用的是大恒图像公司 DH-SVxlGx 这一种类中的 DH-SV1411GM 数字摄像机，如图 3-2 所示。



图 3-2 DH-SV1411GM 摄像机

上图 3-2 中的摄像机，它的分辨率为 140 万像素，在此分辨率下可以输出 8 位灰度图像，另外该摄像机支持连续采集和触发采集的方式、支持热插拔、支持 Windows/Linux 系统、支持多种开发工具，配置了 3 入 3 出 IO，具有高精度、低噪声、传输速率快、占用内存低等优点。

数字相机采用高性能索尼 ICX285 CCD 芯片，能够达到 X 射线埋弧焊焊缝图像采集的标准，传输速率以一秒 1GB 的速度传输，传输距离较远，其传输效率符合企业要求，并且它已经普及到工业工程、监控设备、图片检测等各个方面。

3.1.2 图像采集的结果与存取

经过数字化成像之后的图像在计算机中的存储类型为 BMP 或者 JPEG 格式，但是 JPEG 存储格式存在一定的局限性，而 BMP 格式在某些方面优于 JPEG 格式，对比如表 3-1 所示。

表 3-1 图片存储类型的对比

图片的存储类型	特点
BMP 格式	无损存储、采集的图像信息较全面、不支持压缩形式、占用磁盘空间大、格式简单、可靠性高
JPEG 格式	支持最高级有损压缩、占用磁盘空间小、容量小、存储单个光栅图像

根据表 3-1 所示，由于格式上具有一些特点不利于对采集的焊缝缺陷图像进行存储，所以本文采用的无压缩的 BMP 格式对图像进行存储。BMP 图像是位图（Bitmap）的简称，它是 Windows 系统中储存文件最常用的格式，其中 24 位的 BMP 图像文件无法压缩占据很大内存空间，但是图像信息是最完整的^[37]，综上，得到的缺陷图片格式：24 位 768×576 的 BMP 图像。采集到检测图像如图 3-3 所示。

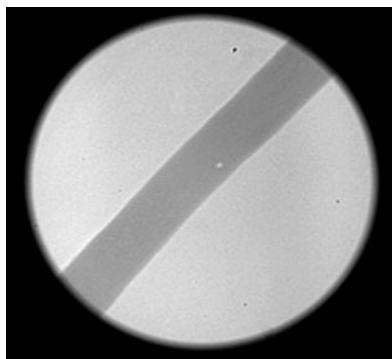


图 3-3(a) 气孔射线检测采集图

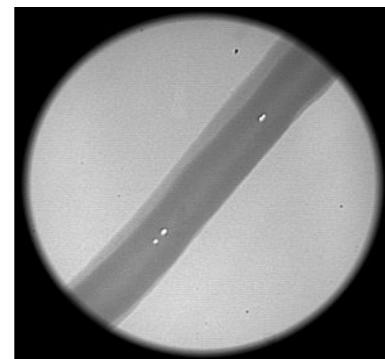


图 3-3(b) 气孔射线检测采集图

从射线检测采集图中，利用 MATLAB 编程裁剪掉埋弧焊缺陷图像中不感兴趣的部分，保留图像感兴趣的部分，得到以下处理图像。

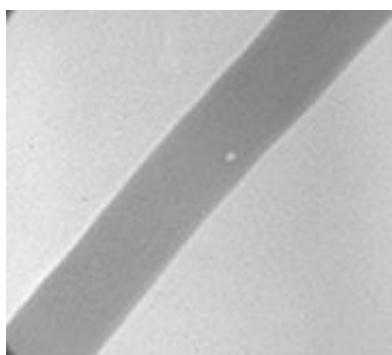


图 3-4 (a) 气孔的处理图像

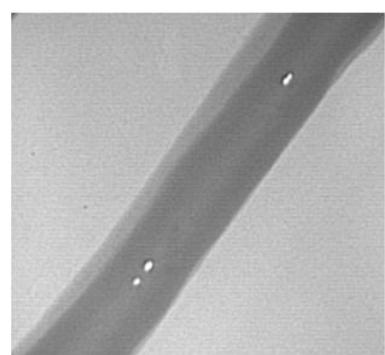


图 3-4 (b) 气孔的处理图像

在埋弧焊焊缝缺陷图像的探讨中，采集到的图像不是很多并且提取到数据也不是很大，因此采用较小的数据库对埋弧焊焊缝缺陷检测图像进行存取，本文首先将需要处理的图像数据存储到计算机中，然后根据数据存放的路径进行图像数据的输入。

3.2 焊缝图像处理系统

X 射线在经过不同厚度的待测样本时，穿过样本后的射线会随着样本厚度的增加而减弱，会导致检测对象的对比度不同，加大了埋弧焊焊缝缺陷提取和分割的困难。除此之外，在其处理的过程中，会产生额外的一些噪声，在被检测图像中呈现为高亮的白点，参合在缺陷中，在图像识别的过程中缺陷的漏检和误检现象会随时发生，加大了图像识别的难度，因此需要对图像中高亮的白点进行去除，为后续的建模提供保证。

图像处理这门技术已经在很多领域得到了快速发展，很多的专家学者经过长时间的积累、研究现已提出了各种各样的算法，例如图像降噪和图像增强等，这些算法已经被我们所熟悉，而且也在不断的进行优化，使得算法的识别率更加准确。针对检测图像中焊缝的分离，通常采用图像滤波、增强、分割、边缘提取等步骤来实现，由于在检测的焊缝图像中隐藏着各种复杂因素的影响，找到一种适合所有焊缝图像的提取与分割的办法是非常困难的，所以在图像处理期间遇到的一些难题要善于转变思想、学会灵活运用。

本文针对采集到的原始埋弧焊焊缝图像采用一套准确率高的图像处理技术实现焊缝缺陷的分割，得到焊缝缺陷样图，其流程如下图所示。

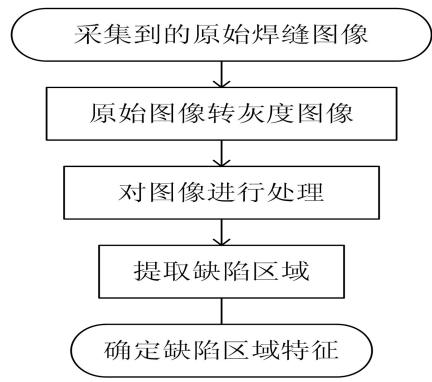


图 3-5 图像预处理流程图

首先对采集到的原始焊缝图像进行灰度化转换，然后在图像处理中的针对遇到的各种问题根据查阅的资料、书籍采取不同的算法，进而提取出整幅图的焊缝区域，再次在焊缝区域内通过对图像进行灰度曲线分析的方法实现缺陷定位，最终提取缺陷区域。

3.2.1 确定焊缝区域(ROI)

本文主要针对焊缝缺陷进行研究，所以只需要研究感兴趣的部分即焊缝缺陷，如果对整幅图进行研究不仅耗费时间，而且检测效果也不高。因此只需要考虑把 X 射线检测图像的背景剔除，提取焊缝区域 (ROI)，最后在对其进行检测和判断。焊缝区域提取如下所示。

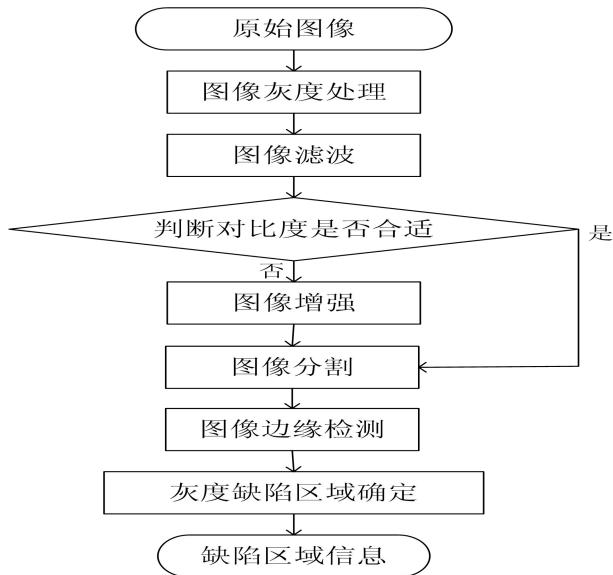


图 3-6 焊缝区域提取

首先对图像进行灰度转化处理，将焊缝的 BMP 图像转换为灰度图像，即将原来由多种灰度值构成的图像转换成 8 位灰度值图像，然后通过滤波处理来排除干扰，紧接着对滤波之后的图像进行对比度的判别。当对比度低于一定的标准时，需要进行图像增强处

理, 然后, 利用图像分割算法实现背景与焊缝的分割, 最后, 利用边缘检测方法获得焊缝边界信息。

1) 24 位真彩图转换成 8 位灰度图

X 射线检测图像采集到计算机之后以 24 位真彩图的形式存在, 图像中颜色越多所包含的数据信息量越大, 对样本分析起来就越复杂, 不利于后续步骤的判断, 而灰度图像只有亮度差异, 即黑与白之间的灰度区分, 使过程变得简便可行。真彩图图文件中没有调色板, 它的像素矩阵是 RGB 值; 灰度图有调色板, 它的像素矩阵是调色板的索引值。24 位真彩图转换成 8 位灰度图, 转换公式如 (3-1) 所示^[38]。

$$Gray = R \times 0.229 + G \times 0.587 + B \times 0.114 \quad (3-1)$$

式 (3-1) 中 B 表示为蓝色分量, G 表示绿色分量, R 表示为红色分量, $Gray$ 表示为图像转换后相对应的灰度值。转换后如图 3-7 所示。

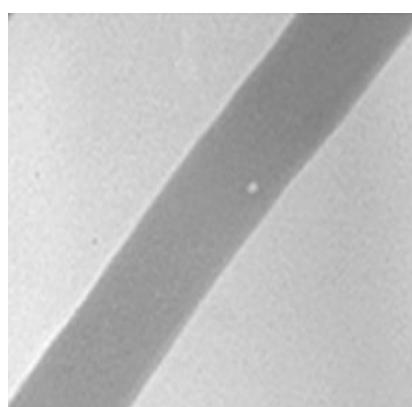


图 3-7(a) 气孔灰度图像

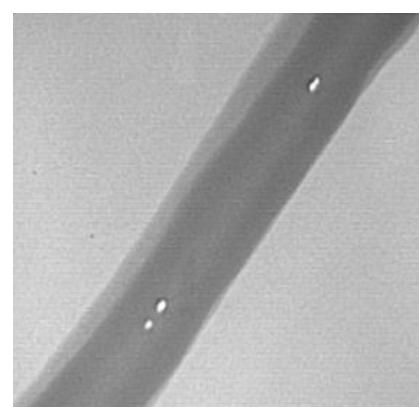


图 3-7(b) 气孔灰度图像

2) 图像滤波

图像噪声是在图像输入、采集、处理、发送、接收、输出的过程中产生, 使得图像的质量降低, 为后续图像处理带来很大的不利因素。表 3-2 不同滤波方法对比的特点:

表 3-2 中值、均值滤波对比

方法	特点
中值滤波	对异常值不敏感、图像清晰度增强、有效去除脉冲噪声
均值滤波	处理速度快、数学处理方法简单、减弱噪声、平滑图像

中值滤波器是使用一个带有奇数个数值点的平滑算子窗口, 如窗口有奇数个数值点, 并且数值点是从小到大的顺序排列, 中值就最中间那个值^[39]。本课题分别采用不同的平滑算子 H 对处理的样本进行降噪, $f_{a,b}$ 为原来像素点 (a,b) 的灰度值, $y_{a,b}$ 为转换后像素点的灰度值, 下式 (3-2) 为 3*3 平滑算子 H 公式。

$$H = \begin{bmatrix} f_{a-1,b-1} & f_{a-1,b} & f_{a-1,b+1} \\ f_{a,b-1} & f_{a,b} & f_{a,b+1} \\ f_{a+1,b-1} & f_{a+1,b} & f_{a+1,b+1} \end{bmatrix} \quad (3-2)$$

$$y_{a,b} = Med \{f_{a-1,b-1}, \dots, f_{a,b}, \dots, f_{a+1,b+1}\} \quad (3-3)$$

均值滤波算法^[40]是将待处理的像素点(m, n)放置在一个3行3列的模板中心，将其自身像素值和邻近的8个像素点的像素值相加并取平均值作为待处理像素点的灰度值，根据以上原理遍历整幅图图像的像素，采用 3×3 模版方法进行处理，如下图3-8所示：

a	b	c
d	$Y(m,n)$	f
g	h	i

图 3-8 3×3 模板

本文分别采用上述两种方法进行比较，用 MATLAB 编程结果如图 3-10 所示。

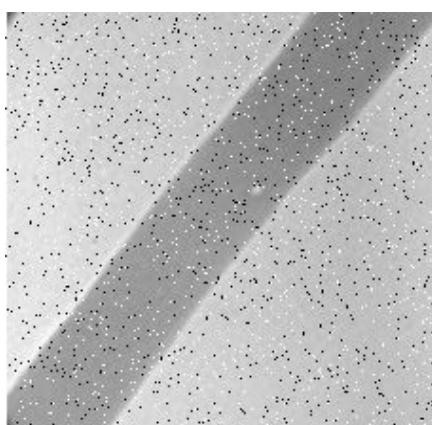


图 3-9(a) 添加椒盐噪声图像

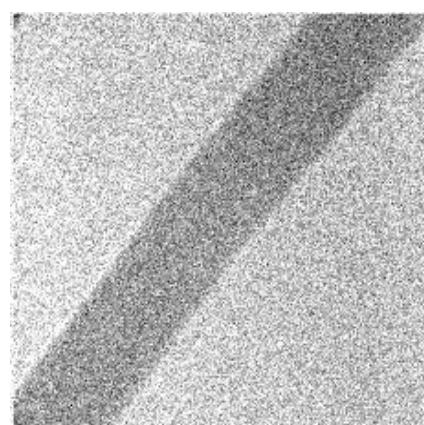
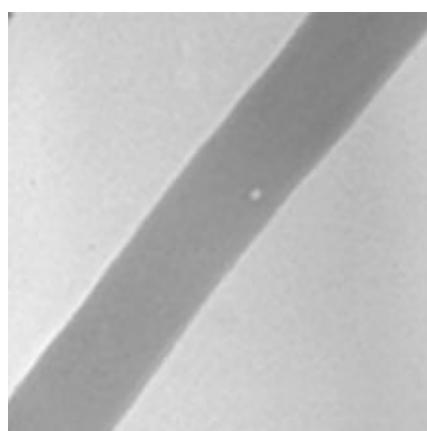
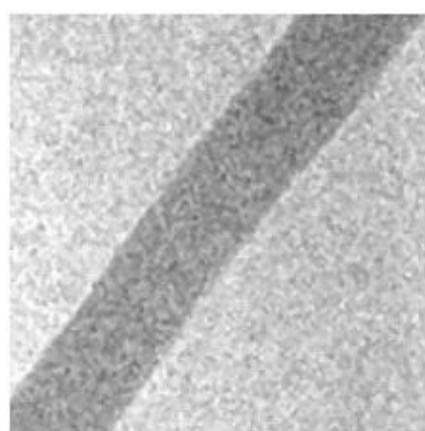


图 3-9(b) 添加高斯噪声图像

图 3-10(a) 椒盐 3×3 中值滤波图像图 3-10(b) 高斯 3×3 中值滤波图像

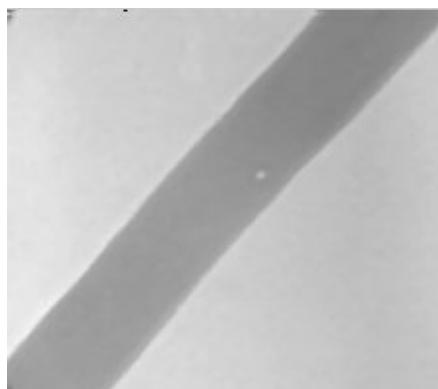


图 3-10(c) 椒盐 5*5 中值滤波图像

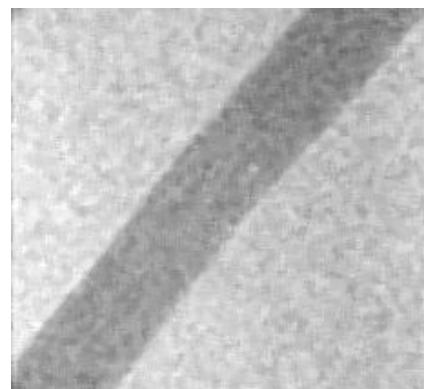


图 3-10(d) 高斯 5*5 中值滤波图像



图 3-10(e) 椒盐 7*7 中值滤波图像

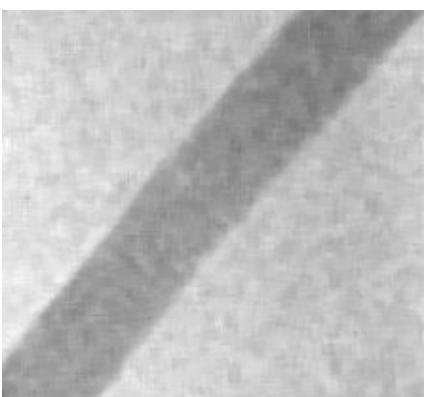


图 3-10(f) 高斯 7*7 中值滤波图像



图 3-10(g) 椒盐 9*9 中值滤波图像

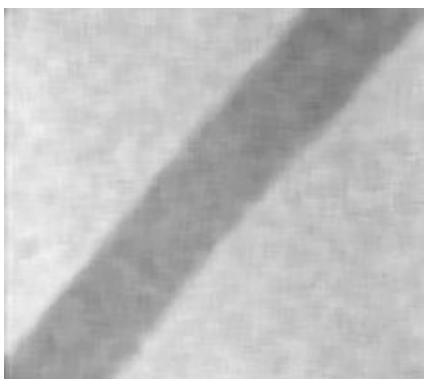


图 3-10(h) 高斯 9*9 中值滤波图像

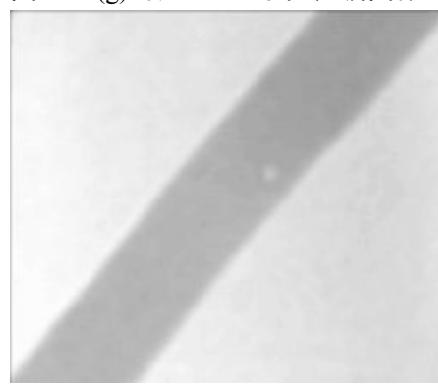


图 3-10 (i) 椒盐噪声均值滤波图像

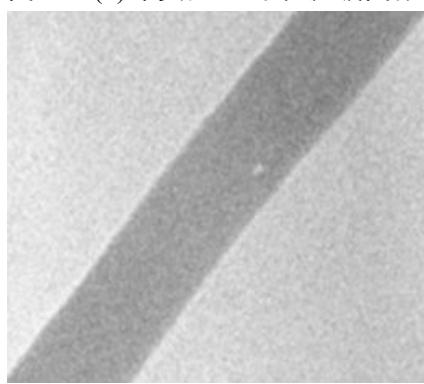


图 3-10 (j) 高斯噪声均值滤波图像

首先分别对图 3-7 (a) 添加椒盐噪声、高斯噪声，用 MATLAB 编程得到 3-9 所示的

样本图，然后分别对图进行中值、均值处理，得到图 3-10 结果，根据图 3-10 (i) (j) 处理图可以看出均值滤波对高斯噪声的去除比对椒盐噪声的去除处理效果较好一些；根据图 3-10 中 (a)、(b)、(c)、(d)、(e)、(f)、(g)、(h) 处理图可以看出中值滤波对消除椒盐噪声的效果比对消除高斯噪声的效果较好。所以针对不同噪声污染的图像样本，选用合适的方法去排除。

3) 图像对比度检测

焊缝检测图像的采集过程中，受诸多因素的影响，使缺陷样图的对比度相差不大，进而图像分辨起来比较困难，对焊缝分割产生了一定的影响，所以在对焊缝检测图像进行分割时需要对那些对比度比较差的图片进行增强算法编程，提高辨识度。

灰度直方图 (histogram) 是最简单的工具之一，用来判断图像的分布是否均衡，从数学上说它是一个关于灰度级的分布函数，它的横坐标是灰度级别或灰度值，纵坐标是各个灰度值或灰度级别的像素在图像中出现个数的累加，也是最有用的绘图统计信息工具。如果检测图像的对比度较高其灰度直方图应该呈现双峰型；检测图像的对比度较低，其灰度直方图则会渐变成单峰型，就对图像前景的分割造成一定的影响。用 MATLAB 编程画出对比度较弱的图像的灰度直方图如下 3-11(b) 所示：

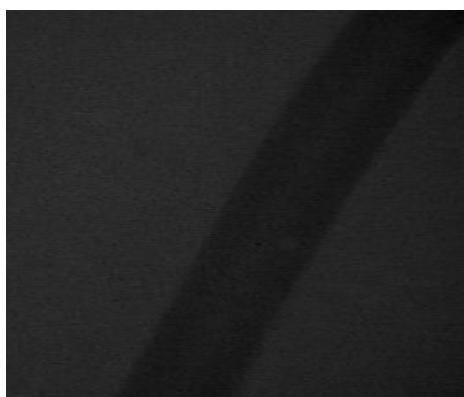


图 3-11 (a) 灰度低的缺陷图像

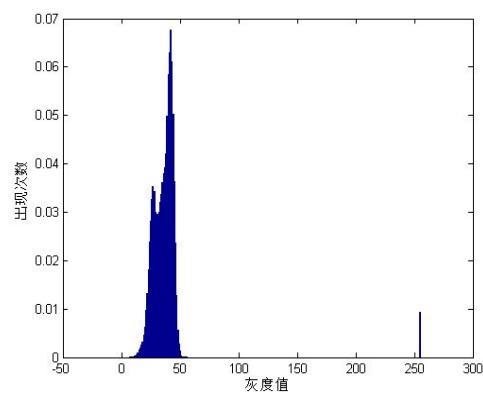


图 3-11(b) 灰度低缺陷图像直方图

经大量实验证明，当一幅样本图片中的灰度像素个数不低于 150 个时，就能够达到最低标准要求，不需要图像增强这一步骤，直接就可以对图像进行分割处理。上图所示灰度直方图对比度达不到要求，出现单峰情况，需要对其对比度进行增强处理。

4) 灰度变换的图像增强

图像对比度增强不仅使原来模糊的图片变得清楚，而且转换成的图像更易于人和计算机判断。其目的是突出图像中的有用信息部分，使其有各自的特点，转变成的图像更容易让人观察和判断，提高对图像的分析理解能力。由于采集到的 X 射线焊缝图像在灰度直方图中，它的灰度级分布情况是焊管区域的灰度级集中在图像靠右的区域其灰度值相对较高，焊缝区域的灰度级集中在图像靠左的区域其灰度值相对较低，如果检测图像

的焊缝区域和焊管区域的灰度值相差不大，在灰度直方图上就集中分布到一个区域，这时就需要对焊缝灰度分布图进行拉开扩展，将原来集中在一个区域的灰度级扩充开来，使其充满整个灰度级或者是按照一定规则进行扩充，提高图像的对比度。

灰度变换能够使图像动态范围增大，它是通过使用不同的灰度变换函数扩充分布，不改变其内部空间结构^[41]。它分为线性变换和非线性变换，线性变换分为一般性和分段性；非线性变换分为对数、指数、sin 函数等^[42]。线性灰度变换可以借助直线的几何意义来进行描述，假设其中 $f(x,y)$ 是变换前像素的灰度值，其范围 $[a,b]$ ，为 $g(x,y)$ 是变换后像素的灰度值，其范围为 $[c,d]$ ，其数学表达式为：

(1) 一般线性变换函数的变换方程如下所示：

$$g(x,y) = \frac{d-c}{b-a} \times [f(x,y) - a] + c \quad (3-4)$$

(2) 分段性变换函数方程如下所示：

$$g(x,y) = \begin{cases} c \\ \frac{d-c}{b-a} \times [f(x,y) - a] + c \\ d \end{cases} \quad (3-5)$$

(3) 非线性变换指数函数方程如下所示：

$$g(x,y) = b^{f(x,y)} \quad (3-6)$$

式 (3-6) 中 b 为底数，是可调参数。为了增加变换的动态范围，在上式 (3-6) 中添加一些参数来使曲线的初始位置和曲线的坡度得到调整， a, c 都是可调参数。

$$g(x,y) = b^{c \times [f(x,y) - a]} - 1 \quad (3-7)$$

(4) 非线性变换对数函数方程如下所示：

$$g(x,y) = \lg[f(x,y)] \quad (3-8)$$

式 (3-8) 中 \lg 是以 10 为底，为了增加变换的动态范围也可以选用 \ln 是以 e 为底，在上式 (3-8) 中添加一些参数来使曲线的初始位置得到调整，其中 a, b, c 都是可调参数。

$$g(x,y) = a + \frac{\ln[f(x,y) + 1]}{b \times \ln c} \quad (3-9)$$

(5) 非线性 Sin 函数的变换方程如下所示：

$$g(a,b) = 127 \{1 + \sin[(\pi * f(a,b)/(m-n)) - (\pi * (m+n)/2 * (m-n))] \} \quad (3-10)$$

式 (3-10) 中 m 变换前最高灰度值， n 是变换前最低像素灰度值，最低像素灰度值， $n \leq f(a,b) \leq m$ ，则 $n \leq g(a,b) \leq m$ 。

五种函数的灰度转换图如下图 3-12 (a) (b) 所示。

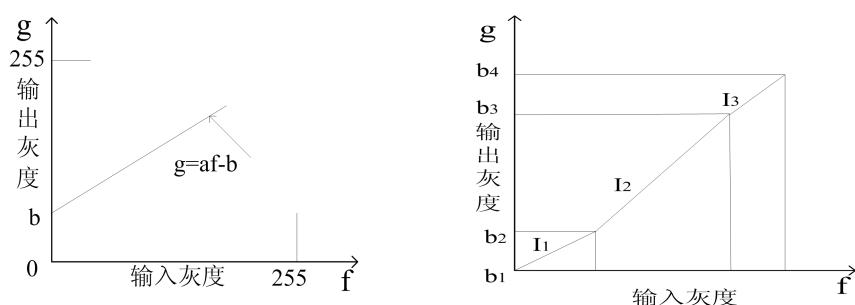


图 3-12 (a) 线性函数变换

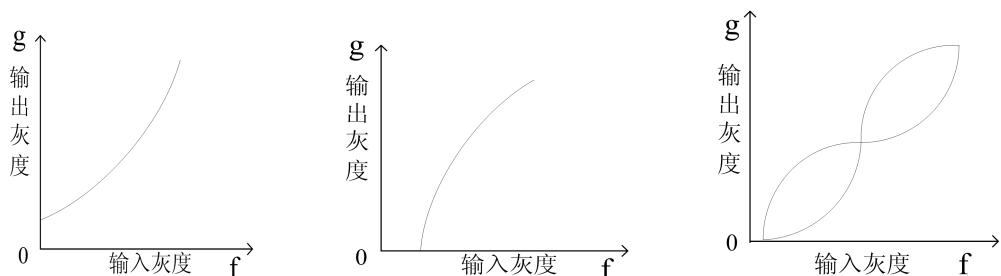


图 3-12(b) 非线性函数转换

直方图规定化的原理是依据灰度映射函数，使图像按照人的意愿去改变。假设 $P_r(V)$ 是原始图像的灰度概率密度函数， $P_z(Z)$ 是期望的灰度概率密度函数， S 原始图像灰度级， Z 期望的图像灰度级，其公式为：

$$S = T(r) = \int_0^r P_r(V) dV \quad (3-11)$$

$$V = G(Z) = \int_0^z P_z(Z) dz \quad (3-12)$$

$$Z = G^{-1}(V) \quad (3-13)$$

本文利用四种变换分别对图 3-11(a)在 MATLABR2012b 环境下进行编程，输出增强后的图像和直方图，对其进行观察，其结果如下所示：



图 3-13 (a) 线性变换增强图片

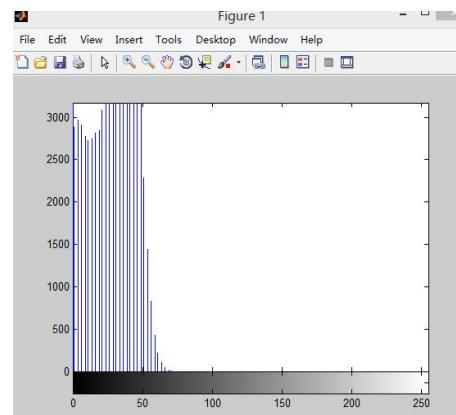


图 3-13 (b) 线性变换增强直方图



图 3-13 (c) 对数变换增强图片

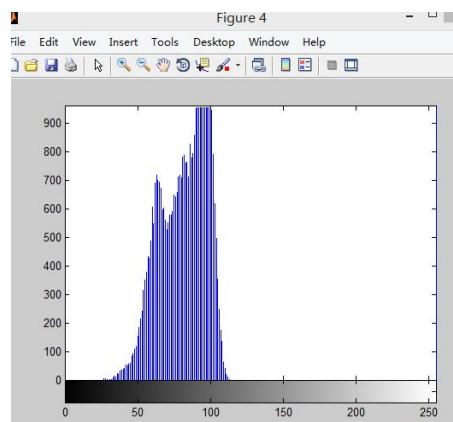


图 3-13 (d) 对数变换增强直方图

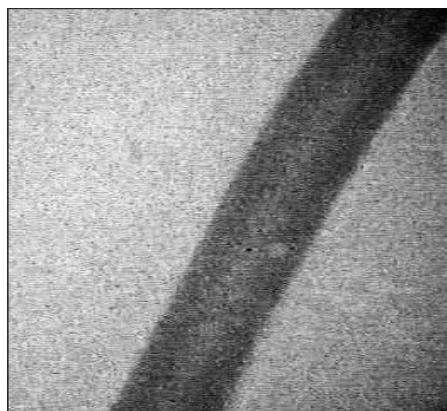


图 3-13 (e) sin 函数变换增强图片

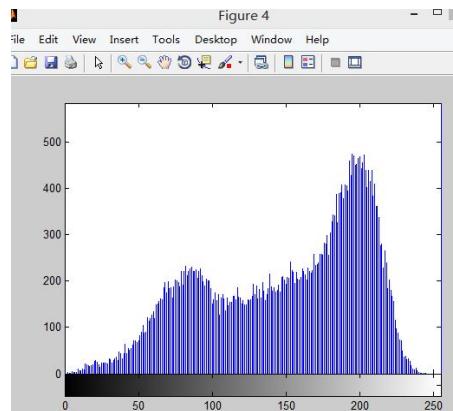


图 3-13(f)sin 函数变换增强直方图

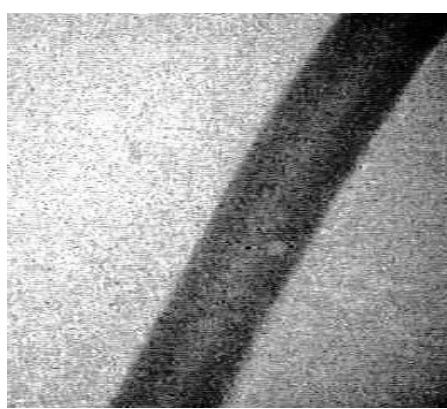


图 3-13 (g) 直方图规范化增强图片

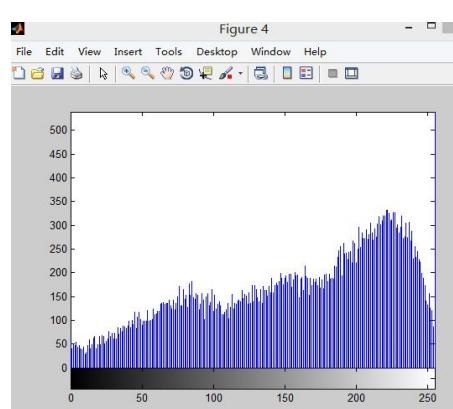


图 3-13(h) 规定化增强直方图

由图 3-13 (a)、(b)、(c)、(d) 可知，通过线性函数、对数函数增强后的图像在视觉上看起来比原来清晰一些，但是调整后的直方图分布还是比较集中不能够达到期望要求，但是由图 3-13 中的(e)、(f)、(g)、(h) 可知，sin 函数和直方图规范化增强后的图像清晰度高，其灰度直方图也呈现双峰型，其焊缝区域和背景区域的对比度明显得到了改善。经过上述步骤处理后的图像排除了噪声的污染，图像的某些重要特征也凸显出来，进而可以继续完成以下操作。

5) 阈值分割

直方图双峰法是通过对样本的直方图进行探讨的方法来实现前景目标和背景的分割，当被检测的图样的直方图出现明显的波峰波谷时，我们把处于波谷处点的值作为阈值，这样分割出的样图不仅精度较高而且效果也好。当样图的波峰波谷不明显或者没有时，这时采用直方图双峰法对样图的分割效果较差，这时我们就需要选取另一种有效的分割方法—最大类间方差法，它是在最小二乘法的原理上推导出来的，它取得某个阈值是前景和背景两大类类间方差的最大值，其间考虑了像素邻近以及图像整体灰度分布等多种因素。从识别的角度看，适当的阈值使不同类别数据间的方差越大越好，同类别数据间的方差越小越好，这样就能够拉大不同类别之间的差距，缩小同类别之间的差距；并且适当的阈值产生的效果能够实现前景与背景区域的分割^[43]。

设图像包含 L 个灰度级， N 为像素的总个数，灰度级为 i 的像素点数 n_i ，图像公式为：

$$N = n_0 + n_1 + \dots + n_{L-1} \quad (3-14)$$

p_i 表示原始图像在第 i 个灰度级的概率公式为：

$$p_i = n_i / N \sum_{i=0}^{L-1} p_i = 1 \quad (3-15)$$

设 u_0 目标像素的平均灰度， u_1 背景像素的平均灰度； w_0 前景像素点数占整幅图的比例， w_1 背景像素点数占整幅图的比例；前景和背景的分割阈值为 t 将灰度级分为两类。

c_0 的概率公式为：

$$w_0 = \sum_{i=0}^t p_i u_0 = \sum_{i=0}^t i p_i / w_0 \quad (3-16)$$

c_1 的概率公式为：

$$w_1 = \sum_{i=t+1}^{L-1} p_i u_1 = \sum_{i=t+1}^{L-1} i p_i / w_1 \quad (3-17)$$

u 整幅图的平均灰度值公式为：

$$u = w_0 u_0 + w_1 u_1 \quad (3-18)$$

类内方差公式为：

$$\sigma_w^2 = w_0 \sigma_0^2 + w_1 \sigma_1^2 \quad (3-19)$$

类间方差公式为：

$$\sigma_w^2 = w_0 (u_0 - u)^2 + w_1 (u_1 - u)^2 \quad (3-20)$$

总体方差公式为：

$$\sigma_T^2 = \sigma_B^2 + \sigma_w^2 \quad (3-21)$$

t^* 阈值公式为：

$$t^* = \operatorname{Arg} \max_{0 \leq t \leq l-1} [w_0(u_0 - u)^2 + w_1(u_1 - u)^2] \quad (3-22)$$

其分割图像的具体步骤是：

- (1) 设整幅图的阈值 t 为初始值，执行循环操作。
- (2) 计算当前的平均灰度 u
- (3) 计算其类间方差，根据上式取它最大时对应的灰度值为最佳分割阈值。
- (4) 根据阈值 t 进行二值化，输出图像。

按照上面的步骤用 MATLAB 编程进行分割处理，得到如下结果。

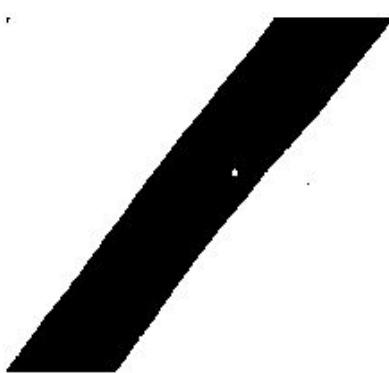


图 3-14 (a) 直方图双峰法分割图片

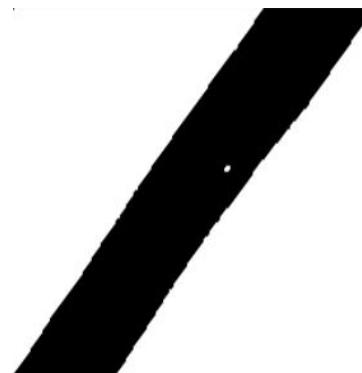


图 3-14 (b) 最大类间方差法分割图片



图 3-14 (c) 直方图双峰法分割图片

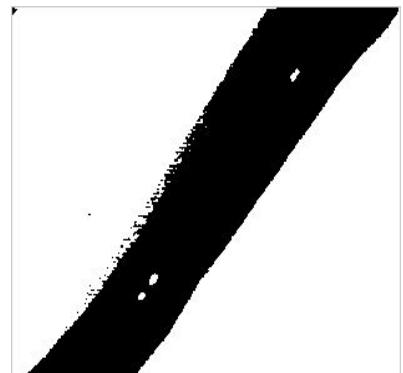


图 3-14 (d) 最大类间方差法分割图片

直方图双峰分割法它通过人手动设置阈值输出图像，图像分割的好坏需要人眼去观察分析，最终选择适合的阈值，不同的是最大类间方差法分割法它不需要人手动设置阈值，而是自动去选择，输出图像，所以针对不同的样本选择适合的方法进行处理。

6) 图像边缘检

对 X 检测焊缝图像进行均值滤波和分割之后，焊缝区域的基本形状已经显现出来，满足了从视觉上对焊缝区域的提取，但是从实际角度来说，并没有获得焊缝边界的信息。图像的边缘隐藏很多信息，因此可以利用边缘检测来对图像进行分隔，以此来获得焊缝边界的准确信息。经过分割之后的 X 射线焊缝图像边缘灰度不连续表现为阶跃型，背景区域的灰度值为 255，目标区域的灰度值为 0，根据这一特点，对图像的各像素点求一阶

或二阶微分，进而定位到图像的边缘信息。常见的微分算子有很多它们的特点如下表所示。

表 3-3 不同边缘算子的比较

边缘检测算子	含义及其特点
Roberts 算子 ^[44]	采用梯度幅值检测相互垂直方向的效果好于其它方向，有精准的定位、需要通过滤波降噪、适合低噪声图像。
Sobel 算子	采用离散差分计算梯度，Sobel 算子比较简单，运行速度快，做了加权处理，对噪声有一定的抑制作用，提取轮廓模糊。
Prewitt 算子	利用水平、垂直两个模板与图像进行卷积运算，不仅可以检测到边缘点，而且还对抑制噪声污染有显著的效果。
Canny 算子	Canny 算子采用一阶偏导的有限差分进行计算，Canny 算子较其他算子检测的效果好，但是它检测过程比较麻烦。

Roberts 算子边缘检测模板如下所示：

$$G_x = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \quad G_y = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$$

采用范数 1 衡量梯度的幅度：

$$|G(x, y)| = |G_x| + |G_y| \quad (3-23)$$

Sobel 算子两个模板如下所示：

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \quad G_y = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$$

采用范数衡量梯度的幅度：

$$|G(x, y)| = \max(|G_x|, |G_y|) \quad (3-24)$$

Prewitt 算子两个模板如下所示：

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} \quad G_y = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{bmatrix}$$

采用范数衡量梯度的幅度：

$$|G(x, y)| \approx \max(|G_x|, |G_y|) \quad (3-25)$$

本文分别用这四种不同的边缘检测算子进行边缘检测之后，得到了如图 3-15 所示，提取了焊缝的边缘。

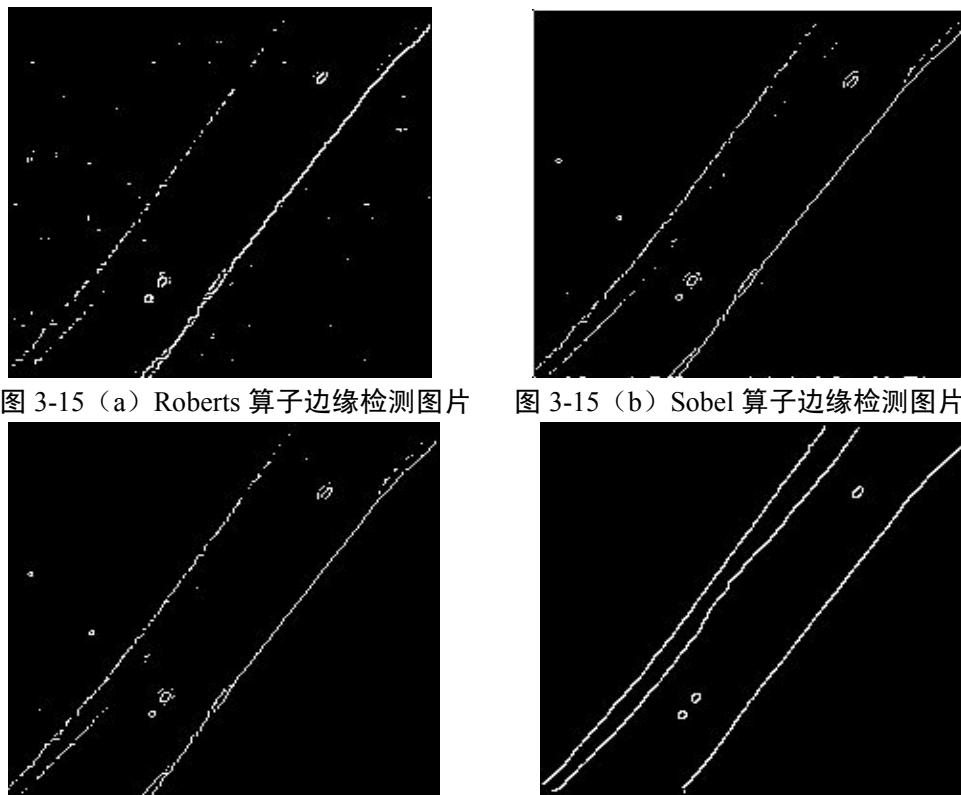


图 3-15 (a) Roberts 算子边缘检测图片 图 3-15 (b) Sobel 算子边缘检测图片

图 3-15 (c) Prewitt 算子边缘检测图片 图 3-15 (d) Canny 算子边缘检测图片

根据 Matlab 各种算法仿真结果图 3-15 中 (a) (b) (c) (d) 可以看出, Roberts 算子检测方法不利于噪声的抑制, 利用它提取的边缘比较粗, 容易丢失一部分边缘信息, 定位不准确。Sobel 算子检测方法对抑制噪声有一定的作用, 但是对边缘定位不是很准确, 不能够将前景和背景隔开来。Prewitt 算子检测方法对噪声较多的图像处理效果较好, 但是得到的图像边缘比较宽, 而且间断点也比较多。Canny 算子方法对噪声的抑制效果最好, 并能够检测到清晰边缘, 是这几种算子中最实用的方法。

3.2.2 基于灰度曲线分析的焊缝缺陷定位

本文中为了对感兴趣的部分进行特征提取与主成分分析, 需要将这些有用信息从检测图像中提取出来, 这是图像处理到图像分析的关键。通过图像预处理将焊缝区域信息确定之后, 便缩小了焊缝区域中焊缝缺陷的查找范围, 只需要对焊缝区域内的缺陷定位, 便可提取到图像中的特征参数^[45]。

在检测图像中确定焊缝缺陷的位置是识别图像缺陷的前提条件。经过预处理之后的样图, 在不含有缺陷的基础上, 背景区域和目标区域的对比度相差不大, 即使有噪声污染, 其灰度值上下摆动的幅度也相对平缓, 灰度函数图像中也没有明显的波峰、波谷出现; 当有缺陷存在时, 灰度函数图像中波峰、波谷状态较为显著^[46]。根据灰度函数的性质, 通过行、列灰度函数的图像就可以焊缝缺陷进行大致定位, 得到其相对应的行列坐标值, 以便特征参数的获取。

根据埋弧焊焊缝图像灰度分布的性质，我们起初从列灰度函数的曲线来进行判断，通过大量实验进行验证，图 3-16 (a) 代表不含缺陷的列灰度函数的曲线，很明显曲线可以把图像分为两个区域一个是灰度值较小的背景区域，一个是灰度值较大的焊道区域，其灰度函数曲线表现为 1 个波峰，0 个波谷；图 3-16(b) 含缺陷的列灰度函数的曲线，很明显曲线成 M 形，比不含缺陷的图像多出一个波峰、波谷，灰度变换从亮到暗再到亮。若想要判断焊缝图片中是否含有缺陷，可以根据列灰度函数曲线的波峰、波谷的个数进行判断，若曲线中表现为 1 个或多于 1 个波谷，2 个或多于 2 个波峰，则缺陷一定存在，且波谷的个数代表缺陷的个数，波谷在曲线中的位置代表缺陷的列坐标。

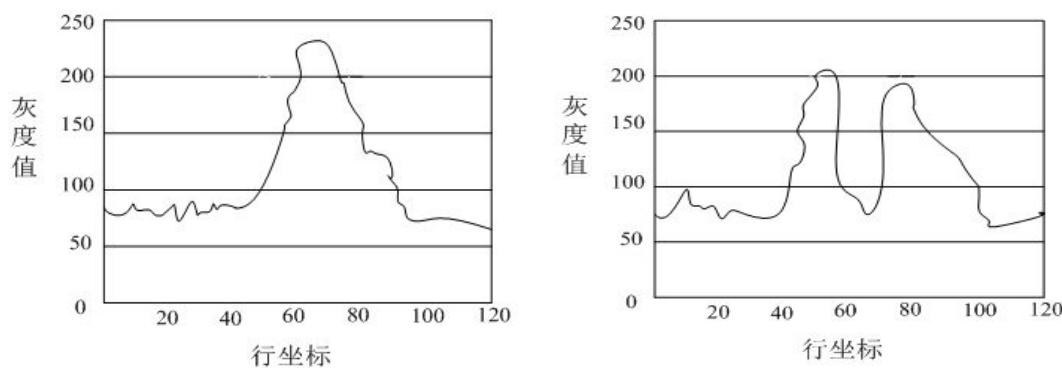


图 3-16(a) 没有穿过缺陷列灰度图片

图 3-16(b) 穿过缺陷列灰度图片

通过列灰度曲线确定了缺陷列坐标，要想知道它在图像中的具体信息，还需要知道埋弧焊焊缝缺陷的行坐标，这就需要用到行灰度函数图像。当图像中不含缺陷时，函数曲线的形状接近于一排平行的直线，即使有噪声的存在，也不会改变直线的大概形状；当图像中含有缺陷时，函数曲线的形状会出现较大起伏，甚至跳跃性波动，把其位置记录下来，获得缺陷的行坐标，从而得到缺陷确切的位置坐标。根据行列灰度函数曲线，可以实现缺陷的大概位置，实现了缺陷的分割，为后续的缺陷的几何特征提取做好了准备。

3.3 本章小结

焊缝图像处理对于焊缝缺陷识别是不可缺少的一部分，本文重点研究了图像滤波、增强、分割等技术，通过滤波抑制了焊缝图像中的噪声，通过增强提高了不同区域特征的差异，通过分割实现了前景与背景的分隔，最后利用图像的行列灰度曲线的分布图确定了缺陷的大概位置，为下一章的特征提取做好了准备工作。

第四章 特征参数的选取与分析

从埋弧焊焊缝图像中提取出缺陷图样之后，对这些图样进行特征参数的测量，然后进一步进行分析实现不同缺陷的分类和识别。图像特征是图像识别的开始，每一幅都具有各自的特征，本章将通过对不同特征参数加以描述和分析，从而使缺陷图像能够真正意义上被计算机识别。

4.1 焊缝缺陷种类及其特点

为了正确的识别焊缝缺陷图像，要求人们不仅要有丰富的经验，还要具备一定的知识基础。在焊缝缺陷提取和计算过程中需了解各类不同缺陷的特点以及其产生的原因，为后续的识别奠定基础。根据焊接领域的相关技术发展以及人们的丰富经验，大致将缺陷分为气孔、裂纹、未熔合、夹渣几大类^[47]等，但大类中又包含很多小类，为了简化计算，按照大类进行缺陷识别。不同的焊缝缺陷形成的机理不相同，在检测图片上提取的特征参数也不同。为了能够正确识别埋弧焊焊缝缺陷，需要对不同的缺陷类别进行理解，掌握他们各自的规律，做以下介绍。

1) 裂纹

裂纹是工业中最常见的焊缝缺陷之一，它是由于局部材料断裂产生的裂隙，其特点黑细直线条、两端突出较尖锐、线条形状较清晰、黑度较淡。裂纹可以按照强度、温度以及断裂方向进行分类，并分别研究。裂纹产生的位置不止在图像的焊缝中，有可能还会存在被焊接材料的热影响区（Hear Affect Zone）中，所以在焊接时要多加注意和观察。

2) 气孔

气孔也是最常见的缺陷之一，它是由于在焊接时，气体出现饱和而没来的及逸出而在留在焊缝金属内部或表面所产生的。气孔可以按照形状、位置进行分类，不同的类别具有不同的特点，其中单个气孔形状不一，颜色呈黑色斑点，中点较黑，边缘较浅，轮廓清晰可见；链状气孔是很多个单个气孔重叠在一起组成很多个密密麻麻的黑点，并且排成一排；密集气孔是由很多的点相互交叉组成的，其形状模糊，且黑度较其他气孔来说相对较低。气孔产生的因素很多，所以要严格控制金属密度、粘度以及焊接的材料、条件等。

3) 未熔合

未熔合是点焊时被焊接材料之间的层没有融合或焊接金属与被焊材料未熔合。其特

点是黑度分布不均匀一侧较高直线条一侧较暗曲线条、轮廓线宽、阴影较淡。未熔合缺陷大大降低了焊缝的强度，在受到外力的拉伸、延展时，容易引发裂纹缺陷。其产生的有很多原因：焊接时参数选择不当、焊接压力不足、电场强度不够、电流过小。

4) 夹渣

夹渣它是由于熔渣残留在了焊缝金属中形成的。夹渣可以按照形状和缺陷形成的机理进行分类，不同的夹渣具有不同的特点，其中点状夹渣有很多小黑点且形状参差不齐；条状型黑度淡、形状清晰、阴影分布不均、线条宽；链状夹渣形状参差不齐、黑度均匀分布、直线条与轴平行。

总结分析缺陷的特点与产生的原因，在此基础上建立模型，提取缺陷的特征并计算相应的特征参数，其目的是对焊缝缺陷准确的识别。裂纹、气孔是最为常见的缺陷，占到总缺陷的 80%左右，本文以其作为研究对象。

4.2 建立缺陷的特征参数

X 焊缝检测图像缺陷的建模就是对图像的基本属性从多个方面来描述。本文通过研究采用埋弧焊焊缝缺陷的外部特征对焊缝缺陷进行描述。不同类别的缺陷，具有不同的几何特征和形状特征，本文采用图 4-1 建立缺陷的特征参数。

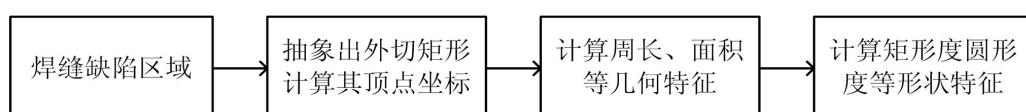


图 4-1 建立缺陷的特征参数

首先，在埋弧焊焊缝图像中，通过基于灰度曲线分析的方法搜索到缺陷所在的区域；其次，通过该区域抽象出缺陷区域的外切矩形并计算上下左右点的值；再次，计算焊缝缺陷的质心、面积、周长等几何特征；最后，在计算出焊缝缺陷的填充指数、长短轴之比、图形两边尖锐度等形状特征。

4.2.1 截取到的焊缝缺陷区域

通过灰度曲线分析的方法搜索到焊缝缺陷的区域后，需要将原始的缺陷局部图像存入到数据库中，其目的是为了方便后续的处理。在缺陷区域内实施的具体步骤如下：第一步是确定区域内各像素点地址，它是通过 scanline 函数读入本行第一个像素的首地址 P[ii] 来实现的；第二步恢复原始 RGB 图像的信息，它是通过灰度赋值的方法分别给连续的三个地址 p[3*jj+2]、p[3*jj+1]、p[3*jj] 赋给蓝、绿、红三个颜色值来实现的；最后一步实现矩形区域中原始缺陷图像的截取，它是通过借助 Canvas 函数完成的。截取到

原始缺陷如下图所示。

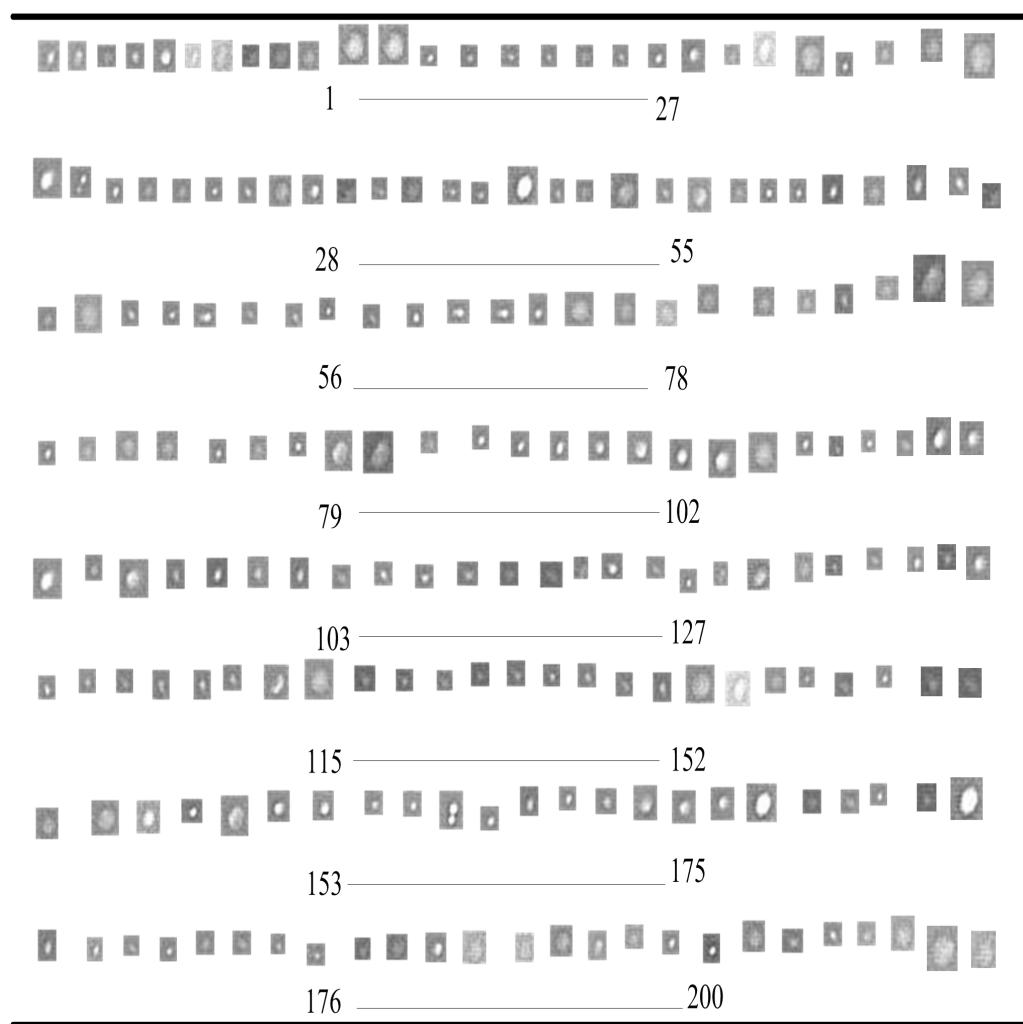


图 4-2 200 组圆形缺陷图像

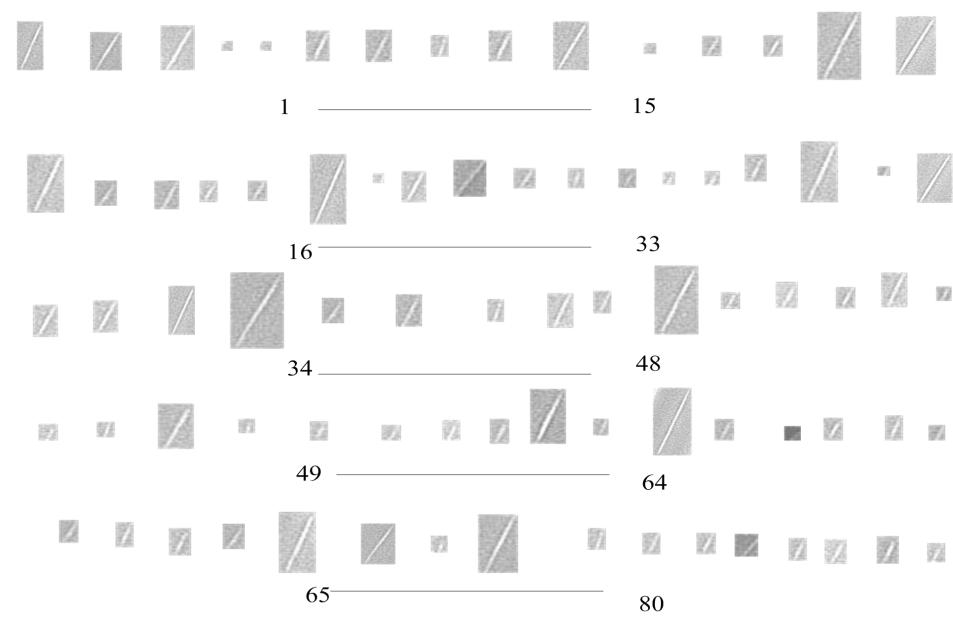


图 4-3 80 组线形缺陷

4.2.2 缺陷的几何特征

通过灰度曲线分析的方法搜索到焊缝缺陷区域后，得到了该区域的行列信息参数，以最大列参数值减去最小列参数值得到的数作为缺陷最小外切矩形的长为 X 值和以最大行参数值减去最小行参数值得到的数作为缺陷最小外切矩形的宽为 y 值，以此建立该区域的模型。不同类型的缺陷具有不同的几何特征。气孔的形状通常是球形或椭圆形，裂纹的形状通常是长短不同的缝隙，夹渣呈现规则不同的形状。本文分别采用以下几种缺陷的几何特征缺陷的面积 s_n 、缺陷的周长 L、质心 (s_x, s_y) 、外切矩形的长和宽、外切矩形的面积。下表 4-1 就是埋弧焊焊缝缺陷几何特征内容的概括和计算公式。

表 4-1 缺陷的几何特征

编号	几何特征的名称	几何特征的描述	
1	缺陷的面积s	缺陷面积与物体的边界以及边界内部的像素数有关，而与其内部的灰度级变化及影像的位置无关，只是缺陷区域的大小。通常最简单的计算缺陷面积的方法是计算缺陷区域中的像素点的数目，像素点的数目越多，缺陷区域面积越大，反之面积就越小。在经过二值化处理后的缺陷图像，用1表示目标区域内的对象，用0表示不感兴趣区域的背景，外切矩形区域中的点的个数就是缺陷的面积。	$s = \sum_{i=1}^n \sum_{j=1}^m f(a, b)$
2	缺陷的周长C	缺陷的周长定义为缺陷外围区域边界的总长度，它最大的亮点是能够很快区别简单或者复杂形状物体。求取周长时，通常设垂直相邻的像素间的距离为1，水平方向为1，对角线方向为水平垂直相加的平方 n_2 表示水平、垂直像素个数， n_1 对角线方向像素个数	$C = n_2 + \sqrt{2}n_1$
3	质心 (S_x, S_y)	质心坐标是缺陷内部灰度分布情况的反应，质心指物质系统上被认为质量集中于此的一个假想点物体，由于二值图像质量分布是均匀的，所以质心即是物体的面积中心。假设缺陷图像中对应的像素位置坐标为 (a_i, b_i)	$S_x = \frac{1}{mn} \sum_{i=1}^n \sum_{j=1}^m a_i$ $S_y = \frac{1}{mn} \sum_{i=1}^n \sum_{j=1}^m b_i$
4	缺陷的长轴 (L1) 短轴 (L2)	通过图像处理已知缺陷对象的边界，为了方便起见，我们通常用最小外切矩形的尺寸来刻画它的基本形状，如图4.4。缺陷边界上任意两像素点之间距离的最大值代表长轴。那缺陷短轴的计算呢，我们知道缺陷的长轴和短轴是垂直的，知道长轴的斜率利用两条直线垂直定理，就可以计算出短轴的斜率，进而求出短轴	$L_1 = \sqrt{(a_1 - b_2)^2 + (a_1 - b_3)^2}$ $L_2 = \sqrt{(a_2 - b_3)^2 + (a_2 - b_1)^2}$
5	外切矩形面积	缺陷的长轴乘以缺陷的短轴	$S_n = L_1 \times L_2$

4.2.3 缺陷的形状特征

通过已经求出的缺陷几何特征的公式，进一步研究缺陷形状特征的公式。本文为了分析和识别各类缺陷采用以下 7 种形状特征，其内容概括和计算公式如下表所示：

表 4-2 缺陷样图的形状特征

编号	形状特征名称	形状特征的描述	公式
1	质心到焊缝中心线的距离	焊缝缺陷的几何特征中提取到的焊缝区域 (ROI) 边界斜率为 k ，焊缝的缺陷质心为 (s_x, s_y) ，焊缝区域上边界在 y 轴上的截距为 c_1 ，焊缝区域下边界在 y 轴上的截距为 c_2 ，得到的最终截距为 $c = (c_1 + c_2) / 2$ 。由于未焊透的缺陷散落在焊缝中心线上的这种特殊性，所以质心到焊缝中心线的距离可以用来区别未焊透缺陷与其他的焊缝缺陷	$G(1) = \frac{ s_y - k * s_x - c }{\sqrt{1+k^2}}$
2	填充度指数	缺陷的面积与外切矩形面积的比	$G(2) = S / (L_1 \times L_2)$
3	长短轴之比	焊缝缺陷的长、短轴分别为 (L_1) 、 (L_2) ，依据长宽比可以将缺陷分为线性缺陷、圆形缺陷。线性缺陷均表示为笔直或者弯曲不同粗细的线条包括未焊透、未熔合、裂纹等；圆形缺陷均表示轮廓都比较圆滑包括夹渣、气孔等。长宽比即可以用来描述目标区域的扁平程度，又可以用来区别气孔、未熔合、夹渣和裂纹及未焊透缺陷	$G(3) = L_1 / L_2$
4	圆形度	由于二值化之后的图像形状规则不一，用圆形度进行刻画，其目的是为了更好地对焊缝射线图像进行分析，圆形度是用来刻画焊缝缺陷区域边界的复杂程度，是在缺陷面积和缺陷周长的基础上得到的，它可以用来区别气孔、裂纹及夹渣等缺陷。	$G(4) = 4\pi S / C^2$
5	短轴和缺陷面积之比	通过缺陷的短轴和缺陷面积之比可以用来区别细长条状（裂纹、未焊透）、圆形区域，通过焊缝缺陷的外切矩形的长宽比可以用来区别气孔和夹渣等缺陷。	$G(5) = L_2 / S$
6	两边尖锐度	缺陷长径两边 $1/4$ 段的面积与焊缝总面积之比中较小的一个，描述缺陷两端的形状	$G(6) = \min(s_1, s_2) / S$
7	海梧德直径	海梧德直径主要用来区别噪声点和焊缝缺陷，它定义为与对象具有相同面积圆的直径。	$G(7) = 2 * \sqrt{S / 3.14}$

4.2.4 提取到气孔和裂纹的部分特征参数

本文提取到200组圆形缺陷样图的形状特征参数和80组裂纹缺陷样图的形状特征参数，由于数据较多，以下表格只列出小部分特征参数。

表 4-3 部分特征参数

	G(1)	G(2)	G(3)	G(4)	G(5)	G(6)	G(7)
气孔	14.86105	1.010899	0.08137571	2.929089	0.04058949	1.010899	8.060283
	16.18458	1.148606	0.05174701	2.273643	0.04120084	1.148606	13.49687
	1.831117	2.165513	0.06338893	5.746222	0.03980892	2.165513	5.047544
	6.663684	0.8640553	0.05593025	3.245339	0.03980892	1.157333	12.05085
	10.75904	0.611873	0.04159347	6.699916	0.04009125	1.634326	13.40216
	18.24676	1.039698	0.1226162	3.046333	0.0454959	1.039698	5.172194
	4.48092	0.7354348	0.1450189	1.701465	0.04399933	1.35974	6.95756
	6.862586	0.5813111	0.1742945	1.415676	0.04179936	1.720249	7.138306
	3.683243	1.285776	0.1480336	1.267524	0.04265241	1.285776	5.972335
	4.096413	0.966837	0.1634806	1.138244	0.04215062	1.0343	6.581193
	10.90178	1.442231	0.1634815	1.526085	0.04215062	1.442231	4.653606
	1.719138	1.4837	0.1011679	2.438962	0.04128332	1.4837	5.864717
	2.780824	0.9748454	0.1263267	1.460904	0.04161841	1.025804	7.486719
裂纹	1.697428	0.7435142	0.1224604	1.992998	0.04069356	1.344964	7.571317
	4.002632	0.9777587	0.1535172	1.607277	0.04423213	1.022747	5.864717
	5.977594	0.2761471	0.009317907	76.38888	0.03339283	3.621258	26.37312
	7.570455	0.6370875	0.01192181	83.03576	0.04130549	1.569643	13.0164
	4.397151	2.404376	0.01110412	67.46201	0.03980892	2.404376	7.980869
	2.216006	0.303185	0.07670988	16.48582	0.04449232	3.298316	6.581193
	6.405139	0.6909858	0.05125729	17.76879	0.04109308	1.447208	6.284142
	1.028828	0.4489971	0.06897289	17.33947	0.04128332	2.227186	5.864717
	1.315987	1.427949	0.01172503	79.59386	0.04229698	1.427949	9.029323
	4.685885	26.72345	0.000615343	2670.986	0.04303667	26.72345	6.865403
	3.663375	1.344634	0.004018776	232.5642	0.04061314	1.344634	15.88173
	0.4095468	0.7089654	0.04132694	19.66343	0.04170458	1.410506	7.314587
	3.101661	2.991212	0.02447112	46.52258	0.04644374	2.991212	3.909811
	3.810637	0.2378127	0.0208292	69.22958	0.03980892	4.20499	13.35455
	4.270388	0.6534629	0.03569345	29.29666	0.04272176	1.530309	7.226984
	2.371804	0.6468614	0.04027119	16.15652	0.0418331	1.545926	8.669442
	1.260653	0.03280141	0.00666307	2351.667	0.04008158	30.48649	19.28664
	4.763327	0.1196404	0.01178815	325.1317	0.03959373	8.358381	15.35151

4.3 特征参数的处理

为了更好利用机器识别，得到的焊缝缺陷七维形状特征参数，需要对其进行处理，进一步比较特征参数的主成分分析和核主成分分析。

4.3.1 主成分分析的基本原理及计算步骤

1) 主成分分析的基本原理

主成分分析 (Principal Component Analysis, PCA) 是减少数据的维数，其基本思想就是用几个综合指标代替原来指标，使综合指标达到数目较少、互不相关的标准。在数学上它利用线性变换将相关向量转换成不相关向量，也就是将求得的协方差矩阵变成对角矩阵，进而求出较少的主成分。主成分分析能够使我们从复杂的众多指标中选取一部分新的指标作为主成分进行数据统计以及后续的缺陷识别^[48]。

主成分分析因为各种特征值间存在重叠或者线性相关的原因，不仅增加了计算机运行的时间而且也占用了计算机很大的存储空间，导致检测过程困难。主成分分析最大的特点是降维，利用这个特点可以把它应用到特征参数的提取过程中。主成分分析法它只考虑了低阶数据，忽略了高阶数据，所以是一种线性映射^[49]。

设现在有一个 $m \times n$ 阶的样本数据矩阵 X

$$X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ x_{21} & x_{22} & \dots & x_{2n} \\ \vdots & \vdots & & \vdots \\ x_{m1} & x_{m2} & \dots & x_{mn} \end{bmatrix} \quad (4-1)$$

设单位向量 $a_i = (a_{1i}, a_{2i}, \dots, a_{ni})$ ，且我们知道 $a_i \cdot a_i^T = 1$ ，我们就可以得到样本数据矩阵 X 的 n 个列向量的线性组合为：

$$F_i = a_{1i}X_1 + a_{2i}X_2 + \dots + a_{ni}X_n \quad (4-2)$$

由公式具有以下规定：其一，公式中任意两个不相等的值 F_i 与 F_j 它们不相关，即 $\text{cov}(F_i, F_j) = 0$ 。其二，公式中另 $i=1$ 得到的 F_1 ，它是方差最大的线性组合，我们把它称为第一主元， F_2 为第二主元， F_3 为第三主元，以此类推 F_n 为第 n 个主元。

这 n 个主元从原始数据中提取的信息是依次递减的，每一个主元提取原始数据的信息量是根据方差排列的大小顺序依次排列的，方差最大的排列到第一个主元，第二大的排列到第二位，以此类推直到所有的方差求和大于给定的一个指标，这样就得到了最小的方差。我们把所有方差求和得到的数据叫做方差贡献率 $\sum_{i=1}^n \lambda_i$ ，可知它越大，数据综合信息反应的就越大。

2) 主成分分析计算步骤:

(1) 首先采集 p 维随机向量 x , n 个样品 x_i , 其中 $x = (x_1, x_2, \dots, x_p)^T$, $x_i = (x_{i1}, x_{i2}, \dots, x_{ip})^T$, $i=1, 2, \dots, n, n > p$, 构造样本矩阵并对特征向量进行特征中心化处理, 消除差异, 得到标准矩阵 Y, 其公式如下。

$$\bar{y} = \frac{\sum_{i=1}^n y_{ij}}{n} \quad (4-3)$$

$$s_j^2 = \frac{\sum_{i=1}^n (y_{ij} - \bar{y}_j)^2}{n-1} \quad (4-4)$$

$$Y_{ab} = \frac{y_{ij} - \bar{y}_j}{s_j} \quad (4-5)$$

式中 y_{ij} 是第 j 个观测变量的第 i 个观测数据; \bar{y}_j 是第 j 个观测变量的平均值; $\text{var}(y_i)$ 是第 j 个样本的标准差。

(2) 求步骤 1 得到的标准矩阵 Y 相关系数矩阵 R, 其公式如下。

$$r_{ij} = \frac{\sum Y_{kj} \cdot Y_{ij}}{n-1} \quad (4-6)$$

$$R = [r_{ij}]_p \times p = \frac{Y^T Y}{n-1} \quad (4-7)$$

(3) 解相关系数矩阵 R 特征方程得到特征值根据特征值得到特征向量。编程使得到的特征值按照由大到小的顺序排列, 前 m 个特征值为提取主元的方差, 其公式如下。

$$|R - \lambda I_p| = 0 \quad (4-8)$$

(4) 通过计算协方差矩阵的特征值比上特征值总和的方法来得出累积方差贡献率, 通过累积贡献率之和大于某个固定值的方法来提取主成分, 其公式如下。

$$\frac{\sum_{j=1}^m \lambda_j}{\sum_{j=1}^p \lambda_j} \geq 0.85 \quad (4-9)$$

(5) 选取主成分的个数, 其公式如下。

$$U_{ij} = Y_i^T b_j^o, \quad j = 1, 2, \dots, m \quad (4-10)$$

其中 b_j^o 是方程组 $Rb = \lambda_j$ 的单位特征向量, U_1 为第一个主成分, U_2 为第二主成分, U_p 为第 p 个主成分。

(6) 对主成分进行综合评价。

主成分分析的算法流程图如下。

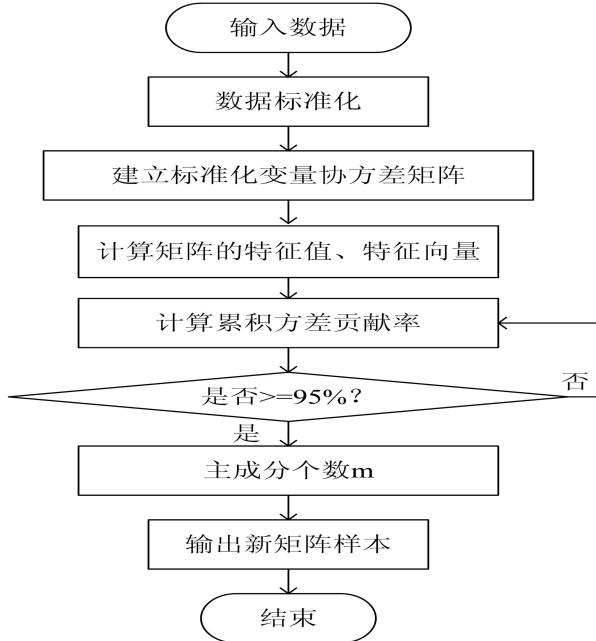


图 4-4 算法流程图

4.3.2 特征参数的主成分分析

通过测量得到的样本值X对焊缝圆形缺陷进行主成分分析,用MATLAB编程读取到的文件数据X是200行7列的矩阵,数据的行代表200幅图片的圆形缺陷,数据的列代表圆形缺陷不同类型的特征参数。程序中的输出协方差矩阵的特征向量latent,它是由7个不同特征值按照由大到小的规律组成的。输出函数包括7个元素的列向量tsquare,它的第*i*个元素是第*i*个观测对应霍特林统计量;返回值score是200个缺陷图像的7个主成分的得分矩阵,它是200行7列的矩阵;在当贡献累计率达到0.95以上,计算机对200×7的缺陷特征矩阵依次通过以上步骤处理。用MATLAB编程程序如下所示。

```

data=xlsread('datt.xls','Sheet1')
x=data;
[coef,SCORE,latent,tsquare]=princomp(x) explained=100*latent/sum(latent)
pareto(explained);
set(get(gca,'YLabel'),'String','主成分方差贡献率 (%) ','FontSize',10)
set(get(gca,'XLabel'),'String','主成分','FontSize',10)
set(findobj('Type','line'),'Color','g')
s={'标准化变化';
'x1:G(1)';'x2:G(2)';'x3:G(3)';'x4:G(4)';'x5:G(5)';'x6:G(6)';'x7:G(7)'};
result2(:,1)=s;
result2(1,2:4)={'prin1','prin2','prin3'};
  
```

```

result2(2:8,2:4)=num2cell(coef(:,1:3))

plot((score;,1),SCORE (:,2) '+')
xlabel('1st Principal Component')
ylabel('2st Principal Component')

```

结果显示如下：

表 4-4 提取到的 7 维数据的不同量

	特征值	贡献率	累积贡献率
1	34.3525	72.8825	72.8825
2	7.4274	15.7581	88.6406
3	5.0723	10.7614	99.4020
4	0.2226	0.4722	99.8742
5	0.0526	0.1117	99.9858
6	0.0067	0.0141	99.9992
7	2.7027e-06	5.7341e-06	100.0000

表 4-5 主成分的表达式系数矩阵

	标准化变量	'print1'	'print2'	'print3'
1	'x1:G(1)'	0.0095	-0.0165	-0.0984
2	'x2:G(2)'	-0.0013	0.0315	0.0064
3	'x3:G(3)'	-0.0019	-0.0050	-0.0144
4	'x4:G(4)'	0.0167	0.9985	-7.5897e-04
5	'x5:G(5)'	9.6804e-06	6.3982e-06	-1.2087e-04
6	'x6:G(6)'	-0.0016	0.0427	0.0017
7	'x7:G(7)'	0.0984	-0.0012	0.9950

为了使结果更加直观, MATLAB 编程中定义的两个元胞数组: result1 和 result2 如上表所示, 用 result1 存放特征值、贡献率、累积贡献率, 用 result2 存放 3 个主成分系数矩阵, 就是输出参数 coef 的前 3 列数据。

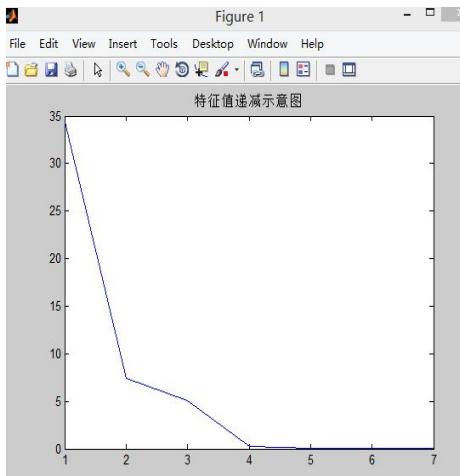


图 4-5 (a) 特征值递减示意图

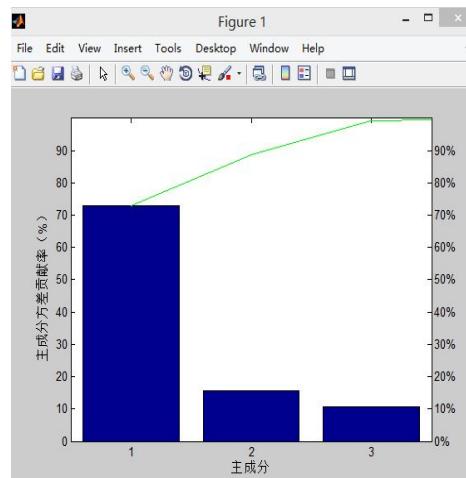


图 4-5(b) 提取到的主成分

由图 4-5 (a) 所示很明显，在这 7 个特征值中的，第一个特征值最大，而且图像曲线呈下降趋势，通过表可知前三个特征值的方差贡献率达到了 0.9940；根据图 4-5 (b) 可以看出，在保留原始数据 95%的前提下，运用主成分算法分析从原始的特征矩阵中提取出了 3 个主元，这不仅减少样本数据的个数而且还确保这些数据之间是互不交叉的。处理之后数据与原始数据进行对比如下。

表 4-6 数据对比

数据	数据大小	数据量	下降比例
原始数据	200×7	11200	57.14%
处理之后的数据	200×3	4800	

由表 4-6 所示经过主成分分析特征描述的数据量减少了 57.14%，由此可见主成分分析法提高了效率，更有利于缺陷识别。提取到的三个主成分相对来说信息量较少，但是却不对整体局势造成困扰。我们可以写出前三个主成分分析的表达式分别为：

$$y_1 = 0.9950x_1^* - 0.0013x_2^* - 0.0019x_3^* + 0.0167x_4^* + 9.6804e06x_5^* - 0.0016x_6^* + 0.0984x_7^* \quad (4-11)$$

$$y_2 = -0.0165x_1^* + 0.0315x_2^* - 0.005x_3^* + 0.9985x_4^* + 6.3982e06x_5^* + 0.0424x_6^* - 0.0012x_7^* \quad (4-12)$$

$$y_3 = -0.0984x_1^* + 0.0046x_2^* - 0.0144x_3^* - 7.5897e04x_4^* - 1.2087e04x_5^* + 0.0017x_6^* + 0.9950x_7^* \quad (4-13)$$

SCORE 包含了原始数据在被主成分定义的新坐标系统中的坐标，它是和原始数据矩阵同大小的，绘制 SCORE 的前两列，目的是展示原始数据投影到两个主成分的新数据，结果显示如下：

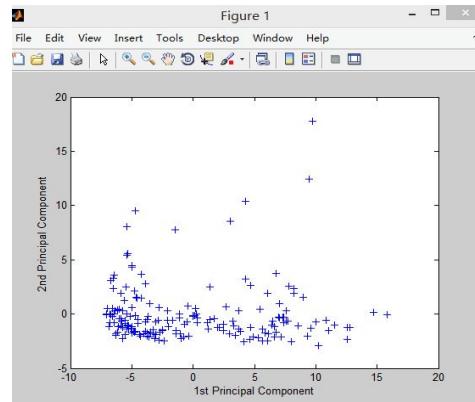


图 4-6 散点图

4.3.3 核主成分分析的基本原理及计算步骤

1) 核主成分分析的基本原理

核主成分分析它是一种非线性推广的主成分分析，对特征参数进行主成分提取，以此来压缩维数、消除不相关因素、降低问题的复杂度，如下图所示代表了核主成分分析（KPCA）的基本思想^[50]。

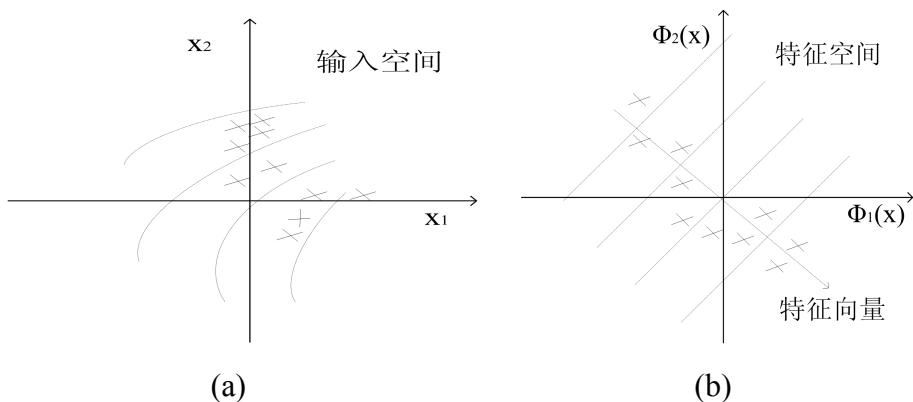


图 4-7 核主成分的基本思想

图（a）代表输入空间数据，显示的是输入空间上的非线性等值线对应特征空间的线性等值线，因为特征向量的原像可能不存在，所以没有在图中画出。图（b）代表特征空间数据，图中用虚线箭头表示特征向量，在主特征向量上的投影为常数的线代表形状线。

2) 核主成分分析算法步骤

(1) 输入数据如下：

$$S = (x_1, x_2, \dots, x_l) \quad (4-14)$$

(2) 计算核矩阵如下表达式：

$$K_{mn} = k(x_m, y_n) \quad (4-15)$$

(3) 将核矩阵进行中心化如下所示：

$$(1_N)_{mn} = \frac{1}{N} \quad (4-16)$$

$$K_c = K - 1_N K - K 1_N + 1_N K 1_N \quad (4-17)$$

(4) 计算核矩阵的特征值和特征向量:

$$\lambda_k(\alpha_k \cdot \alpha_k) = 1 \quad [A, \tilde{\Lambda}] = \text{eig}(k) \quad (4-18)$$

(5) 将特征向量进行规范处理:

$$\tilde{\alpha}_i = \frac{\alpha_i}{\sqrt{\tilde{\lambda}_i}} \quad (4-19)$$

(6) 对原始数据进行重建:

$$\phi(X)_{kpc}^k = \sum_{i=1}^n \tilde{\alpha}_i^k (\phi(x_i) \cdot \phi(x)) \quad (4-20)$$

(7) 输出变换之后的数据。

$$\tilde{S} = [s_1, s_2, \dots, s_l] \quad (4-21)$$

核主成分分析算法流程图:

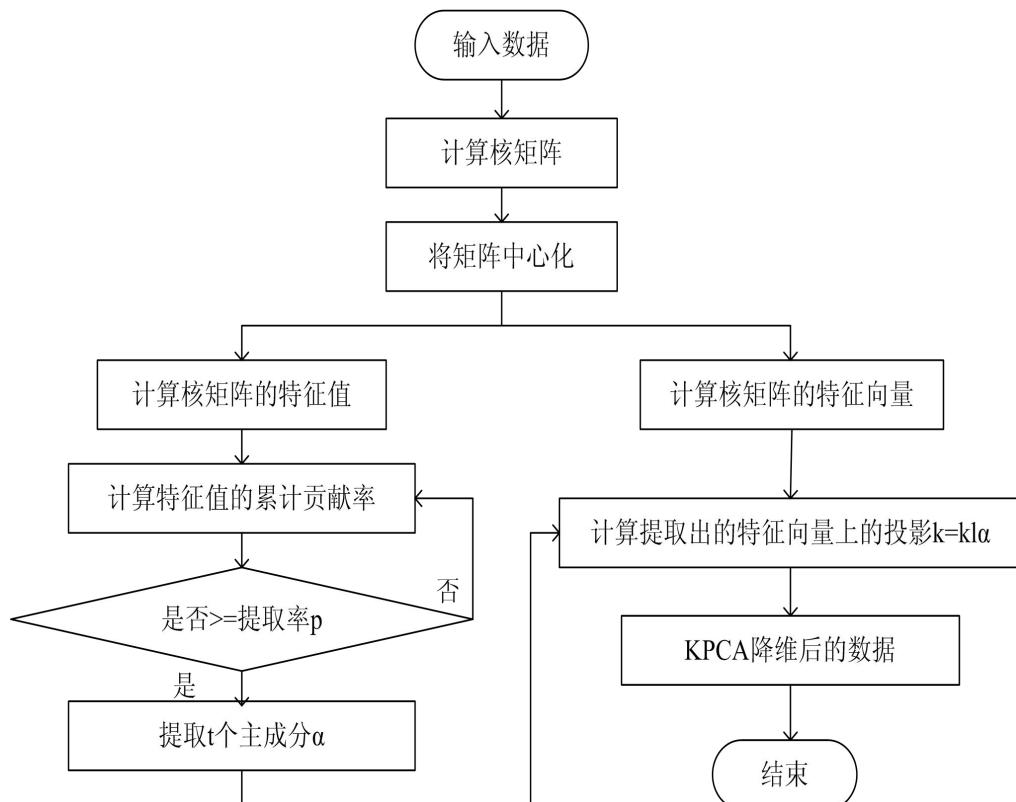


图 4-8 核主成分流程图

4.3.4 特征参数的核主成分分析

本课题使用焊缝圆形缺陷提取到的数据参数，根据上述流程依次对数据进行处理，选取 140×7 的缺陷特征矩阵作为训练集， 60×7 的缺陷矩阵作为测试集，采用 RBF 高斯径向核函数 MATLAB 编程如下：

```

function
[RDData,ED1,Contribution,AContribution]=KPCA(TrainData,TestData,Kernel,Rate)
求核矩阵
[r,~]=size(TrainData);
Avr=mean(TrainData,2);           % 求每一行段（行）的均值
for k=1:r                        % 求每一行段（行）零均值化
    TrainData(k,:)=TrainData(k,:)-Avr(k);
end
K=zeros(r,r);
if(strcmp(Kernel,'RBF'))
    sigma=100;
    for k=1:r
        for l=1:r
            K(k,l)=exp(-sum((TrainData(k,:)-TrainData(l,:)).^2)/(sigma^2));
        End
    end
    求特征值特征向量
    [V,D]=eig(K);
    [r1,~]=size(D);
    [r2,c2]=size(V);
    ED=zeros(1,r1);
    EV=zeros(c2,r2);
    for k=1:r1
        ED(k)=D(k,k);
    end
    [ED1,order]=sort(ED,'descend');
    for k=1:r1
        EV(k,:)=V(:,order(k))';
    End
    求贡献率累积贡献率

```

```

Contribution=ED1/sum(ED1);
AContribution=zeros(1,r1);
data=xlsread('datt.xls',1,'A1:G140');
a=data;
data=xlsread('datt.xls',1,'A141:G200');
b=data;
time1=clock;
[train_kpca,test_kpca]=kpcaForData(a,b);
time2=clock;
etime(time2,time1)

```

改变高斯径向核函数的参数，并分别运行结果如下表所示：

表 4-7 高斯径向核函数参数 sigma=100

	特征值	贡献率	累积贡献率
1	5.9149	84.4985	84.4985
2	0.7014	10.0198	94.5283
3	0.2289	3.2705	97.7889
4	0.1476	2.1093	99.8981
5	0.0049	7.0665e-02	99.9688
6	0.0021	2.9408e-02	99.9982
7	1.2693e-02	1.8134e-05	100.000

表 4-8 高斯径向核函数参数 sigma=150

	特征值	贡献率	累积贡献率
1	6.4127	91.6248	91.6248
2	0.4071	5.8154	97.4402
3	0.1085	1.5502	98.9904
4	0.0675	0.9644901	99.9548
5	0.0022	3.31310e-02	99.9862
6	9.1312e-04	1.3045e-02	99.9992
7	5.5765e-05	7.9665e-04	100.0000

表 4-9 高斯径向核函数参数 sigma=200

	特征值	贡献率	累积贡献率
1	6.6451	94.9296	94.9296
2	0.2514	3.6055	98.5351
3	0.0624	0.8918	99.4268
4	0.0383	0.5477	99.9746
5	0.0012	1.7591e-02	99.9922
6	5.1325e-04	7.3322e-03	99.9996
7	3.1236e-05	4.4623e-04	100.0000

改变函数为多项式核函数，并使用不同的参数，运行结果如下表所示：

表4-10 多项式核函数参数 p=1

	特征值	贡献率	累积贡献率
1	6.8374e+03	72.8412	72.8412
2	1.4792e+03	15.7581	88.5993
3	1.01102e+03	10.7618	99.3611
4	46.1270	0.4914	99.8525
5	10.5181	1.7591e-02	99.9645
6	2.8934	3.0825e-02	99.9953
7	0.4374	4.6598e-03	100.0000

表 4-11 多项式核函数参数 p=2

	特征值	贡献率	累积贡献率
1	4.5960e+07	93.2686	93.2686
2	2.1801e+06	4.4241	97.6927
3	1.1351e+06	2.3.35	99.9962
4	1.3634e+03	2.7668e-05	99.9990
5	502.0399	1.0188e-02	99.9645
6	7.0456	1.4298e-02	99.9999
7	0.8330	1.6904e-06	100.0000

为了使结果更加直观，用 MATLAB 编程如下图所示：

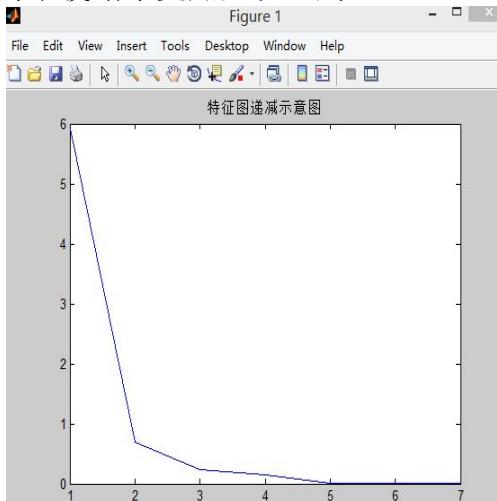


图 4-9(a) $\sigma=100$ 特征值图

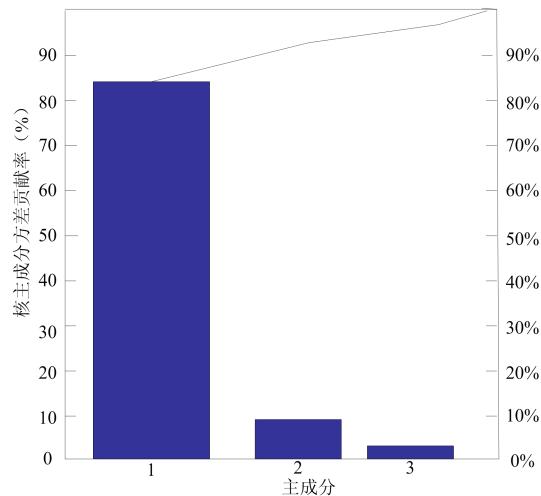


图 4-9(b) $\sigma=100$ 提取的主成分图

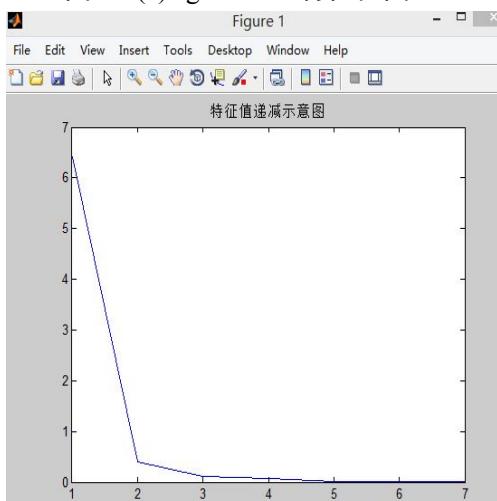


图 4-10(a) $\sigma=150$ 特征值图

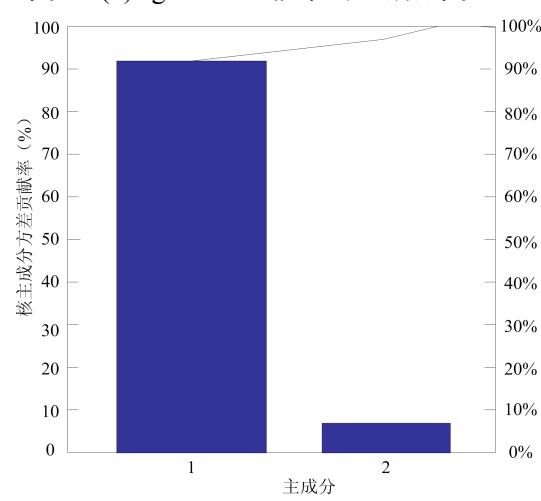


图 4-10(b) $\sigma=150$ 提取的主成分图

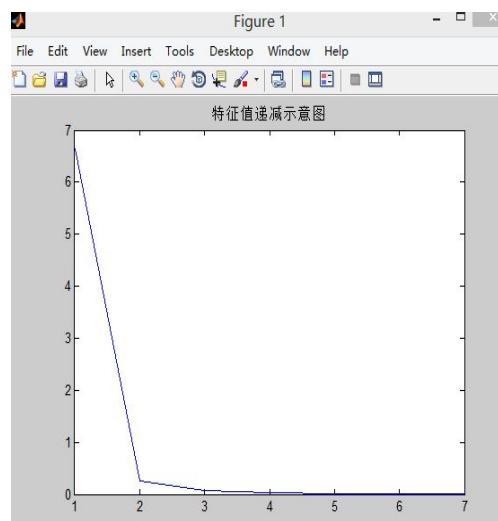


图 4-11(a) $\sigma=200$ 特征值图

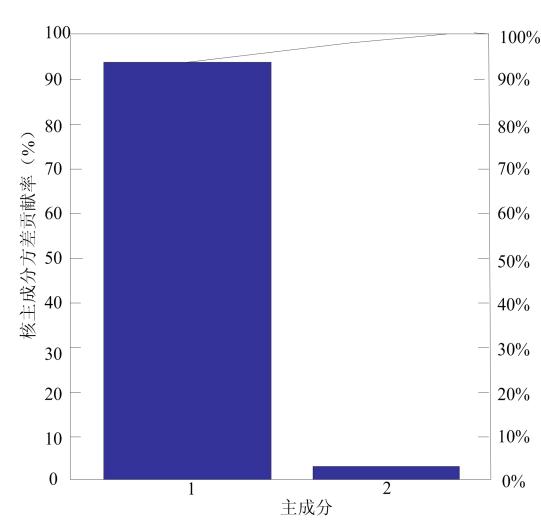


图 4-11(b) $\sigma=200$ 提取的主成分图

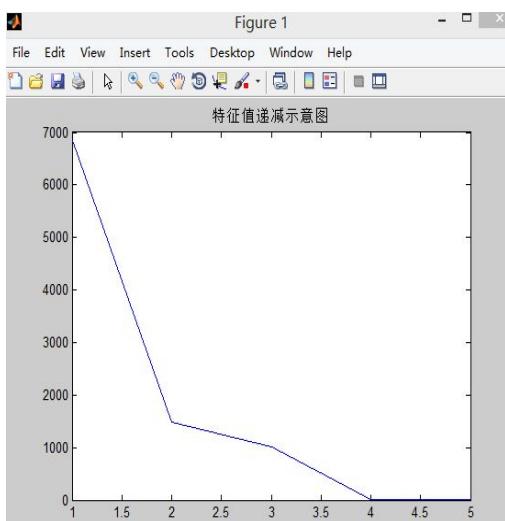


图 4-12(a) K=1 特征值图

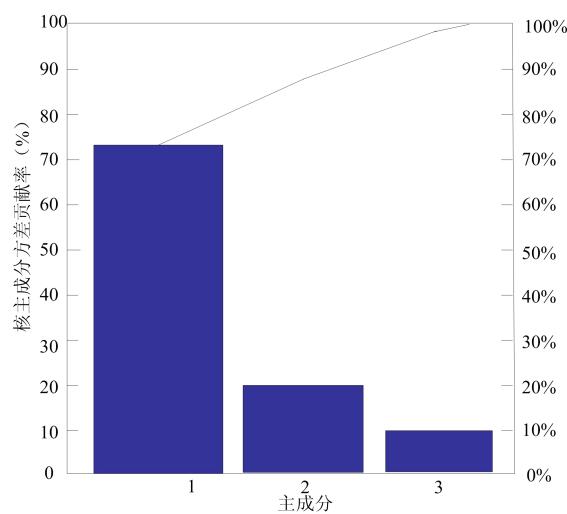


图 4-12(b) K=1 提取的主成分图

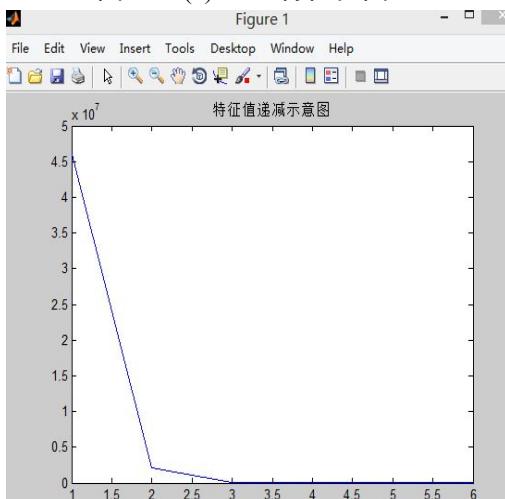


图 4-13(a) K=2 特征值图

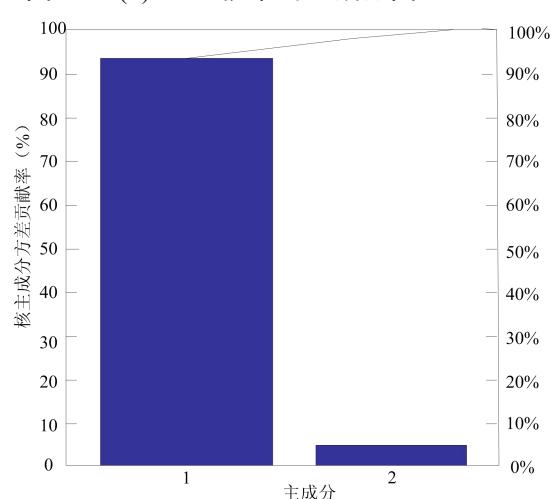


图 4-13 (b) K=2 提取的主成分图

由上图所示可以看出，核主成分分析算法可以减少样本数据的个数。使用不同的核函数以及不同的参数经过核主成分分析之后从原始的特征矩阵中提取的主元个数不同，下表分别是不同核函数提取的主元个数。

表 4-12 不同核函数降维后数据对比

数据	KPCA1			KPCA2	
原始数据	sigma=100	sigma=150	sigma=200	K=1	K=2
	200×7	200×7	200×7	200×7	200×7
处理之后数据	200×3	200×2	200×2	200×3	200×2
下降比例	57.14%	71.42%	71.42%	57.14%	71.42%

由表可见经过核主成分分析之后，特征的数据量相应的减少，采用不同的核函数以及不同参数数据量减少的不同，有的特征矩阵从 200×7 变成了 200×3 ，并且数据量减少了 57.14%，有的特征矩阵从 200×7 变成了 200×2 ，并且数据量减少了 71.42%，由此可见核主成分分析法不仅使计算机处理的数据量减少，而且还有利于缺陷识别。

4.4 特征参数的主成分分析和核主成分分析的对比

主成分分析和核主成分分析都是对缺陷区域提取的形状特征参数进行降维，降低数据的复杂度，提高计算机的运行速率，更有利后续的焊缝缺陷的识别，但是采用这两种不同的算法，运行结果是不同的，结果对比如下表所示：

表 4-13 主成分分析和核主成分分析对比

		提取主元个数	运行速率\秒
主成分分析		3	0.378991
核主成分分析	sigma=100	3	0.056882
	sigma=150	2	0.0502823
	sigma=200	2	0.057182
	K=1	3	0.054723
	K=2	2	0.054995

根据上表可知核主成分分析比主成分进行特征提取的速度快，而且根据不同参数的设定，核主成分分析提取的效果比主成分更加满足缺陷识别要求。

4.5 本章小结

本章介绍了焊缝缺陷的类别及其产生的原因，计算出焊缝缺陷区域的几何特征以及形状特征，然后进行主成分分析分析，对特征参数进行预处理，紧接着介绍了核主成分分析，它的优点在于不仅能够对数据进行降维，而且能够保留图像的高阶信息，这为后面的识别带来了方便。最后通过实验数据对比核主成分分析比主成分分析更有利于焊缝缺陷的识别。

第五章 基于神经网络的焊缝缺陷识别研究

随着现代工业技术的快速发展，焊缝缺陷被广泛应用于计算机识别中，用于判断工件是否合格。本章利用神经网络模式识别中良好的识别性能，去设计更有利于焊缝缺陷识别的系统。

其步骤是将已知大量缺陷的特征参数存入数据库，通过上一节主成分分析和核主成分分析得处理选取用于缺陷识别的特征参数，最后利用神经网络去观察缺陷类型，其目的是使识别结果更加准确。

5.1 神经网络特征和缺陷识别原理

1) 神经网络特征

神经网络作为缺陷识别的模型，它具有很多特点^[51]。

其一，神经网络它是由多个神经元组成的而且其相互之间具有多层互联结构，这种特点使其可以实时进行并运算，把结果输入到下一层运算，具有并行计算数据的特点。

其二，根据人脑的组织结构，它们之间的神经元是非线性连接的，可以将信息存储于其中实现非线性映射，具有非线性处理数据的能力。

其三，它由于其神经元之间的并行分布结构，使得其具有良好的可靠性。

其四，当改变训练数据的个数时，网络能够快速调节权值参数，具有自适应能力。最后，神经网络因为接近人大脑的思维规律，所以有利于计算模拟的实现。

2) 神经网络用于缺陷识别的基本原理

神经网络由于其优越的特点，被广泛应用于各种领域。其基本原理是：作为训练样本的输入参数特征数据和作为输出参数的缺陷类型，通过神经网络的训练，使样本的输入、输出模式反复作用于网络，网络就会按照一定的规则自动调整神经元之间的连接强度，实现输入到输出的非线性映射，从而满足要求预测出焊缝缺陷类型。

神经网络模型，它不需要对系统进行透彻的了解，这时系统的非线性能力映射较为突出。使用时无需建立数学模型，省略了很多在数学运算中的求解步骤，使运算量降低，它的实施步骤是将特征数据输入到网络结构中，根据网络中的运行原理，就可以得到想要的结果数据。

5.2 神经网络模型的对比

人工神经网络模型包含节点和连接权值，可以分为不同的种类，采用不同的神经网络模型就会呈现不同的预测结果^[52]。当网络模型确定下来，神经元之间连接的结构以及

学习方法也确定下来，即网络特性及功能确定。下面我们一起看一下 BP 神经网络和 RBF 神经网络。

5.2.1 BP 神经网络

BP 神经网络是一种误差反向传播算法，解决了多层网络的学习复杂问题，促进了其快速发展^[53]。BP 神经网络是输入输出的一种映射关系，无需计算数学方程，它通过从输出层逐层向前不断修正网络阈值和权值，通过学习规则使误差越来越小，最终达到要求输出结果。BP 神经网络以其简单、并行算法，在工业工程中广泛应用，BP 神经网络的结构一般是多层的，输入层、隐含层、输出层组成，层与层之间是互相连接的，同一层之间的神经元没有连接^[54]。其图如下所示：

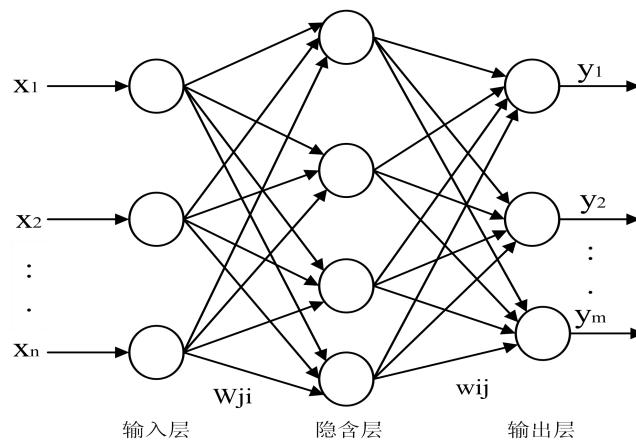


图 5-1 三层 BP 神经网络

由图可以看出 BP 神经网络层与层之间有两种信号在流动一种是工作信号，一种是误差信号。正向传播阶段是输入层接收外界信息将刺激传给中间层，中间层即隐含层是处理内部信息通过神经元之间联系的权重和激活函数将刺激传递给输出层，最后输出层输出实际数据。当实际输出数据和期望输出数据不一致时误差信号沿原来的连接原路返回，对神经网络权值和阈值进行反馈修正，这样反复训练多次直至误差低于预先设定的期望值才完成学习过程。

Sigmoid 函数作为传递函数时必须可微，使用其时输入与输出以及误差函数可以表示为：

$$\text{输入: } \text{net} = x_1 w_1 + x_2 w_2 + x_m w_m \quad (5-1)$$

$$\text{输出: } y = (\text{net}) = \frac{1}{1 + e^{-\text{net}}} \quad (5-2)$$

使用 S 型激活函数的图形如下所示：

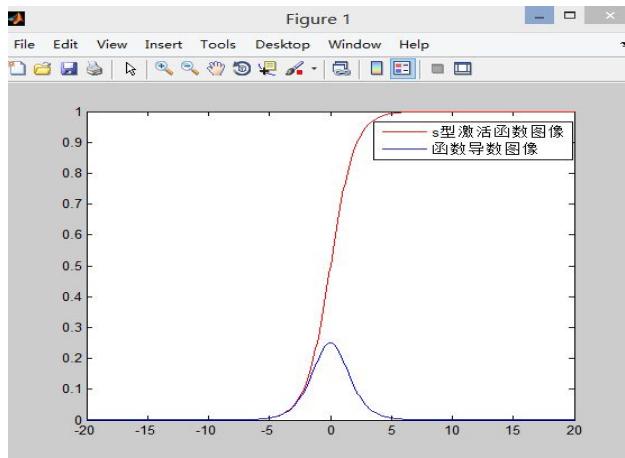


图 5-2 激活函数及其导数图像

神经网路算法，其网络结构为输入层由 n 个神经元，输入量为 $x = (x_1, x_2, \dots, x_n)$ ；隐含层就有 p 个神经元，隐含层的输入量为 $hi = (hi_1, hi_2, \dots, hi_p)$ ，隐含层的输出向量为 $ho = (ho_1, ho_2, \dots, ho_p)$ ；输出层由 q 个神经元，输出层的输入向量 $yi = (yi_1, yi_2, \dots, yi_q)$ ，输出层的输出向量为 $yo = (yo_1, yo_2, \dots, yo_q)$ ；期望输出向量为 $d_o = (d_1, d_2, \dots, d_q)$ ，输入层与中间层的连接权值 w_{ih} ，隐含层与输出层的连接权值 w_{ho} ，隐含层各神经元的阈值 b_h ，输出层各神经元的阈值 b_o ，样本数据个数 m ，误差函数 $e = \frac{1}{2} \sum_{o=1}^q (d_o(k) - yo_o(k))^2$ 。其基本步骤如下所示：

- 1) 初始化权值阈值开始训练。
- 2) 第 k 个输入样本以及其对应的期望输出其公式为：

$$x(k) = (x_1(k), x_2(k), \dots, x_n(k)) \quad (5-3)$$

$$d_o(k) = (d_1(k), d_2(k), \dots, d_q(k)) \quad (5-4)$$

- 3) 第二层第 i 个节点的输入输出公式为：

$$hi_h(k) = \sum_{i=1}^n w_{ih} x_i(k) - b_h \quad (5-5)$$

$$ho_h(k) = f(hi_h(k)) \quad (5-6)$$

$$yi_o(k) = \sum_{h=1}^p w_{ho} ho_h(k) - b_o \quad (5-7)$$

$$ho_o(k) = f(yi_o(k)) \quad (5-8)$$

- 4) 计算误差函数对第三层各神经元的偏导数，得到的公式如下所示：

$$\frac{\partial e}{\partial w_{ho}} = \frac{\partial e}{\partial y_i_o} \frac{\partial y_i_o}{\partial w_{ho}} \quad (5-9)$$

$$\frac{\partial y_i_o(k)}{\partial w_{ho}} = \frac{\partial (\sum_h^p w_{ho} h o_h(k) - b_o)}{\partial w_{ho}} = h o_h(k) \quad (5-10)$$

$$\frac{\partial e}{\partial y_i_o} = \frac{\partial (\frac{1}{2} \sum_{o=1}^q (d_o(k) - y_o(k))^2)}{\partial y_i_o} \quad (5-11)$$

5) 计算误差函数对第二层各神经元的偏导数 $\delta_h(k)$, 得到的公式如下所示:

$$\frac{\partial e}{\partial w_{ho}} = -\delta_o(k) h o_h(k) \quad (5-12)$$

$$\frac{\partial e}{\partial w_{ih}} = \frac{\partial e}{\partial h i_k(k)} \frac{\partial h i_k(k)}{\partial w_{ih}} \quad (5-13)$$

$$\frac{\partial e}{\partial h i_h(k)} = -(\sum_{o=1}^q \delta_o(k) w_{ho}) f'(h i_h(k)) \quad (5-14)$$

6) 修正连接权值 $w_{ho}(k)$, 得到的公式如下所示:

$$\Delta w_{ho}(k) = u \delta_o(k) h o_h(k) \quad (5-15)$$

$$w_{ho}^{N+1} = w_{ho}^N + \eta \delta_o(k) h o_h(k) \quad (5-16)$$

$$\Delta w_{ih}(k) = \delta_h(k) x_i(k) \quad (5-17)$$

$$w_{ih}^{N+1} = w_{ih}^N + \eta \delta_h(k) x_i(k) \quad (5-18)$$

7) 计算全局误差

$$E = \frac{1}{2m} \sum_{k=1}^m \sum_{o=1}^q (d_o(k) - y_o(k))^2 \quad (5-19)$$

8) 进行判断误差是否满足要求, 当满足要求则停止运算。否则依次循环直到满足要求为止。

根据 BP 神经网络模型的学习算法, 可以得到 BP 神经网络模型的学习算法实现流程图如下所示:

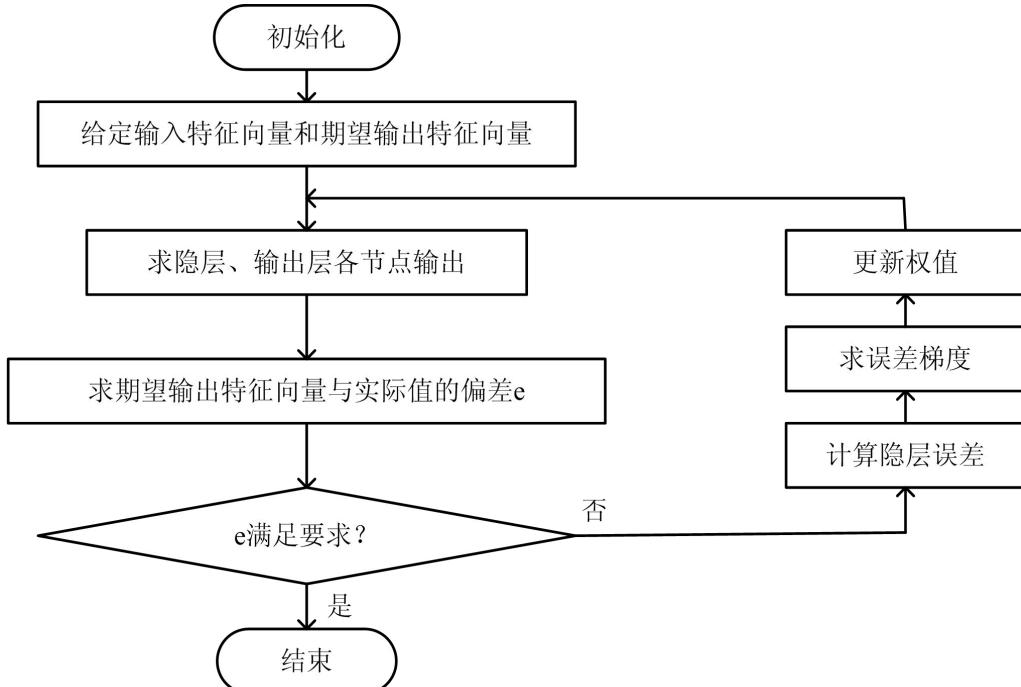


图 5-3 BP 神经网络的工作原理

5.2.2 RBF 神经网络

RBF 神经网络与其他网络相比 RBF 网络对非线性网络具有一致逼近的能力，也可以处理系统内复杂的规律，具有良好的泛化能力，并且结构简单，已经逐步应用在不同行业中。

RBF 神经网络的结构，它是一种三层前向网络，第一层输入层；第二层是隐含层；第三层是输出层。RBF 它的不同层具有不同的功能，隐含层是非线性的，输出层是线性的。RBF 结构如下图所示：

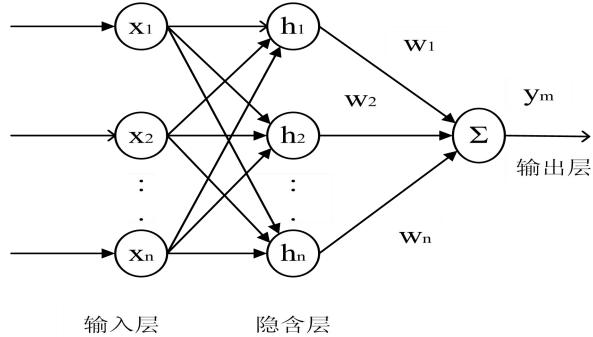


图 5-4 RBF 网络结构

设输入维数为 n ，隐单元数为 m ，输出维数为 p 。设 x 为输入向量， $\|\cdot\|$ 为欧式范数， c_i 为基函数的中心， σ_i 为非线性变换的宽度。 w_i 隐含层与输出层之间连接的权值。隐层节

点的基函数的形式是径向对称的，一般选用高斯函数，网络输入输出模型映射关系如下所示：

$$R_i(x) = \exp\left(-\frac{1}{2\sigma^2} \|x - c_i\|^2\right) \quad (5-20)$$

$$y_i = \sum_{i=1}^h w_i \exp\left(-\frac{1}{2\sigma^2} \|x - c_i\|^2\right) \quad (5-21)$$

在网络结构中，输入层的作用只是对输入的数据进行传送；隐含层是将输入向量空间映射到隐层空间，使原来线性不可分问题转换成线性可分，它采用径向基函数作为基函数；输出层是权值调整。在实际的应用过程中，构造一个 RBF 神经网络系统，就是确定上面的参数，从而完成输入输出的映射。

径向基函数（RBF）神经网络，它的隐含层和输出层的作用是不同的，在给定数据之后，算法按如下步骤进行，第一步，使用 k_ 均值算法求解出径向基函数的聚类中心之后，然后根据得到的数据求解标准差，是一个自组织学习阶段；第二步，是使用最小均方算法或者直接求伪逆的方法进行求解隐含层到输出层之间的权值，是一个有监督的学习阶段^[55]。自适应 RBF 算法流程如下所示。对 RBF 训练之前，首先应确定最大训练次数和训练误差，作为训练结束的条件。

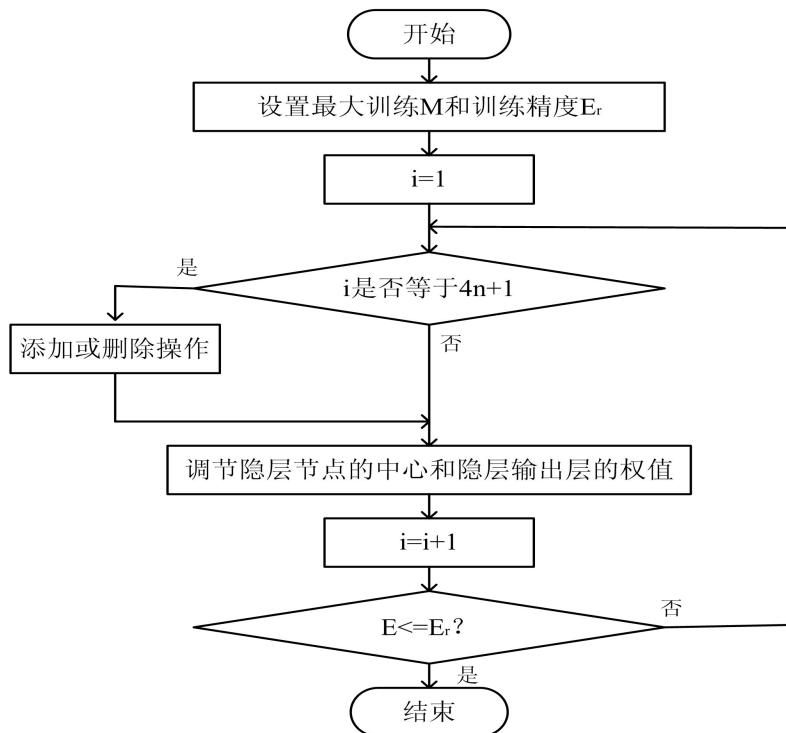


图 5-5 自适应 RBF 网络学习流程图

整个 RBF 网络学习流程图可以分为三个流程，第一流程是初始化径向基函数中心位置和隐层与输出层的权值，通过梯度下降法对网络中的三种参数进行调节。第二流程是执行添加操作，是因为考虑网络输出误差在输入空间中是非均匀分布这一因素提出了这一操作，该操作不会频繁进行，只有满足条件时才去执行这一步骤，否则执行过度就会

导致隐含层节点数目过多，计算复杂性增强，降低调节速度，所以考虑以上因素采用间歇式方法执行。第三流程是执行删除操作，这和第二流程方式一样，采用间歇式方法，否则操作频繁，会导致一些新增的隐节点还未及时处理，就已经被消除，所以当达到一定条件去执行该操作^[56]。

5.3 实验对比分析

数据源测量数据集：包含 2 种类型，7 个属性，280 个的缺陷图像特征参数数据集，其中 2 种类型为气孔和裂纹；7 个属性是 G(1)–G(7)。为了便于比较分析，利用 BP 神经网络和 RBF 神经网络分别进行识别，原始数据集、主成分分析提取特征数据集以及核主成分分析特征提取后的数据集在神经网络上的识别效果，共产生的四种实施方案，具体方案如下：

方案一、原始数据+BP 神经网络

方案二、PCA 提取数据+BP 神经网络

方案三、KPCA 提取数据+BP 神经网络

方案四、原始数据+RBF 神经网络

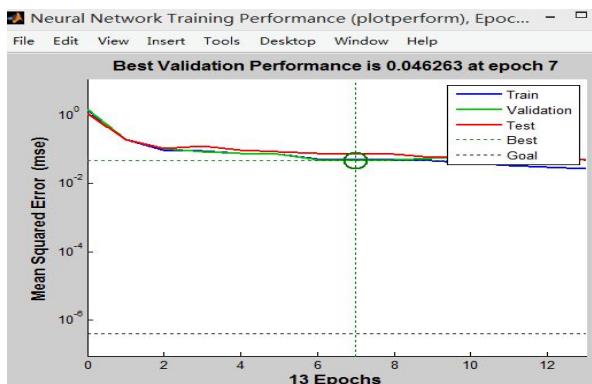


图 5-6 (a) 方案一 BP 网络训练误差曲线

横坐标表示迭代次数，纵坐标表示误差，当迭代到 13 次时达到预设精度。迭代停止时误差为 0.046263。

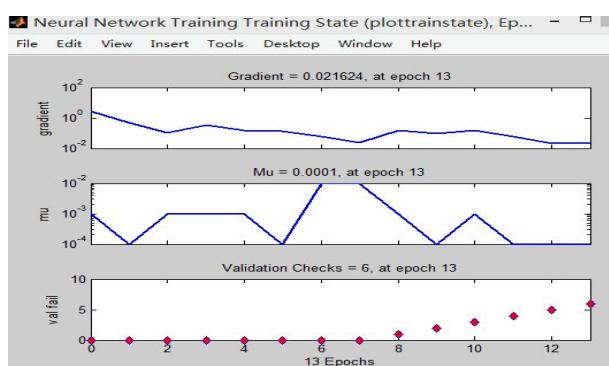


图 5-6 (b) 方案一结果

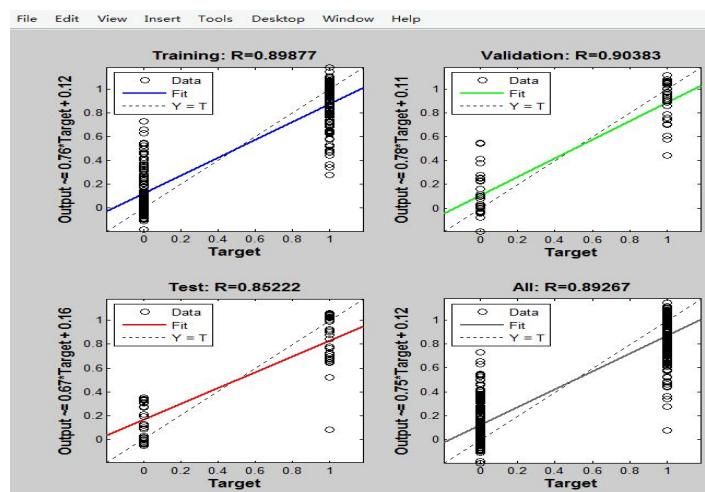


图 5-6(c) 方案一结果

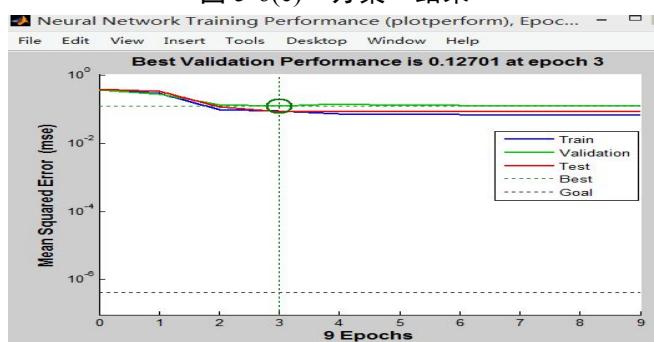


图 5-7 (a) 方案二 BP 网络训练误差曲线

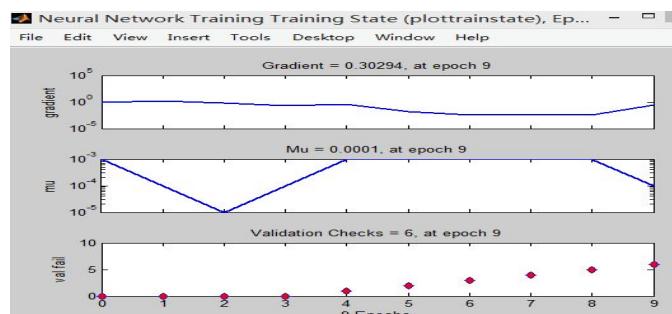


图 5-7 (b) 方案二结果

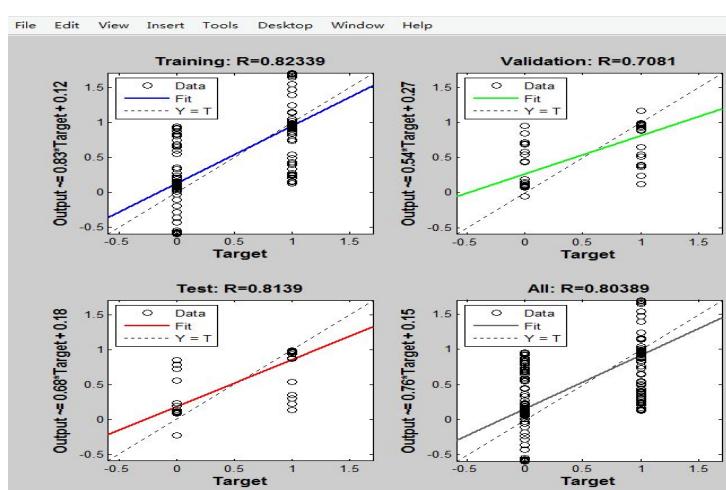


图 5-7(c) 方案二结果

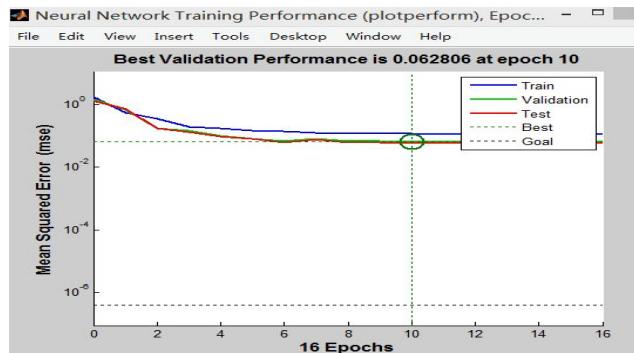


图 5-8 (a) 方案三 BP 网络训练误差曲线

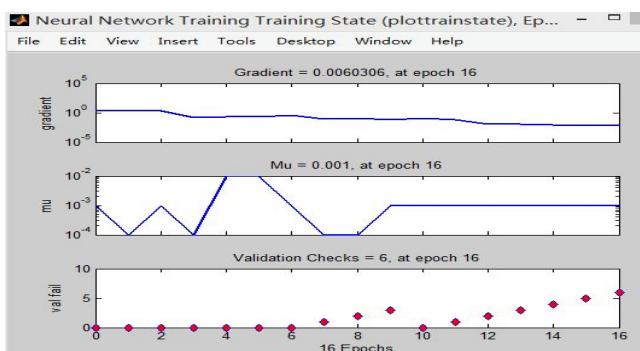


图 5-8 (b) 方案三结果

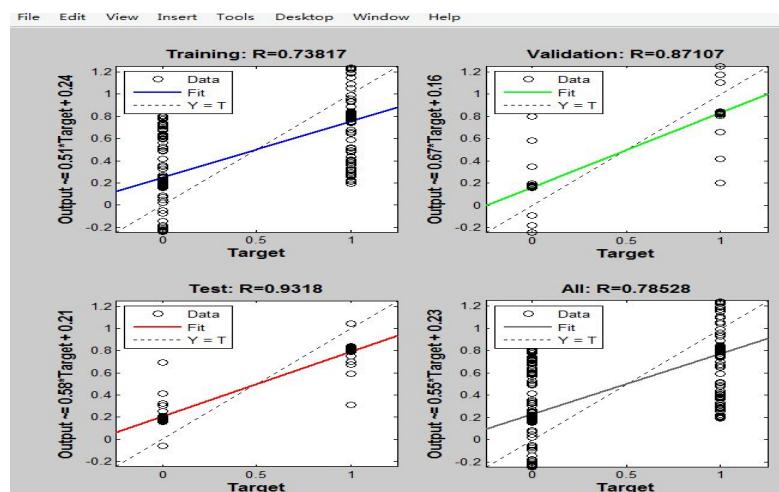


图 5-8(c) 方案三结果

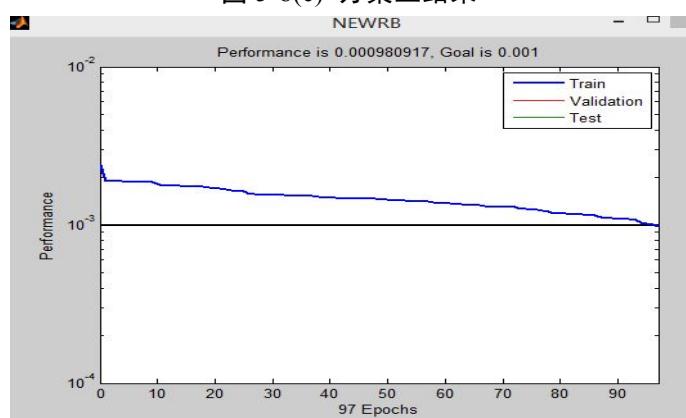


图 5-9 方案四 RBF 网络训练误差曲线

表 5-1 四种方案的识别结果

实验方案	识别对象	对象个数	正确个数	识别率
方案一	缺陷	280	235	83.92%
方案二	缺陷	280	238	85%
方案三	缺陷	280	252	90%
方案四	缺陷	280	237	84.64%

根据表 5-1 的数据分析可以得出以下结论, 方案一在原始数据集上直接使用 BP 神经网络进行识别是四个方案中结果准确率最低的, 方案二和方案三分别利用主成分分析和核主成分分析进行特征提取后的数据, 在分别使用 BP 神经网络进行识别, 结果的准确率得到了进一步的提高, 而且核主成分分析对特征提取的准确率要比主成分分析的更高一些; 方案四阐述了使用 RBF 神经网络比使用 BP 神经网络识别准确率要高一些, 建立网络和训练网络时间也比 BP 神经网络少。

5.4 本章小结

本小章主要介绍了神经网络的特点、原理和网络模型(BP 神经网络、RBF 神经网络)。最后通过数据显示, 在特征参数的提取中, 不管利用主成分分析还是核主成分分析进行特征提取, 最后结果的识别率都有所提高, 但核主成分分析对缺陷识别正确率比主成分分析效果较好一些; 在不同的模型中, 使用 RBF 神经网络比使用 BP 神经网络识别效果要好一些而且效率高些。

第六章 总结与展望

6.1 总结

本课题以埋弧焊焊缝缺陷图像为研究对象,进行了基于主成分分析的识别算法研究,特征参数的提取对焊缝缺陷检测结果至关重要,所以要进一步研究图像处理技术,图像的前期处理工作需要通过一些实验进行分析和探讨,选择一种适合本课题的处理技术,使缺陷识别结果更加准确。重点研究了主成分分析和核主成分分析的特征提取和BP神经网络、RBF神经网络的识别。

本文主要从以下方面探讨研究。

1)首先对焊缝缺陷图像进行前期处理工作,对其工作中出现一些问题采用不同的技术进行处理。其一,图像采集中产生的噪声,本文运用中值滤波和均值滤波进行比较,针对不同的检测图像使用不同的滤波方法进行降噪。其二,前景和背景区域对比度相差不大的问题,本文采用sin函数增强方法扩大不同区域特征之间的差异。其三,针对目标区域与背景区域的分割,本文采用OSTU大律法分割。其四,为了得到焊缝边界信息,本文分别采用不同的微分算子进行比较分析,所以选用Canny算子,因为它对噪声的抑制效果最好,而且能够检测清晰边缘。最后,利用灰度曲线分析进行缺陷定位。

2)然后对提取的缺陷图样进行特征参数的测量,进一步实现不同缺陷的分类与识别。首先本文选用7个形状特征参数作为样本的输入数据集,然后分别利用主成分分析法和核主成分分析法进行特征参数提取,在其过程中,不管利用那种方法都提取了主元、减少了特征数据量,但核主成分分析对特征参数的提取方面略微好于主成分分析。

3)最后利用神经网络进行识别,分别采用六种不同的方案进行比较分析,分别对原始数据,主成分分析提取的数据和核主成分分析提取的数据运用BP、RBF神经网络分别进行识别,对比识别率,明显运用主成分分析和核主成分分析进行特征参数提取的方案要优于原始数据,并且核主成分分析的方案稍微优于主成分分析的方案。

6.2 展望

虽然有些方法在某些方面得到了一定的效果,但是不一定适合所有图片的处理,而且产生的效果也不一定是最好的,所以还存在着一些问题需要进一步研究。

其一,在核主成分的核函数选择时要尽可能多的尝试新的函数进行特征提取并和其他函数进行对比分析。

其二,在神经网络的选择上要尽可能选择多的模型进行缺陷类型识别并对其正确率进行分析比较。

其三，在缺陷类型识别中，可以选用核主成分分析和 SVM 进行研究。

其四，每一种算法都有优缺点，要尽可能的思考将多种算法进行结合进行研究。

致 谢

时光荏苒，我的硕士生涯已接进尾声。这几年的时光既漫长又短暂，其中充满了酸甜苦辣，更有收获和成长。几年来，感谢陪我一起度过美好时光的每位尊敬的老师和亲爱的同学，正是你们的帮助，我才能克服困难，正是你们的指导，我才能解决疑惑，直到学业的顺利完成。

首先，由衷的感谢我的导师穆向阳教授，感谢他在科研、学习和生活中曾经给与的无微不至的关心和照顾，是他将我带入了模式识别的领域，给我展现了另一片天空，让我有机会站在巨人的肩膀上看得更远。论文从初稿到终稿都离不开他们的严格要求、悉心指导和字字把关，他们开阔的视野、严谨的作风和求是的态度将影响和激励我的一生。

三年的石大生活，三年的成长，对于我来说是不能一笔带过的历程。感谢我的同学以及实验室的师兄们，对于遇到的问题我们一起探讨，大家一起交流写作经验，共同进步。他们提出的建议与鼓励使我获益良多。感谢你们的帮助，愿我们一起顺利完成学业找到好工作。最后深深的感谢呵护我成长的父母。每当我遇到困难的时候，父母总是第一个给我鼓励的人。回顾 20 多年来走过的路，每一个脚印都浸满了他们无私的关爱和谆谆教诲，10 年的在外求学之路，寄托着父母对我的殷切期望。他们在精神上和物质上的无私支持，坚定了我追求人生理想的信念。父母的爱是天下最无私的最宽厚的爱。大恩无以言报，惟有以永无止境的奋斗，期待将来辉煌的事业让父母为之骄傲。我亦相信自己能达到目标。

最后，我要向百忙之中参与审阅、评议本论文各位老师、向参与本人论文答辩的各位老师表示由衷的感谢！再次由衷的向所有关心帮助过我的人致以最诚挚的谢意！

参考文献

- [1] 苗世疆.从焊接工艺角度分析焊接缺陷类型及成因[J].内蒙古石油化工,2015,(11): 99~101.
- [2] 陈本智,方志宏.基于 X 射线图像的厚钢管焊缝中气孔缺陷的自动检测[J].计算机应用,2017,37(3):849~853.
- [3] 邵家鑫,都东,石涵,等.基于厚壁工件 X 射线实时成像的焊缝缺陷自动检测[J].清华大学学报(自然科学版),2013,53(2):150~154.
- [4] 邵中华.X 射线焊缝数字图像的缺陷提取技术研究[D].中北大学, 2011.
- [5] Lashkia V. Defect detection in X-ray images using fuzzy reasoning [J]. Image and Vision Computing, 2001,19(5):261~269.
- [6] 王彬.焊接缺陷超声波检测信号的小波分析与处理[D].西安科技大学,2003.
- [7] 王恩亮.X 射线无损探伤中缺陷的自动检测与识别[D]大连理工大学,2003.
- [8] 藤田勉.溶接部写真の画像処理[J].日立造船技报,2003,39(4):1~5.
- [9] Liao, T.Warren ; Ni, Jiawei. Automated radiographic NDT system for weld inspection: Part I - weld extraction [J]. NDT and E International,1996, 29(3):157~162.
- [10] 杨川.焊缝缺陷图像特征提取[D].武汉理工大学,2010.
- [11] 魏大慧. X 射线检测焊缝缺陷图像的预处理[J].中国西部科技学术,2010,30(2):31~32.
- [12] 仲崇丽.X 射线探伤中焊缝缺陷的图像处理与自动识别[D].西安电子科技大学,2010.
- [13] 莫国柱.X 射线焊缝图像缺陷提取技术的研究[D].北京邮电大学,2010.
- [14] Inoue,Katsunori,Kobayashi,Masafumiv.Automatic Recognition of Weld Defects in Radiographic Test(Report I)-Extraction of Feature Parameters[J].Teansaction of JWRI(Japanese Welding Research institude),1982,11(2):9874~9882.
- [15] 王鹏.基于神经网络的焊缝缺陷自动识别技术研究[D].西安工业大学,2014.
- [16] 蔡晓龙,穆向阳.基于支持向量机的焊缝缺陷建模及其识别算法研究[D].西安石油大学, 2014.
- [17] Zapata J,Vilar R,Ruiz R.performance evaluation of an automatic inspection system of weld defects in radiographic images based on neuro classifiers[J].Expert Systems with Applications,2011,38(7): 8812~8824.
- [18] Barai S V,Agrawal neuro classifier for weld defect classification[M].Applied soft Computing Technologies:The Challenge of Complexity[J]. Springer Berlin Heidelberg,2006,67(9):37~54.
- [19] 李力. 基于小波和神经网络的焊接缺陷识别方法[J].三峡大学学报（自然科学版）,2014, (1):72~34+107.
- [20] 巩森.基于模糊集和神经网络的焊缝缺陷识别技术研究[D].东北石油大学,2014.
- [21] 殷鹰,毛健.基于主成分分析法的 X 射线焊缝缺陷图像增强与分割算法[J].矿山机械,2011,32(9):678~683.
- [22] ZVOKELJ M,ZUPAN S,PREBIL I.Multivariate and multiscale monitoring of large-size low-speed

- bear-ings using ensemble empirical mode decomposition method combined with principal component analysis[J].Mechanical Systems and Signal Processing,2010,24(4):1049~1067
- [23] ZVOKELJ M,ZUPAN S,PREBIL I.Non-liner multivariate and multiscale monitoring and signal denoising strategy using kernel principal component analysis combined with ensemble empirical mode decomposion method[J].Mechanical Systems and Signal Processing,2011,25(7):2631~2653.
- [24] 李博.焊缝 X 射线图像缺陷识别技术研究[J].赤峰学院学报（自然科学版）,2010,26(4):86~89.
- [25] 张兆礼, 赵春晖.现代图像处理技术及 Matlab 实现[M].北京: 人民邮电出版社, 2011.
- [26] 宁媛, 李皖.图像去噪的几种方法分析比较[J].贵州工业大学学报,2005,34(4): 63~66.
- [27] 莫玲,高向东.微间隙焊缝磁光图像增强方法[J].焊接技术,2015,44(6):17~22.
- [28] Sauvola J,Pietikainen M.Adaptive document image binarization[J].Pattern recognition,2000,33(2): 225~236.
- [29] 段瑞玲, 李庆祥.图像边缘检测方法研究综述[J].光学技术, 2005,31(3): 415~419.
- [30] Jang J S R.ANFIS:adaptive-network-based fuzzy inference system[J].Systems,Man and Cybernetics, IEEE Transactions on,1993,23(3):665~685.
- [31] L.I.Kuncheva,W.J.Faithfull.Pca feature extraction for change detection in multidimensional unlabeled data[J].Neural Networks and Learning Systems,IEEE Transactions on Jan, 2014,25(1):69~80.
- [32] 蔡晓龙,穆向阳,高炜欣,等. PCA 和贝叶斯分类技术在焊缝缺陷识别中的应用[J].焊接,2014,(3): 32~36.
- [33] 黄国宏.核主元分析及其在人脸识别中的应用[J].计算机工程,2004,30(13):13~14.
- [34] 杨胜凯.基于核主成分分析的特征变换研究[D].浙江大学,2014.
- [35] 张盼,陈志东.基于小波变换的 X 射线数字图像焊接缺陷边缘检测[J].管道技术与设备, 2016, (3) :41~43.
- [36] 宋庆国.焊缝图像缺陷提取与识别系统研究[D].武汉理工大学,2008.
- [37] 王珩.基于人眼视觉特性的焊缝 X 射线图像辅助判读系统[J].无损检测,2009,31 (3)
- [38] 任治, 苏真伟.一种焊缝 X 射线数字图像的缺陷提取算法[J].无损检测, 2009, 31 (2): 89~91+146.
- [39] 周正干,赵胜.基于分区域自适应中值滤波的 X 射线图像缺陷提取[J].航空学报,2004, 25(4): 420~224.
- [40] 陈光.焊缝 X 射线数字图像处理及缺陷检测方法研究[D].兰州理工大学,2007.
- [41] 邸慧,于起峰.一种基于灰度变换的红外图像增强算法[J].应用光学, 2006,27(1):12~14.
- [42] 冈萨雷斯.数字图像处理[M].电子工业出版社,2014.
- [43] 郭延龙.焊缝 X 射线图像缺陷检测技术研究[D].华东理工大学,2011.
- [44] 李华.一种基于方向曲线的目标检测方法[J].中国图像图形学报,1999,4(7):590~594.
- [45] John Canny.A Computational Approach to Edge Detection[J].IEEE Transactions on Pattern Analysis and Machine IntelligenceVol,PAMI-8 No.6 1986,12:679~697.
- [46] 王娜.管道焊缝缺陷射线检测图像获取与处理的数字化技术研究[D].东北大学,2009.

- [47] 胡敏, 李梅, 汪荣贵, 等. 改进的 OSTU 算法在图像分割中的应用[J]. 电子测量与仪器学报, 2010, 24(5): 443~449.
- [48] 赵玉霞, 王克如, 白中英, 等. 贝叶斯方法在玉米叶部病害图像识别中的应用[J]. 计算机工程与应用, 2007, 43(5): 193~195.
- [49] 蔡晓龙, 穆向阳, 高炜欣, 等. PCA 和贝叶斯分类技术在焊缝缺陷识别中的应用[J]. 焊接, 2014, (3): 32~36.
- [50] 杨俊. 基于核主成分分析和径向基神经网络的文本分类研究[D]. 中国科学技术大学, 2009.
- [51] 蒋宗礼. 人工神经网络[M]. 高等教育出版社, 2001.
- [52] 胡昕. 应用人工神经网络模式识别技术建立了 X 射线探伤底片的自动定级系统[J]. 无损检测, 2007, 29(1): 36~39.
- [53] 贺瑞芳. 基于 BP 神经网络的图像目标识别算法研究[J]. 微处理机, 2015, 15(6): 54~61.
- [54] 高岚, 胡亮, 罗乐, 等. 基于 BP 神经网络的船舶焊缝缺陷图像识别[J]. 武汉理工大学学报, 2012, 34(3): 272~274.
- [55] 马云龙, 王喆. 基于主成分分析的 RBF 神经网络预测算法及其应用[D]. 吉林大学, 2015.
- [56] 乔荣华, 张永恒. 基于 RBF 网络的焊缝缺陷图像的识别与诊断技术研究[J]. 热加工工艺, 2016, 62(1): 217~220.

攻读硕士学位期间发表的论文

- [1] 张君.基于主成分分析的焊缝缺陷识别[J].工业控制计算机,2017,30(1):108~109.192~194.



招 生 办: 029-88382328
培 养 办: 029-88382327
学 位 办: 029-88382324
学校网址: <http://www.xsyu.edu.cn>